# Avaliação de Desempenho de Redes

## MCZA004-13

## Variáveis Aleatórias Discretas

Prof. Carlo Kleber

# Sumário

1. Introdução
2. Sistema e Modelos
3. Teoria da Probabilidade
4. Variáveis Aleatórias
5. Variáveis Aleatórias Discretas
6. Síntese final

Parte Prática

Referências

# 1. Introdução

- Neste módulo temos os seguintes **três** objetivos **principais:**

1. Ressaltar a importância da **teoria da probabilidade** na **avaliação de desempenho de redes.**
2. Apresentar conceitos **básicos** da **teoria da probabilidade.**
3. Apresentar **algumas** das mais importantes **variáveis aleatórias discretas.**

# 2. Sistema e Modelos

- O **sistema** (rede de computadores) a **ser avaliado** pode ser **real** e **estar em operação** ou, talvez, representar um **projeto** a ser implantado, constituindo, por exemplo, uma **ideia** ou uma **solução** ainda a ser desenvolvida.

- O **método de avaliação de desempenho** denominado de **medição** consiste em **escrutinizar** o **sistema real** em **operação normal**. Mas, para evitar **complexidade**, pode ainda imaginar-se a **realização de testbeds**, i.e., experimentos controlados em espaços reais.

- Também, pode-se, ainda, pensar na **construção de protótipos** (modelos físicos parciais/simplificados) para, sobre eles, realizar a **avaliação pretendida.**

- **De qualquer forma**, é de esperar que a **medição** seja, invariavelmente, o **método de avaliação de maior custo associado.**

- **Por outro lado**, se desejamos evitar o método da **medição**, por qualquer que seja a razão, resta-nos então as opções dos métodos denominados, respectivamente, de **modelagem analítica** e **simulação.**

- Tanto no caso da **modelagem analítica** como na **simulação** precisamos construir um **modelo. No caso da modelagem analítica,** tem-se um **modelo matemático**, i.e., um modelo que é expresso diretamente por meio de **formulações matemáticas, representando o sistema.**

- No caso da **simulação**, tem-se o **modelo de simulação**, que um **programa computacional** (software) que representa o sistema. Veja que o **modelo de simulação** pode ser visto como um **modelo matemático** expresso por meio de uma linguagem de programação.

- Em ambos casos, a **avaliação** consiste na **resolução do modelo**.

- Sob o método da **modelagem analítica**, vamos resolver o **modelo** encontrando uma **solução exata**. Neste caso, as teorias envolvidas são geralmente de **Pesquisa Operacional, Teoria das Filas, Equações Diferenciais, dentre outras.**

- Sob o método da **simulação,** o **modelo** obtido não apresenta (ou não sabemos como obter) **respostas precisas e definitivas**, sendo necessária uma **abordagem mais holística e sistêmica.**

- No **método da simulação**, o que fazemos, **de maneira geral**, é estimular sistematicamente o **modelo** por meio de entradas (dados), e monitoramos suas saídas (respostas) até que atinja-se **uma convergência ou alguma condição de parada**.

# 2.1 Modelagem Correta

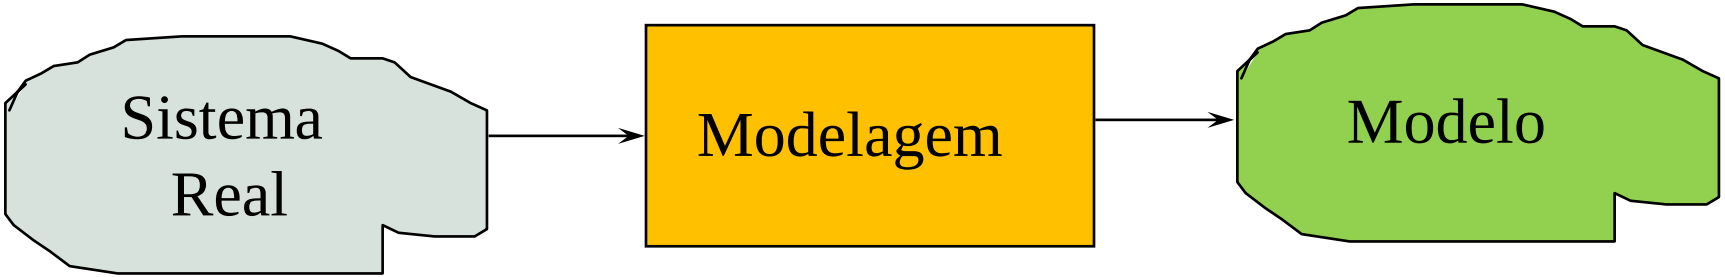

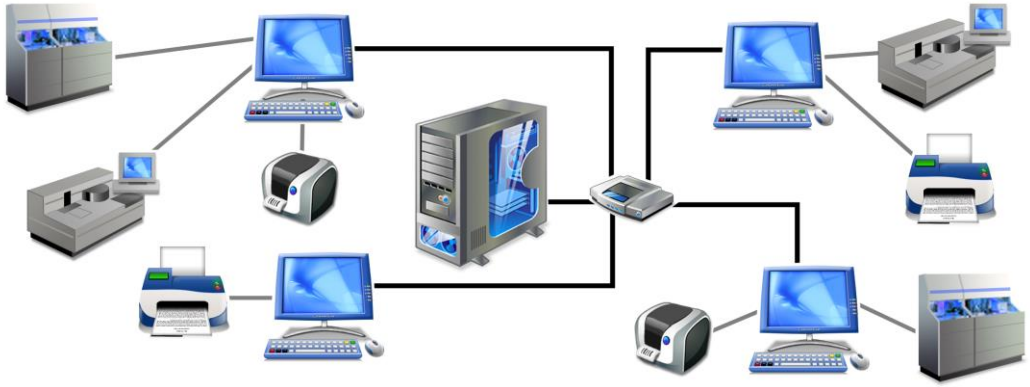

# 2.1 Modelagem Correta

- Para obter um **modelo correto**, precisamos considerar:

1. **Abrangência**: É preciso definir a **abrangência desejada**. Expectativas **irreais**, ou **mal definidas**, podem levar o melhor dos modelos a ser totalmente descartado por não retratar o que era desejado. **Exemplo**: toda a rede ou apenas parte da rede?
2. **Nível de detalhamento**: Mesmo com o escopo bem definido, precisamos ainda saber quais são as expectativas com relação **ao nível de detalhamento esperado**. **Exemplo**: modelar nos mínimos detalhes uma parte da rede?

3. **Entendimento dos conceitos**: Isso significa que, quando da transposição do **sistema real** observado para o **modelo**, devemos antes conseguir **plenamente** entender o **sistema real,** bem como o **modelo então elaborado**.

4. **Verificação de fidelidade e coerência**: É preciso verificar se o **modelo concebido** está **coerente e fiel** aos conceitos encontrados. Se observarmos falhas, devemos verificar se estas existem em função de **conceitos mal formados, pontos de vista equivocados**, etc. Dependendo de onde tenha ocorrido a falha, deveremos **voltar aos passos executados até o momento** para retomar o caminho certo.

# 2.3 Importância da Teoria da Probabilidade

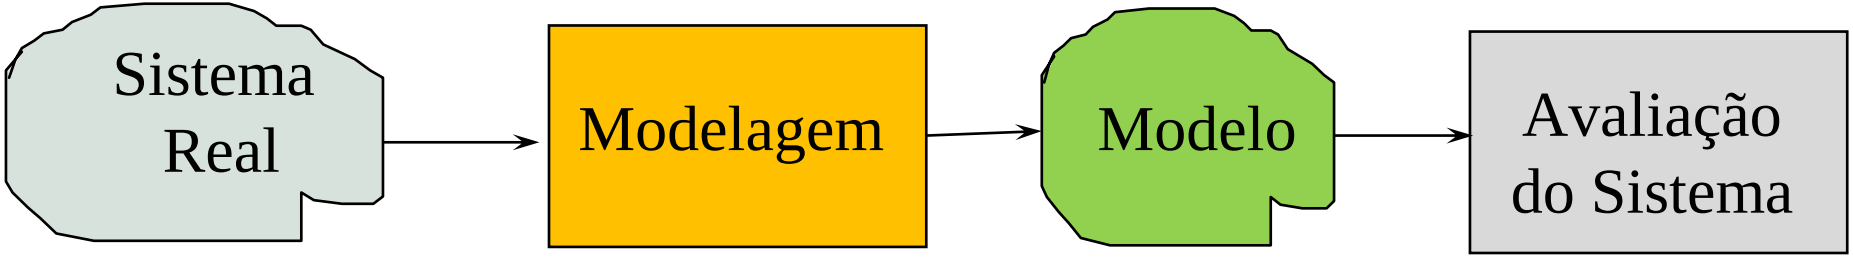


- **De maneira geral**, os **sistemas** (redes de computadores) a serem **modelados** possuem um **comportamento aleatório.**
- **Ou seja, não** há como **prever deterministicamente** o que vai ocorrer.
- A **variação do comportamento** dos sistemas **tem que ser** representada no **modelo** construído.

# 2.3 Importância da Teoria da Probabilidade

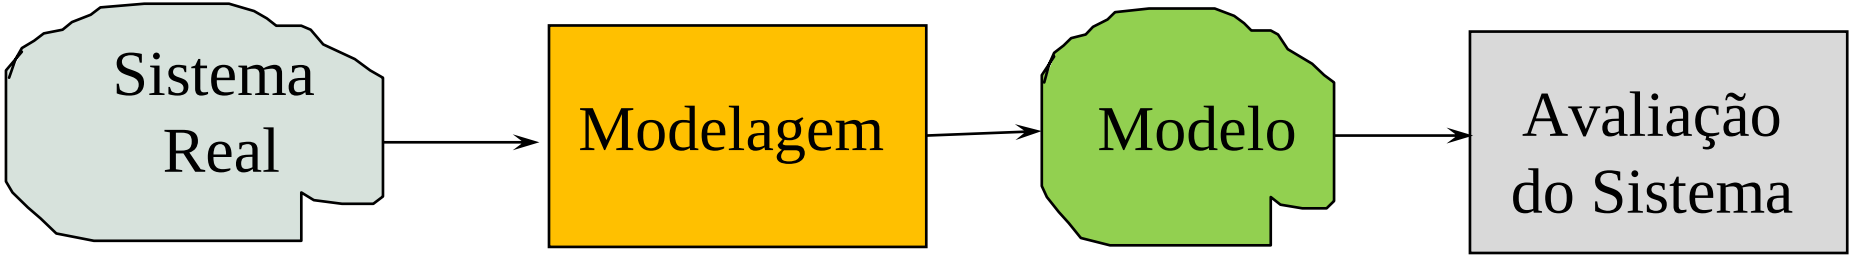


- Um **modelo probabilístico** permite a **representação de fenômenos aleatórios,** e.g., chegadas de mensagens e tempo de transmissão.
- Daí a **importância da teoria da probabilidade** e conhecimentos afins na **avaliação de desempenho de redes.**

# 3. Teoria da Probabilidade

# 3.1 Espaço Amostral e Eventos

- O conjunto de **todos os resultados possíveis** de um experimento aleatório é chamado de **espaço amostral S**.

- Qualquer **subconjunto E** do espaço amostral **S** é um **evento.**

- **Experimento:** Observar o funcionamento de dois componentes de um certo sistema.
  - **S** = {(0, 0), (0, 1), (1, 0), (1, 1)}
  - Somente 1 componente funciona: **E** = {(0, 1), (1, 0)}
  - Os dois componentes funcionam: **E** = {(1, 1)}

- Uma **lista de eventos** $F_1, F_2, ..., F_n$ é composta de eventos **mutuamente exclusivos** se e somente se:
  - $F_i \cap F_j = F_i$ **, se i = j** **(Interseção)**
  - $F_i \cap F_j = \varnothing$ **, se i ≠ j** **(Interseção)**

- **Intuitivamente**, uma lista de **eventos** é composta de **eventos mutuamente exclusivos** se não há não **nenhum elemento** no espaço amostral **S** que esteja incluído em **mais de um evento** na lista.

- Uma **lista de eventos** $F_1, F_2, ..., F_n$ é dita ser **coletivamente exaustiva** se e somente se:
  - $F_1 \cup F_2 \cup F_3 \ldots \cup F_n = S$ **(União)**

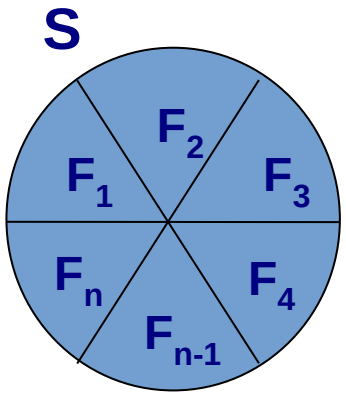

# 3.2 Probabilidade de Eventos

- O **comportamento do experimento** é representado por meio dos **eventos.**

- A **aleatoriedade** é representada pela associação de **probabilidades aos eventos.**

- Para cada evento **E** do espaço amostral **S,** é associada uma **probabilidade P(E).**

- **P(E)** deve satisfazer o seguinte:
  - $0 \leq P(E) \leq 1$
  - $P(S) = 1$

- Se dois eventos **E** e **F** são **mutuamente exclusivos** então:
  - $P(E \cup F) = P(E) + P(F)$

- Se os eventos $E_1, E_2, \ldots, E_n$ são **mutuamente exclusivos** e **coletivamente exaustivos** então:

$$P(E_1 \cup E_2 \cup \ldots \cup E_n) = P(E_1) + P(E_2) + \ldots + P(E_n) = 1$$

# 3.3 Relações Importantes

- Considere o **evento E** e o seu **complemento $\overline{E}$**. Os eventos **E** e $\overline{E}$ são **mutuamente exclusivos** e **$E \cup \overline{E} = S$**. Tem-se então que:
  - $P(E \cup \overline{E}) = P(E) + P(\overline{E}) = P(S) = 1$
  - $P(E) = 1 - P(\overline{E})$
- Considere dois eventos **E** e **F** **não** necessariamente **mutuamente exclusivos**. Tem-se então que:
  - $P(E) + P(F) = P(E \cup F) + P(E \cap F)$
  - $P(E \cup F) = P(E) + P(F) - P(E \cap F)$

- **Exemplo 1: Exercício 1 (Taboga, 2017).**

Uma bola é tirada **aleatoriamente** de uma urna contendo bolas coloridas. As bolas podem ser **azuis ou vermelhas** (nenhuma outra cor **é possível**). A probabilidade de tirar uma bola **azul** é de **1/3**. **Qual é a probabilidade de tirar uma bola vermelha?**

Taboga, Marco (2017). "Probability", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/fundamentals-of-probability/probability.

https://www.statlect.com/fundamentals-of-probability/probability

- **Exemplo 1: Exercício 1 (Taboga, 2017).**
- O **espaço amostral S** pode ser representado como a união de dois eventos **E** e **F** mutuamente exclusivos.
- O **evento E** pode ser descrito como **"uma bola azul é tirada"**, e o **evento F** pode ser descrito como **"uma bola vermelha é tirada"**. Observe que, neste experimento, **F** é o **complemento** de **E, isto é, F=** $\overline{E}$.
- Nós sabemos a probabilidade de tirar uma **bola azul** é **P(E) = 1/3**. Precisamos encontrar a probabilidade de tirar uma bola vermelha, i.e., **P(F) = P(**$\overline{E}$**).** Temos então:
- $P(E \cup F) = P(E \cup \overline{E}) = P(E) + P(\overline{E}) = P(S) = 1$
- $P(\overline{E}) = 1 - P(E) = 1 – 1/3 =$ **2/3**

- **Exemplo 2: Exemplo 1.3 (Trivedi, p. 20)**

Um grupo de quatro chips VLSI é constituído por **dois** chips bons, rotulados g1 e g2, e **dois** chips defeituosos, rotulados d1 e d2. Se três chips forem selecionados aleatoriamente neste grupo, **qual é a probabilidade do evento E = "dois dos três chips selecionados estão com defeito"?**

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

- **Exemplo 2: Exemplo 1.3 (Trivedi, p. 20)**

Um **espaço amostral** natural para este problema consiste em todas as seleções possíveis de três chips do grupo de quatro chips: **S = {g1g2d1, g1g2d2, g1d1d2, g2d1d2}.** Não importa a ordem, tampouco há reposição.

Ademais, é comum interpretar a frase **"selecionado aleatoriamente"** como implicando pontos amostrais **equiprováveis** (i.e., de mesma probabilidade). Assim, como os **dois** pontos amostrais "g1d1d2" e "g2d1d2" são favoráveis ao evento E, e como o espaço de amostra tem **quatro** pontos, concluímos então que **P(E) = 2/4 = ½**

# 3.4 Probabilidade Condicional

- **P(A|B)**: **Probabilidade condicional** do evento **A** dado que o evento **B** ocorre ou, simplificadamente, a **probabilidade condicional de A dado B** é:

$$\text{Se } P(B) \neq 0, \text{então } P(A|\mathrm{B}) = \frac{P(A \cap B)}{P(B)}$$

$$\text{Se } P(B) = 0, \text{então } P(A|B) \text{ é indefinida}$$

- Esta definição leva às seguintes **formulações:**

$$P(A \cap B) = \begin{cases} P(B)P(A|B), \text{se } P(B) \neq 0 \\ P(A)P(B|A), \text{se } P(A) \neq 0 \\ 0, \text{caso contrário} \end{cases}$$

- Se **A** e **B** são eventos **independentes** então:

$$P(A|\mathrm{B}) = P(A)$$
$$P(B|A) = P(B)$$
$$P(A \cap B) = P(A)P(B)$$

- Se **A** e **B** são eventos **mutuamente exclusivos** então:

$$P(A|\mathrm{B}) = 0$$
$$P(B|A) = 0$$

- Uma **lista** de ***n*** eventos **$A_1$, $A_2$, ..., $A_n$** é definida como **mutuamente independente** se, e somente se, para cada **conjunto de k** (2 ≤ k ≤ n) índices distintos **$i_1$, $i_2$, ...,$i_k$**, que são elementos de **{1, 2, …,n},** tem-se:

$$P(A_{i_1} \cap A_{i_2} \cap \cdots \cap A_{i_k}) = P(A_{i_1})\mathrm{P}(A_{i_2}) \cdots P(A_{i_k})$$

- **Exemplo 3: Exemplo 1.9 (Trivedi, p. 26)**

Um sistema microprocessador consiste em um **chip de CPU** e um **chip de memória RAM**. O chip de **CPU** é selecionado a partir de um **lote de 100**, **dez** das quais estão com defeito, e o chip **memória** é selecionado a partir de um lote de **300**, **quinze** dos quais estão com defeito. Defina **A** como o evento “o chip de CPU selecionado está com defeito”, seja **B** o evento “o chip de memória selecionado está com defeito”, e seja **C** o evento “o chip de CPU selecionado e o chip de memória selecionado estão com defeito”.

**Determine P(A), P(B) e P(C).**

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

- **Exemplo 3: Exemplo 1.9 (Trivedi, p. 26)**

Podemos notar que:

P(A) = 10/100 = **0,1** e P(B) = 15/300 = **0,05**.

Agora, como os dois chips são selecionadas de lotes diferentes, podemos esperar que os eventos **A e B** sejam **independentes**. Desse modo, temos:

$P(C) = P(A \cap B) = P(A).P(B) = 0{,}1 \times 0{,}05 =$ **0,005**

- **Exemplo 4: Exemplo 1.8 (Trivedi, p. 25)**

Temos uma caixa com **5000 chips**, **1000** dos quais fabricados pela **companhia X** e o restante pela **companhia Y**. **10% dos chips** fabricados por **X** são defeituosos, e **5%** dos chips de **Y** são defeituosos. **Se um chip** aleatoriamente **escolhido** de dentro da caixa é **defeituoso, calcule a probabilidade de ele ter sido fabricado pela companhia X.**

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

## Exemplo 4: Exemplo 1.8 (Trivedi, p. 25)

- Defina os seguintes eventos: **A** = “chip fabricado por X”, **B** = “chip é defeituoso”.
- Como de 5000 chips, 1000 são de X, então **P(A)** = **1000/5000 = 0,2.**
- Ainda, de um total de 5000 chips, 300 são defeituosos, sendo 100 de X, e 200 de Y. Daí, **P(B) = 300/5000 = 0,06.**
- Agora, defina o evento **A ∩ B** = “o chip é fabricado por X e é defeituoso”. Dentre 5000 chips, 100 chips se enquadram nesse evento. Daí, **P(A ∩ B) = 100/5000 = 0,02.**
- Podemos agora **calcular a probabilidade** desejada:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{0{,}02}{0{,}06} = \mathbf{\frac{1}{3}}$$

- **Exemplo 5: Exemplo 1.11 (Trivedi, p. 28)**

Considere o experimento de lançar dois dados. Seja o espaço amostral **S = {(i, j) | 1 ≤ i, j ≤ 6}.** Suponha também que cada ponto amostral tem uma mesma probabilidade de **1/36** (i.e., equiprováveis). Defina os eventos **A, B e C** de modo que **A** = "primeiro dado resulta em 1, 2 ou 3", **B** = "segundo dado resulta em 4, 5 ou 6", **C** = "a soma das duas faces é 7 ". **Determine P(A∩B), P(A∩C), P(B∩C), P(A∩B∩C).**

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

**Exemplo 5: Exemplo 1.11 (Trivedi, p. 28)**

Temos que:

$A \cap B = \{(1, 4), (1, 5), (1, 6), (2, 4), (2, 5), (2, 6), (3, 4), (3, 5), (3, 6)\}$

$A \cap C = \{(1, 6), (2, 5), (3, 4)\} = B \cap C = A \cap B \cap C$

Portanto:

$P(A \cap B) = 9/36 = \mathbf{1/4} = P(A)P(B)$

$P(A \cap C) = 3/36 = \mathbf{1/12} = P(A)P(C)$

$P(B \cap C) = 3/36 = \mathbf{1/12} = P(B)P(C)$

Mas $P(A \cap B \cap C) = \mathbf{3/36} \neq P(A)P(B)P(C) = (18/36)(18/36)(6/36) = \mathbf{1/24}$. Isto ocorre porque os eventos A, B, and C têm independencia apenas de um em relação ao outro (par a par), mas **não são mutuamente independentes**.

# 3.5 Teorema da Probabilidade Total

- **Interprete** a figura a seguir:

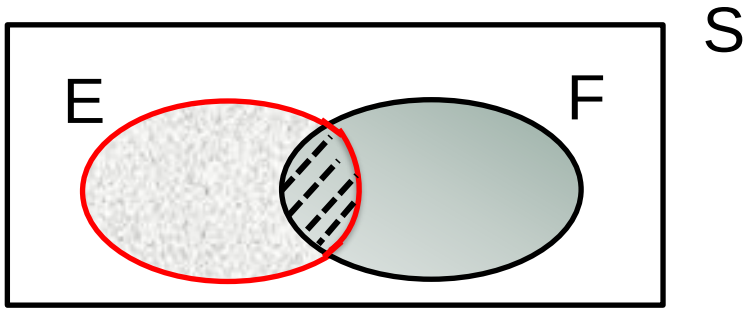


- Tem-se então **que:**

$$E = (E \cap F) \cup (E \cap \bar{F})$$

$$P(E) = P(E \cap F) + P(E \cap \bar{F})$$

$$P(E) = P(E|F)P(F) + P(E|\bar{F})P(\bar{F})$$

# 3.5 Teorema da Probabilidade Total

- **Generalizando-se**:

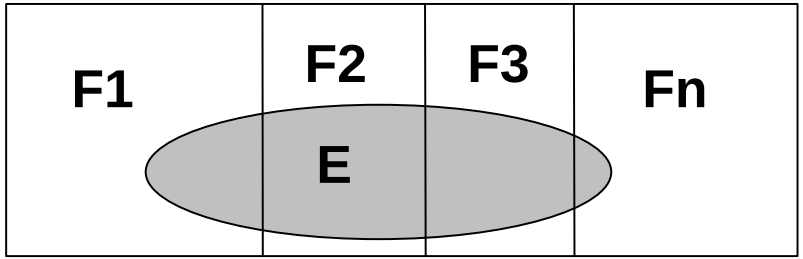


- Para eventos $F_i$ ($1 \leq i \leq n$) **mutuamente exclusivos** e **coletivamente exaustivos**, tem-se o **teorema da probabilidade total:**

$$P(E) = \sum_{i=0}^{n} P(E \cap F_i) = \sum_{i=0}^{n} P(E|F_i)P(F_i)$$

# 3.5 Teorema da Probabilidade Total

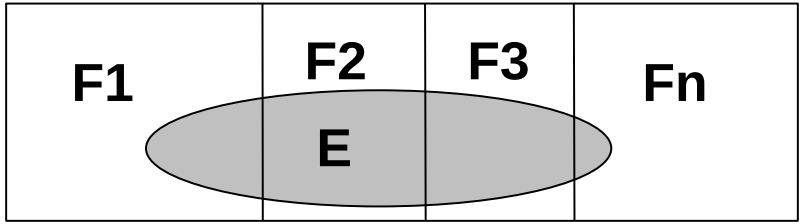


- **Mas,** se desejamos calcular a **probabilidade condicional** de que **apenas** um desses eventos $F_i$ ($1 \leq i \leq n$) ocorra, dado que **E** ocorra?
- Aplicando a definição de **probabilidade condicional** seguida do **teorema da probabilidade total**, temos então a **Lei de Bayes:**

$$P(F_j|E) = \frac{P(F_j \cap E)}{P(E)} = \frac{P(E|F_j)P(F_j)}{\sum_{i=1}^{n} P(E|F_i)P(F_i)}$$

- **Exemplo 6: Exemplo 1.15 (Trivedi, p. 39)**

Medições no centro de computação **NSCS** indicaram que a fonte originadora de jobs (trabalhos) é **15%** da **universidade Duke**, **35%** da universidade **UNC**, e **50%** da universidade **NC**. Suponha que as probabilidades de um job iniciado nessas universidades ser **multitask** sejam **0,01; 0,05;** e **0,02**, respectivamente.

1. Calcule a **probabilidade** de que um job escolhido aleatoriamente no NSCS seja **multitask.**
2. Também, calcule a **probabilidade** de que um job escolhido aleatoriamente venha da universidade **UNC**, dado que o mesmo é **multitask.**

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

- Defina os eventos $\mathbf{B_i}$ = "job é da universidade **i**" (**i = 1, 2, 3** para Duke, UNC, e NC, respectivamente), e **A** = "job é multitask".
- Então pelo **teorema da probabilidade total**, temos:

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + P(A|B_3)P(B_3)$$

$$= (0{,}01)(0{,}15) + (0{,}05)(0{,}35) + (0{,}02)(0{,}5)$$

$$= \mathbf{0{,}029}$$

- E pela **Lei de Bayes**, temos:

$$P(B_2|A) = \frac{P(A|B_2)P(B_2)}{P(A)} = \frac{(0{,}05)(0{,}35)}{0{,}029} = \mathbf{0{,}603}$$

# 4. Variáveis Aleatórias (V.A.)

# 4. Variáveis Aleatórias

- Uma **variável aleatória (v.a.)** **X** em um **espaço amostral** **S** é uma função **X: S** $\rightarrow \mathbb{R}$ que atribui um **número real** **X(s)** aos pontos amostrais **s** $\in$ **S.**

- Portanto, uma **variável aleatória** é uma **regra** que atribui **valores numéricos** aos **resultados possíveis** de um **experimento.**

# 4. Variáveis Aleatórias

- O termo **variável aleatória** é, na verdade, uma denominação **imprecisa** (imprópria), uma vez que uma **variável aleatória X** é de fato uma **função** cujo **domínio** é o **espaço amostral S** e cujo **contradomínio** é o conjunto de todos os **números reais**, $\mathbb{R}$.

- O conjunto de **todos os valores** assumidos por **X**, denominado **imagem** de **X**, será então um **subconjunto** do conjunto de **todos os números reais**, $\mathbb{R}$.

- Há **2** tipos de **variáveis aleatórias**: **discretas** e **contínuas.**

1. **Variável aleatória discreta** - assume valores de um conjunto de **números discretos** e, portanto, sua **imagem** é finita ou contável. É definida em valores específicos. Pode-se calcular a probabilidade de um **s** específico pertencente a **S.**

2. **Variável aleatória contínua** - assume um número **infinito** de valores possíveis. Não é definida em valores específicos. Em vez disso, é definida em um **intervalo de valores** de **s** pertencentes a **S.** Assim, a **probabilidade** de observar qualquer valor específico **s** pertencente a **S** é igual a **0.**

**Exemplo de variável aleatória discreta.** Seja o experimento de **lançar uma moeda**. A moeda pode cair e ficar em pé, mas este evento é tão improvável que pode ser desconsiderado. **Assim, a moeda cai com um dos dois lados para cima: cara (C) ou coroa (O).** Estes são os dois resultados possíveis do experimento. **X** é definida como o **número de coroas** então observadas.

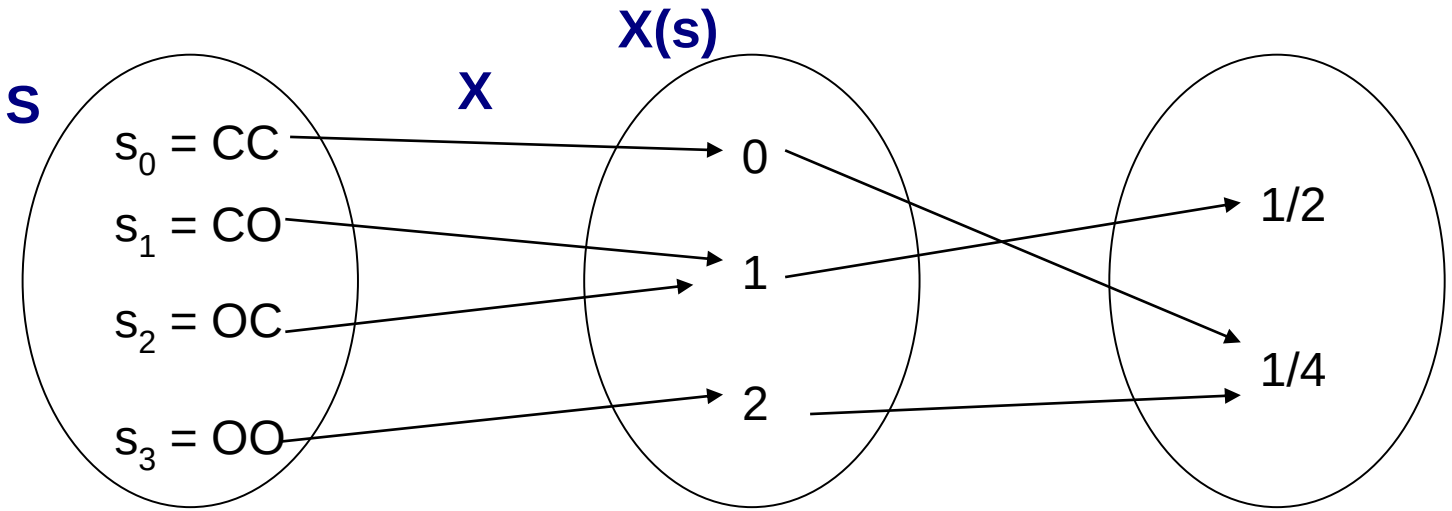


Espaço amostral **S**
Domínio de **X**

Imagem de **X**

Probabilidade de **X(s)**

## Exemplo de variável aleatória contínua.

1. O cenário do experimento considera uma estação de metrô (subterrânea) onde **os trens** passam (idealmente) com **intervalos iguais**. Uma **pessoa entra na estação** e observamos quando chega o próximo trem.

2. Se **T** é o **intervalo de tempo** entre dois trens consecutivos, temos então para nosso experimento: o **espaço amostral S** é o intervalo **[0, T],** ou seja, **todos os valores dentro deste intervalo são resultados possíveis**. Observe que o **espaço amostral** é **incontável** ou **não numerável**.

3. Dado que uma **pessoa entra na estação**, a **variável aleatória X** calcula o **tempo** que decorre **até a chegada do próximo trem**.

4. A **probabilidade** de **X** é calculada da seguinte forma: **P (X ≤ x),** onde **X** atribui um número real a cada ponto amostral **s** pertencente a **S**, de modo que para cada número real **x**, o **conjunto de pontos amostrais {s | X(s) ≤ x}** é um **evento** ao qual pode ser atribuído uma probabilidade.

# 5. Variáveis Aleatórias Discretas

# 5.1 Conceitos Importantes

**Dois** conceitos importantes relacionados às **variáveis aleatórias discretas** são:

1. **Função de probabilidade de massa** ou função de densidade discreta (do inglês, probability mass function - pmf)

2. **Função de distribuição cumulativa** (do inglês, cumulative distribution function - CDF).

# 5.1.1 Função de Probabilidade de Massa

- Seja $\mathbf{A_x}$ o conjunto de todos os pontos amostrais **{s | X(s) = x}.**

- A **pmf da variável aleatória X** é denotada por: $\mathbf{p_X(x) = P\ (X = x) = P(A_x)}$.

- A **pmf de X** é então a **probabilidade** de que o valor da **variável aleatória X**, obtido em uma execução do experimento, **seja igual a x.**

- As seguintes **duas propriedades** são então válidas para a **pmf** $\mathbf{p_X(x)}$
    1. $\mathbf{0 \leq p_X(x) \leq 1}$ para **todo** $\mathbf{x \in \mathbb{R}}$.
    2. **Considere** o conjunto $\mathbf{\{x \mid p_X(x) \neq 0\} = \{ x_1, x_2, x_3, ...\}}$. É um subconjunto finito ou contável de infinito de números reais e definido como a imagem de **X**. Assim: $\mathbf{\sum p_X(x_i) = 1}$

# 5.1.2 Função de Distribuição Cumulativa

- Em vez de calcular **$P(X = x)$,** podemos estar interessados em calcular a **probabilidade do conjunto $\{s \mid X(s) \in A\}$** para algum **subconjunto A de $\mathbb{R}$** diferente de um **conjunto de um único ponto.**

- Daí, a função **$F_X(a)$, $-\infty < a < \infty$**, definida por **$F_X(a) = P(X \leq a) = \sum p_X(x_i)$, $x_i \leq a$,** é chamada de função de **distribuição cumulativa** (CDF) ou função de **distribuição de probabilidade** ou, simplesmente, função de **distribuição** da variável aleatória **X.**

# 5.1.2 Função de Distribuição Cumulativa

- As seguintes três **propriedades** são válidas para a **CDF** $F_X(x)$:

1. $0 \leq F_X(x) \leq 1$ para $-\infty < x < \infty$

2. $F_X(x)$ é monótona crescente, ou seja, se $x_1 \leq x_2$, então $F(x_1) \leq F(x_2)$

3. $F_X(x_{i+1}) = F_X(x_i) + p_X(x_{i+1})$

Obs: **F** é função monótona quando preserva a relação de ordem entre $x_1$ e $x_2$

https://pt.wikipedia.org/wiki/Fun%C3%A7%C3%A3o_mon%C3%B3tona

# 5.2 Importantes V.A Discretas

Bernoulli

Binomial

Geométrica

Poisson

# 5.2.1 Bernoulli

Refere-se a **um experimento** que pode ter **dois resultados possíveis**: **sucesso** com probabilidade **p**, e **fracasso** com probabilidade **q = 1 - p**. Para o **sucesso, seja x = 1;** e para o **fracasso, seja x = 0**.

$$\textbf{pmf:}\ \ p_X(x) = \begin{cases} p, & \text{para } x = 1, \\ 1 - p = q, & \text{para } x = 0, \\ 0, & \text{caso contrário.} \end{cases}$$

$$\textbf{CDF:}\ \ F_X(x) = \begin{cases} 0, & \text{para } x < 0, \\ q, & \text{para } 0 \le x < 1, \\ 1, & \text{para } x \ge 1. \end{cases}$$

# 5.2.2 Binomial

Refere-se ao número de **k sucessos** em **uma sequência** de **n experimentos independentes**. A **probabilidade de sucesso** em cada experimento é **p**, e de **fracasso** é **q = 1 - p.** Cada experimento é um experimento de **Bernoulli**, ou seja, temos então uma sequência de **n** experimentos independentes de **Bernoulli** com **k sucessos.** Seja **x = k**.

**pmf:** $$p_X(k) = \begin{cases} \binom{n}{k} p^k (1-p)^{n-k} \text{ for } 0 \le k \le n \\ 0\,, \qquad \text{caso contrário} \end{cases}$$

**CDF:** $$F_X(k) = \sum_{i=0}^{k} \binom{n}{i} p^i (1-p)^{n-i} \text{ for } 0 \le k \le n$$

# 5.2.2 Binomial

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$$

- É denotado como o **coeficiente binomial**.

- **A ideia geral** é: observaremos **k sucessos** e **(n - k) fracassos (falhas)**. No entanto, os **k sucessos** podem ocorrer em **qualquer lugar** (posição) ao longo das **n tentativas** (experimentos de Bernoulli). Este coeficiente trata então do **número de maneiras diferentes** de distribuir (obter) os **k sucessos** em uma sequência de **n tentativas**.

https://pt.wikipedia.org/wiki/Combina%C3%A7%C3%A3o

# 5.2.3 Geométrica

Refere-se a uma **sequência** de **n** **experimentos independentes** até alcançar (incluindo) o **primeiro sucesso**. A **probabilidade de sucesso** é **p**, e a probabilidade **de fracasso (falha)** é **q = 1 - p** em cada experimento. Cada experimento é de fato um **experimento de Bernoulli**, ou seja, temos então uma sequência de **n** **experimentos independentes de Bernoulli** até alcançar (incluindo) o primeiro sucesso. Seja **x = n**.

**pmf:** $p_X(n) = p(1-p)^{n-1}$, **para** $n = 1, 2, \ldots$

**CDF:** $F_X(n) = 1-(1-p)^n$, **para** $n \geq 0$

# 5.2.4 Poisson

Refere-se ao **número de eventos k** que ocorrem no **intervalo de tempo [0, t].** É uma **boa aproximação** para vários **fenômenos aleatórios** em **análise de desempenho**. Por exemplo, os dois fenômenos a seguir: **número de mensagens transmitidas** por meio de um canal de comunicação, e **número de trabalhos (jobs)** que chegam a um sistema. Seja **x = k.**

**pmf:**

$$p_X(k) = \frac{e^{-\lambda t}(\lambda t)^k}{k!} = \frac{e^{-\alpha}(\alpha)^k}{k!}, k = 0,1,2,\cdots$$

**CDF:**

$$F_X(k) = \sum_{i=0}^{k} \frac{e^{-\lambda t}(\lambda t)^i}{i!} = \sum_{i=0}^{k} \frac{e^{-\alpha}(\alpha)^i}{i!}, k = 0,1,2,\cdots$$

$$\text{where}: \lambda \text{ is the success rate } (\textit{arrival rate})$$

# 5.3 Notação

- **X ~ Bernoulli (p):** **X** é uma variável aleatória e tem uma distribuição de Bernoulli com parâmetro **p**.

- **X ~ Binomial (n, p):** **X** é uma variável aleatória e tem uma distribuição Binomial com parâmetros **n** e **p.**

- **X ~ Geométrica (p):** **X** é uma variável aleatória e tem uma distribuição geométrica com parâmetro **p.**

- **X ~ Poisson (α):** **X** é uma variável aleatória e tem uma distribuição de Poisson com parâmetro **$\alpha = \lambda t$.**

# 5.4 Equivalências

**Se** $X_i$ **~ Bernoulli (p)** e **Y = Σ** $X_i$**, i = 1, 2, …, n,**
**então Y ~ Binomial (n, p).**

**Se n ≥ 20** and **p ≤ 0.05**,

**então X ~ Binomial (n, p)** $\equiv$ **X ~ Poisson (n.p)**,
onde: **n.p = α = λt.**

- **Exemplo 7: Exercício 1 de Taboga.**

Suponha que você jogue uma moeda **4 vezes** independentemente e o resultado de cada lance pode ser cara (com probabilidade **1/2**) ou coroa (também com probabilidade **1/2**). **Qual é a probabilidade** de obter exatamente **2 coroas**?

Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/binomial-distribution.

https://www.statlect.com/probability-distributions/binomial-distribution

- **Exemplo 7: Exercício 1 de Taboga.**

Denote por **X** o número de vezes que o resultado é **coroa** (em 4 lançamentos). **X** tem uma distribuição binomial com parâmetros **n = 4** e **p = 1/2.** A probabilidade de obter **exatamente k = 2 coroas** pode ser calculada a partir da função de probabilidade de **X** da seguinte forma:

$$p_X(k) = \binom{n}{k} p^k (1-p)^{n-k} =$$

$$\begin{aligned} p_X(2) &= \binom{n}{2} p^2 (1-p)^{n-2} \\ &= \binom{4}{2}\left(\frac{1}{2}\right)^2\left(1-\frac{1}{2}\right)^{4-2} \\ &= \frac{4!}{2!2!}\frac{1}{4}\frac{1}{4} \\ &= \frac{4\cdot 3\cdot 2\cdot 1}{2\cdot 1\cdot 2\cdot 1}\frac{1}{16} \\ &= \frac{6}{16} = \frac{3}{8} \end{aligned}$$

- **Exemplo 8: Exercício 2 de Taboga.**

Suponha que você lance um dardo de forma independente **10 vezes**. Cada vez que você lança um dardo, a probabilidade de acertar o alvo é **3/4.** Qual é a **probabilidade de acertar o alvo menos de 5 vezes** em um total de **10 vezes** que você lança um dardo?

Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/binomial-distribution.

https://www.statlect.com/probability-distributions/binomial-distribution

- **Exemplo 8: Exercício 2 de Taboga.**

Denote por **X** o número de vezes que você atingiu o alvo. **X** tem uma **distribuição binomial** com parâmetros **n = 10 e p = 3/4**. A probabilidade de acertar o alvo menos de **k** = **5 vezes** pode ser calculada a partir da **função de distribuição** de **X** da seguinte forma:

$$= F_X(k) = \sum_{s=0}^{k} \binom{n}{s} p^s (1-p)^{n-s}$$

$$\begin{aligned} P(X < 5) &= P(X \leq 4) \\ &= F_X(4) \\ &= \sum_{s=0}^{4} \binom{n}{s} p^s (1-p)^{n-s} \\ &= \sum_{s=0}^{4} \binom{10}{s} \left(\frac{3}{4}\right)^s \left(\frac{1}{4}\right)^{10-s} \simeq 0.0197 \end{aligned}$$

- **Exemplo 9: baseado em Exemplo 2.6 (Trivedi, p. 73)**

O canal de comunicação utilizado para transmissão de **bits** entre os centros de computação das cidades de Santo André (SA) e São Bernardo (SB), respectivamente, tem probabilidade de erro igual a 0,1, associada a cada bit enviado.

1. Qual **distribuição de probabilidade** pode ser utilizada para **modelar** o cenário de uma transmissão de bits com e/ou sem erros?
2. Calcule a **probabilidade** de que, no envio de 10 bits, **90%** desses bits sejam transmitidos corretamente.
3. Calcule a **probabilidade** de que na transmissão de 10 bits, **0%** sejam corrompidos, ou seja, que não haja qualquer erro na transmissão**.**

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

1. Qual **distribuição de probabilidade** pode ser utilizada para modelar o cenário de uma transmissão de bits com e/ou sem erros?

A distribuição de probabilidade **binomial** pode ser utilizada. Cada bit transmitido é visto como um experimento independente de **Bernoulli,** com **p** = 0,9 e **q** = 0,1.

2. Calcule a **probabilidade** de que, no envio de 10 bits, **90%** desses bits sejam transmitidos corretamente.

Para **k** = 9 e **n** = 10**,** tem-se o que se segue.

$$p_X(k) = \binom{n}{k} p^k\,(1-p)^{n-k} = \binom{10}{9} 0{,}9^9\,(1-0{,}9)^{10-9}$$

$$= \frac{10!}{9!\,(10-9)!}\,0{,}9^9(1-0{,}9)^{10-9} = \frac{3628800}{362880}\,.\,0{,}387.\,0{,}1 = 10\,.\,0{,}0387 = \mathbf{0{,}387}$$

3. Calcule a **probabilidade** de que na transmissão de 10 bits, **0%** sejam corrompidos, ou seja, que não haja qualquer erro na transmissão**.**

Para **k** = 10 e **n** = 10**,** tem-se o que se segue.

$$p_X(k) = \binom{n}{k} p^k \, (1-p)^{n-k} \;\; = \binom{10}{10} 0{,}9^{10} \, (1-0{,}9)^{10-10}$$

$$= \frac{10!}{10!\,(10-10)!} 0{,}9^{10} (1-0{,}9)^{10-10} = \frac{3628800}{3628800} \,.\, 0{,}349 .\, 1{,}0 = \mathbf{0{,}349}$$

- **Exemplo 10: Problema 9 (Trivedi, p. 92)**

Assuma que o **número de mensagens** entrantes em um canal de comunicação em um intervalo de tempo de *t* segundos tem distribuição de probabilidade de **Poisson** com parâmetro 0,3*t*. Calcule então as probabilidades dos seguintes eventos:

1. Exatamente **três mensagens** chegam em um intervalo de 10 s.
2. No máximo **20 mensagens** chegam em um intervalo de 20 s.
3. O número de mensagens que chegam em **um intervalo de 5 s** está entre **três** e **sete** mensagens.

**TRIVEDI**, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

1. Exatamente três mensagens chegam em um intervalo de 10 s.

$$p_X(k) = \frac{e^{-\lambda t}(\lambda t)^k}{k!} = \frac{e^{-\alpha}(\alpha)^k}{k!}, k = 0,1,2,\cdots$$

$$p_X(3) = \frac{e^{-0,3t}(0,3t)^3}{3!} = \frac{e^{-3}(3)^3}{3!} = \mathbf{0,224}$$

2. No máximo 20 mensagens chegam em um intervalo de 20 s.

$$F_X(k) = P(X \leq k) = \frac{\sum_{i=0}^{k} e^{-\lambda t}(\lambda t)^i}{i!}, k = 0, 1, 2, \cdots$$

$$F_X(20) = \frac{\sum_{i=0}^{20} e^{-6}(6)^i}{i!} = \mathbf{0,973}$$

3. O número de mensagens que chegam em um intervalo de 5 segundos está entre três e sete mensagens.

$$F_X(k) = P(X \leq k) = \frac{\sum_{i=0}^{k} e^{-\lambda t}(\lambda t)^i}{i!}, k = 0, 1, 2, \cdots$$

$$P(3 \leq X \leq 7) = \frac{\sum_{i=3}^{7} e^{-1,5}(1,5)^i}{i!} = \mathbf{0,1909836}$$

- **Exemplo 11:**
- Apresente um **modelo analítico** para avaliar a probabilidade de descarte de pacotes de dados que chegam até um roteador por meio de um enlace de comunicação. **Elabore gráficos** para efeito de análise.
- O roteador possui uma capacidade de processamento de pacotes determinística com taxa de **β pacotes/s**. O tamanho do buffer do roteador, em número de pacotes, é **L.** A taxa de chegada de pacotes no roteador segue uma distribuição de Poisson de parâmetro $\lambda t$**.**
- O roteador tem um **único** processador: se o pacote de dados chega no roteador e o processador está livre, o pacote é processado; se o pacote de dados chega no roteador e o processador está ocupado, o pacote é colocado no buffer ou, caso o buffer esteja cheio, é então descartado.
- Esta questão **não tem** uma resposta gabarito. Se desejado, pode-se discutí-la **exclusivamente** durante as aulas.

# 5.4 Exemplos de outras V.A. Discretas

Geométrica Modificada

Binomial Negativa

Hipergeométrica

Uniforme Discreta

Indicadora

1. **Geométrica modificada**: Refere-se ao número de experimentos até **antes** do **primeiro** sucesso.
2. **Binomial negativa**: Refere-se ao número de experimentos até **alcançar o k-ésimo sucesso.**
3. **Hipergeométrica:** como na **Binomial**, refere-se a uma **sequência de experimentos**, mas a **probabilidade de sucesso** em cada experimento (tentativa) seguinte **varia** dependendo do resultado do experimento (tentativa) anterior (sucesso ou fracasso).
4. **Uniforme discreta:** cada elemento da imagem tem a **mesma probabilidade.**
5. **Indicadora:** O **espaço amostral S** é dividido em dois subconjuntos mutuamente exclusivos e coletivamente exaustivos.

**Estudo extraclasse**: TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

# 6. Síntese Final

- Este módulo apresentou **brevemente** o tema **Variáveis Aleatórias Discretas**

- O tema foi desenvolvido sob o enfoque geral de **Avaliação de Desempenho de Redes.**

- Os slides desta aula estão disponíveis em:
- https://sites.google.com/site/carlokleber/disciplinas-ministradas/avalia-de-desempenho-de-redes

- A **lista de exercícios**, disponível no site acima, propicia a oportunidade de praticar, complementar e fixar o conteúdo ministrado.

# Prática e Estudo Individual

**Acesse o MOODLE tempestivamente, acesse a aba atividades e realize a atividade prevista.**

# Referências


- JAIN, R. The art of computer systems performance analysis: technique for experimental design, measurement, simulation, and Modeling. New York: John Wiley & Sons, 1991. 685p.
- TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.
- Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/
- Leão, R. M. M (2015). “Estatística e Modelos Probabilísticos”, Notas de aula. Online http://www.land.ufrj.br/~classes/est-prob-2015/

# Fim

Prof. Carlo Kleber da Silva Rodrigues
carlo.kleber@ufabc.edu.br