Avaliação de Desempenho de Redes

MCZA004-13

Variáveis Aleatórias Contínuas

Prof. Carlo Kleber

Sumário

1. Introdução
2. Definição de Variáveis Aleatórias
3. Tipos de Variáveis Aleatórias
4. Variáveis Aleatórias Contínuas
5. Teoremas Limites
6. Parâmetros Estatísticos
7. Desigualdades
8. Síntese final

Parte Prática

Referências

1. Introdução

- Neste módulo temos estes **três** objetivos **principais:**

1. Apresentar **algumas** das mais importantes **variáveis aleatórias contínuas.**
2. Explicar importantes **conceitos estatísticos relacionados a variáveis aleatórias.**
3. Ressaltar a **importância** do emprego de **variáveis aleatórias** na avaliação de desempenho.

2. Definição de Variáveis Aleatórias (V.A.)

2. Definição de V.A.

- Uma **variável aleatória (v.a.)** **X** em um **espaço amostral** **S** é uma função **X: S** $\rightarrow \mathbb{R}$ que atribui um **número real** **X(s)** aos pontos amostrais **s** $\in$ **S.**

- Portanto, uma **variável aleatória** é uma **regra** que atribui **valores numéricos** aos **resultados possíveis** de um **experimento.**

2. Definição de V.A.

- O termo **variável aleatória** é, na verdade, uma denominação imprecisa (imprópria), uma vez que uma **variável aleatória X** é de fato uma **função** cujo **domínio** é o **espaço amostral S** e cujo **contradomínio** é o conjunto de todos os **números reais**, $\mathbb{R}$.

- O conjunto de **todos os valores** assumidos por **X**, denominado **imagem** de **X**, será então um **subconjunto** do conjunto de **todos os números reais**, $\mathbb{R}$.

3. Tipos de Variáveis Aleatórias (V.A.)

- Há **2** tipos de **variáveis aleatórias**: **discretas** e **contínuas.**

1. **Variável aleatória discreta** - assume valores de um conjunto de **números discretos** e, portanto, sua **imagem** é finita ou contável. É definida em valores específicos. Pode-se calcular a probabilidade de um **s** específico pertencente a **S.**

2. **Variável aleatória contínua** - assume um número **infinito** de valores possíveis. Não é definida em valores específicos. Em vez disso, é definida em um **intervalo de valores** de **s** pertencentes a **S.** Assim, a **probabilidade** de observar qualquer valor específico **s** pertencente a **S** é igual a **0.**

Exemplo de variável aleatória discreta. Seja o experimento de **lançar uma moeda**. A moeda pode cair e ficar em pé, mas este evento é tão improvável que pode ser desconsiderado. **Assim, a moeda cai com um dos dois lados para cima: cara (C) ou coroa (O).** Estes são os dois resultados possíveis do experimento. **X** é definida como o **número de coroas** então observadas.

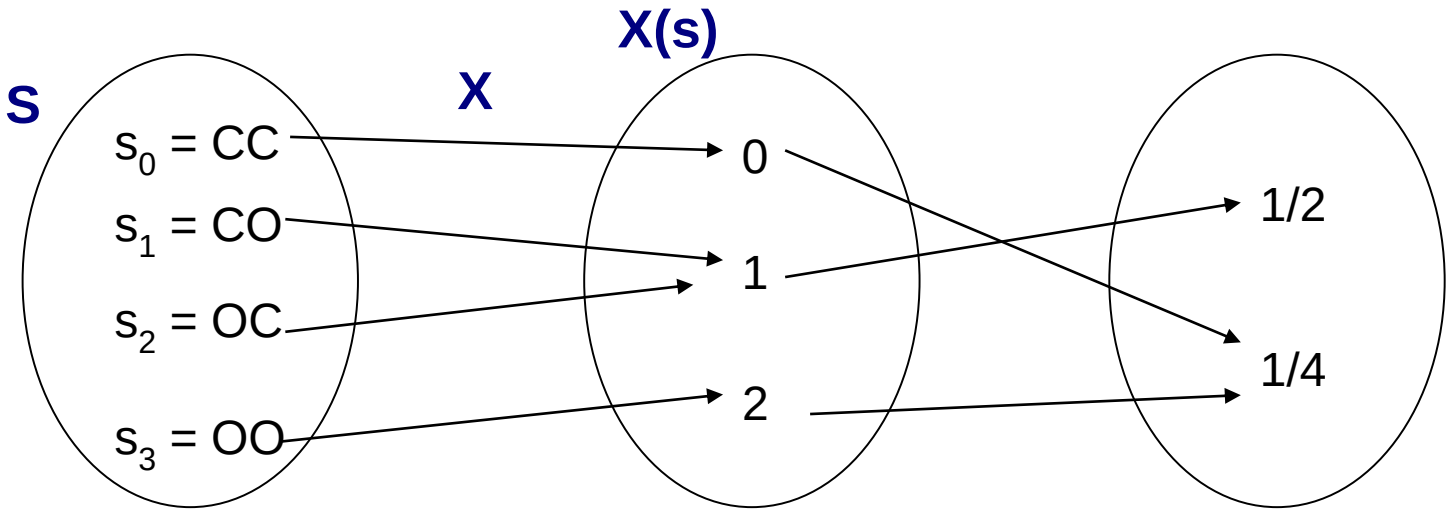

Espaço amostral **S**
Domínio de **X**

Imagem de **X**

Probabilidade de **X(s)**

Exemplo de variável aleatória contínua.

1. O cenário do experimento considera uma estação de metrô (subterrânea) onde **os trens** passam (idealmente) com **intervalos iguais**. Uma **pessoa entra na estação** e observamos quando chega o próximo trem.

2. Se **T** é o **intervalo de tempo** entre dois trens consecutivos, temos então para nosso experimento: o **espaço amostral S** é o intervalo **[0, T],** ou seja, **todos os valores dentro deste intervalo são resultados possíveis**. Observe que o **espaço amostral** é **incontável** ou **não enumerável**.

3. Dado que uma **pessoa entra na estação**, a **variável aleatória X** calcula o **tempo** que decorre **até a chegada do próximo trem**.

4. A **probabilidade** de **X** é calculada da seguinte forma: **P (X ≤ x),** onde **X** atribui um número real a cada ponto amostral **s** pertencente a **S**, de modo que para cada número real **x**, o **conjunto de pontos amostrais {s | X(s) ≤ x}** é um **evento** ao qual pode ser atribuído uma probabilidade.

4. Variáveis Aleatórias Contínuas

4.1 Dois Conceitos Importantes

1. **Função de distribuição cumulativa** (Cumulative Distribution Fu*nction* - **CDF**) de uma **variável aleatória contínua X**, denotada por F_X, é definida pela função:

$$F_X(x) = P(X \leq x), -\infty < x < \infty$$

2. Para uma **variável aleatória contínua X**, a função $f_X(x) = dF_X(x)/dx$ é chamada **função de densidade de probabilidade** (**pdf** ou função de densidade) de **X**. A **CDF** pode então ser obtida integrando a **pdf.**

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)dt\,, -\infty < x < \infty$$

Observação - Por simplicidade, tem-se $F_X(x) \equiv F(x)$ e $f_X(x) \equiv f(x)$.

- As seguintes **propriedades** se aplicam:

P1: $\boldsymbol{f(x) \geq 0}$ para todo x

P2: $\boldsymbol{\int_{-\infty}^{\infty} f(x)dx = 1}$

P3: $\boldsymbol{0 \leq F(x) \leq 1, -\infty < x < \infty}$

P4: $\boldsymbol{F_X(x)}$ é uma função monótona crescente.
Ou seja: se $\boldsymbol{x_1 \leq x_2}$, então $\boldsymbol{F(x_1) \leq F(x_2)}$

P5: $\boldsymbol{P(X = c) = P(c \leq X \leq c) = \int_{c}^{c} f_X(y)dy = 0}$

- Ao contrário da **CDF** de uma **variável aleatória discreta** que **cresce** apenas **por saltos**, a **CDF** de uma **variável aleatória contínua** cresce **continuamente**, ou seja, não tem saltos.

- Portanto, a **probabilidade associada** a um **valor discreto** é **zero**. A probabilidade associada a **variáveis aleatórias contínuas** é definida em **um intervalo de valores.**

- Abaixo vê-se a relação entre a **CDF** e a **pdf. Probabilidades** são representadas pelas áreas **sob a curva pdf.** A área total sob a curva pdf é **unitária.**

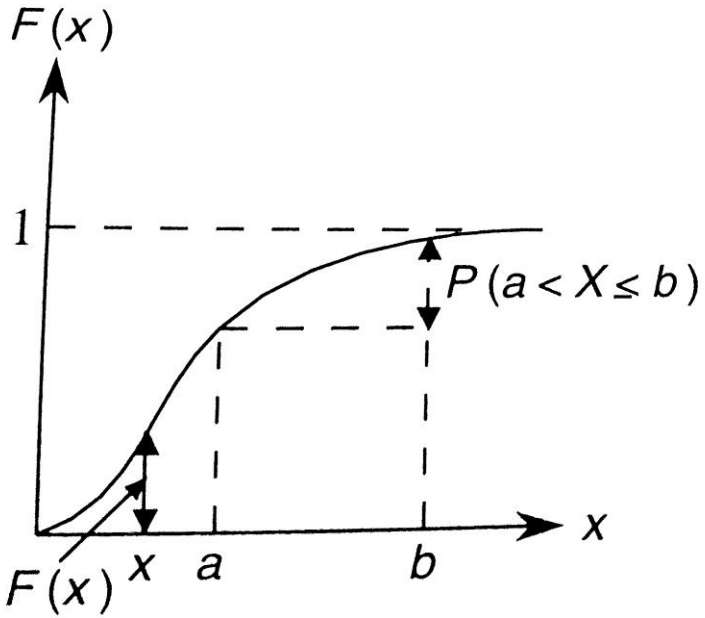

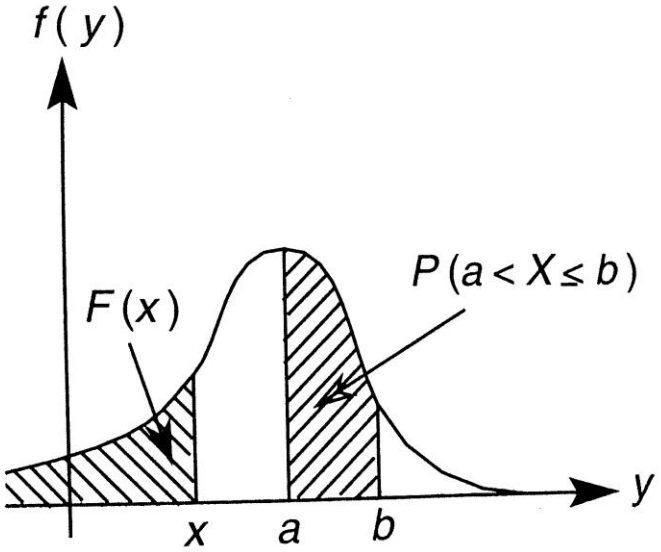

4.2 Importantes V.A Contínuas

Uniforme

Exponencial

Hipoexponencial

Erlang

Hiperexponencial

Normal

4.2.1 Uniforme

Diz-se que uma **variável aleatória X** tem uma **distribuição uniforme** ou **retangular** ao longo do intervalo **(a, b)** se sua **função de densidade f(x)** é:

$$f(x) = \begin{cases} 1/(b-a), & a < x < b \\ 0, & \text{caso contrário.} \end{cases}$$

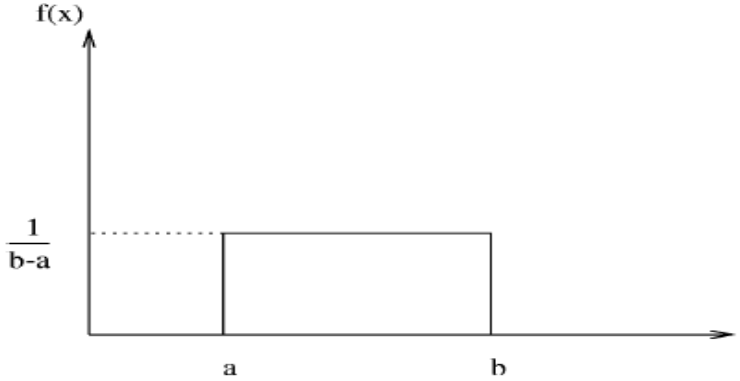

E a **função de distribuição F(x)** é:

$$F(x) = \begin{cases} 0, & x < a \\ (x-a)/(b-a), & a \le x < b \\ 1, & x \ge b \end{cases}$$

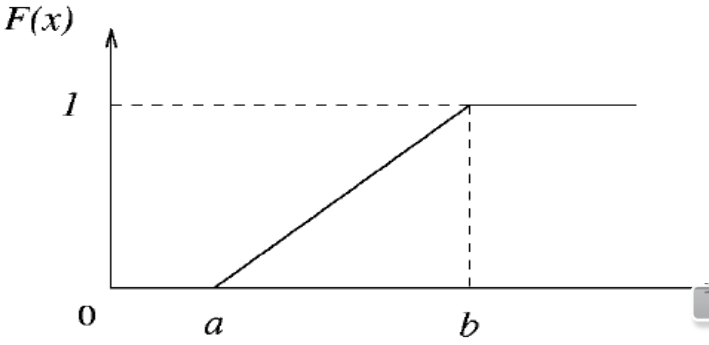

- **Exemplo 1: Exercício 1 (Taboga, 2017)**

- Seja **X** uma **variável aleatória uniforme** contínua ao longo do **intervalo [5, 10].**

1. Calcule a probabilidade: $P(7 \leq X \leq 9)$

Taboga, Marco (2017). "Uniform distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/uniform-distribution.

- **Exemplo 1: Exercício 1 (Taboga, 2017)**

- Seja **X** uma **variável aleatória uniforme contínua** ao longo do **intervalo [5, 10].**

1. Calcule a probabilidade: $P(7 \leq X \leq 9)$

Usando a função de **densidade de probabilidade**:

$$P(7 \leq X \leq 9) = \int_7^9 fX(x)dx$$

$$= \int_7^9 \frac{1}{10-5} dx$$

$$= \frac{1}{5}[x]_7^9 = \frac{1}{5}(9-7) = \frac{2}{5}$$

- **Exemplo 1: Exercício 1 (Taboga, 2017)**

- Seja **X** uma **variável aleatória uniforme contínua** ao longo do **intervalo [5, 10].**

1. Calcule a probabilidade: $\mathrm{P}(7 \leq X \leq 9)$

Usando a função de **distribuição**:

$$\begin{aligned}\mathrm{P}(7 \leq X \leq 9) &= F_X(9) - F_X(7) \\ &= \frac{9-5}{10-5} - \frac{7-5}{10-5} \\ &= \frac{4}{5} - \frac{2}{5} = \frac{2}{5}\end{aligned}$$

4.2.2 Exponencial

Diz-se que uma **variável aleatória X** tem uma **distribuição exponencial** se sua **função de densidade f(x)** é:

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & , \text{ se } x > 0 \\ 0, \text{ caso contrário.} & \end{cases}$$

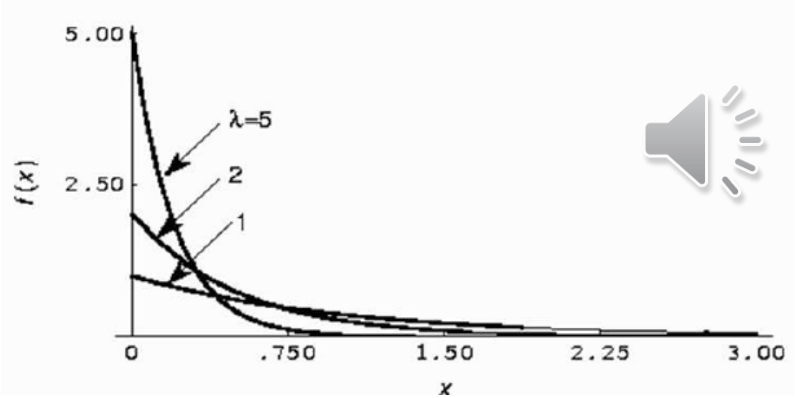

E a **função de distribuição F(x)** é:

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, \text{ se } 0 \leq x < \infty \\ 0, \text{ caso contrário} \end{cases}$$

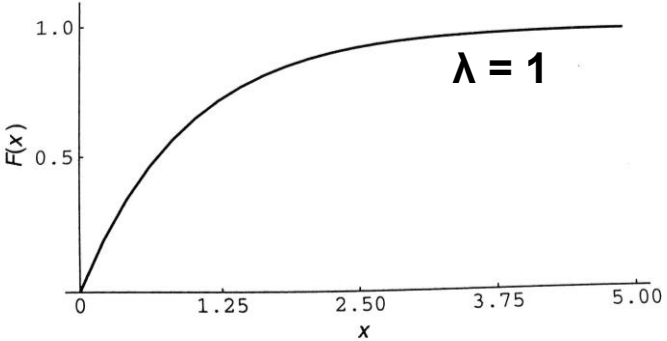

4.2.2 Exponencial

- A **distribuição exponencial** é também denotada como **distribuição exponencial negativa.**

- É uma boa **aproximação** para os seguintes fenômenos:

➢ tempo entre **duas chegadas sucessivas** de jobs em um servidor (tempo entre chegadas);
➢ tempo de **serviço** em um servidor;
➢ tempo **até a falha** (vida útil) ou **de reparo** de um componente;
➢ tempo **de transmissão** de uma mensagem; **etc.**

4.2.2 Exponencial

- O **parâmetro λ** da **distribuição exponencial** representa o **inverso do tempo médio** para a ocorrência de um evento ou, equivalentemente, **a taxa de chegada de eventos**.

- A distribuição **exponencial** tem a propriedade de ser **sem memória** (**Markov**). A distribuição **geométrica** discreta possui esta mesma propriedade.

- A distribuição **exponencial** tem uma relação direta com a distribuição discreta de **Poisson**: se o **processo de chegada** de jobs tem uma distribuição de **Poisson**, então o **tempo entre chegadas** dos jobs tem uma distribuição **exponencial** e vice-versa.

4.2.2 Exponencial

- A distribuição **exponencial** tem uma relação direta com a distribuição discreta de **Poisson**: se o **processo de chegada** de jobs tem uma distribuição de **Poisson**, então o **tempo entre chegadas** dos jobs tem uma distribuição **exponencial** e vice-versa.

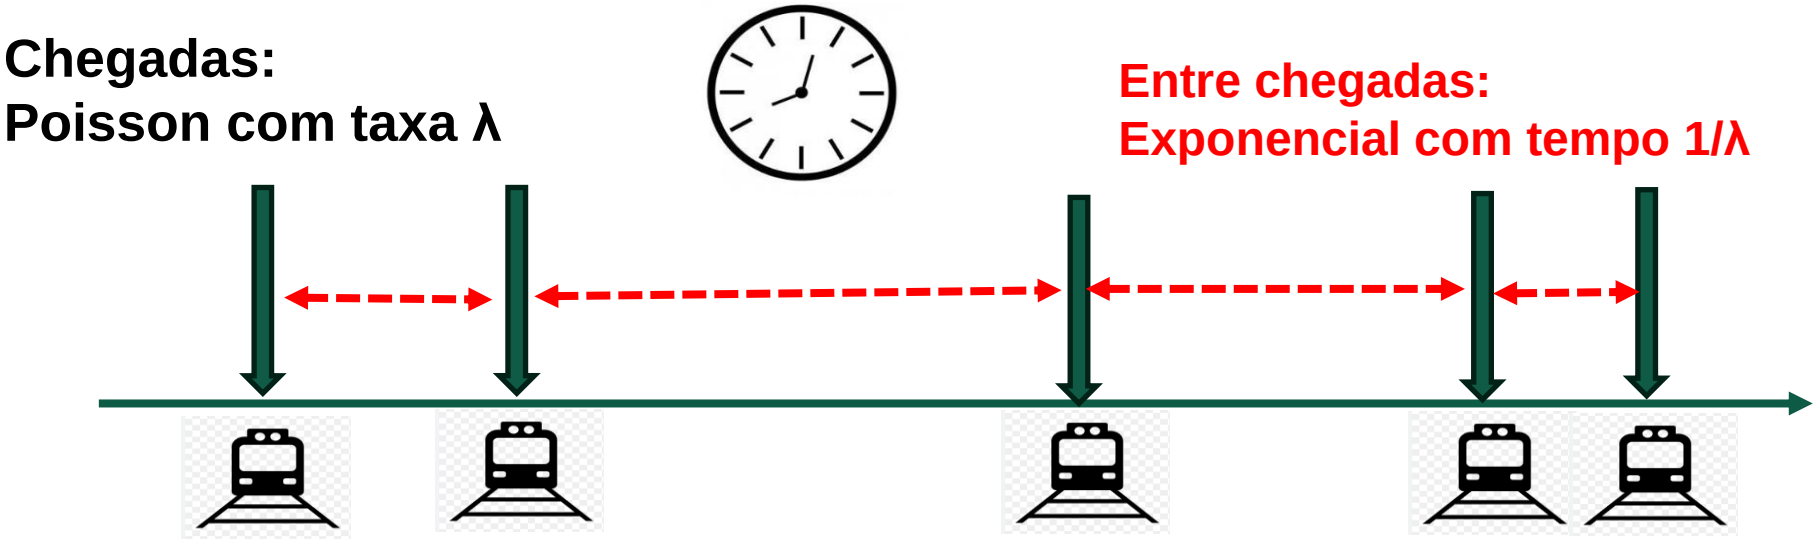

Exemplo 2: Exemplo 3.3 (Trivedi, p. 123)

- Considere um **servidor Web** com uma **taxa de chegadas** de requisições de **λ = 0,1** jobs por segundo. Assumindo que o número de chegadas por unidade de tempo é **Poisson**, o tempo entre chegadas, ***X***, é então **exponencialmente distribuído com parâmetro λ**.

1. Qual a **probabilidade** de que um intervalo de **10 segundos** ocorra **sem chegada de requisições**?

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

Exemplo 2: Exemplo 3.3 (Trivedi, p. 123)

1. Qual a **probabilidade** de que um intervalo de **10 segundos** ocorra **sem chegada de requisições**?

X tem distribuição **exponencial** de parâmetro **λ**

$$F(x) = P(X \leq x) = 1 - e^{-\lambda x}, \text{onde } x = 10$$

$$1 - F(x) = 1 - P(X \leq x) = \boldsymbol{P(X > x)} = e^{-\lambda x} = e^{-0,1.10} = e^{-1} = \mathbf{0,368}$$

Obs: número de Euler *e* =2,718281828459045235360287 4...

4.2.3 Hipoexponencial

- Muitos **processos** na natureza podem ser **divididos em *r* estágios** (ou fases) **sequenciais.**

- Se o **tempo gasto** em **cada estágio** é **independente e exponencialmente** distribuído, então pode ser mostrado que o tempo total do processo é **hipoexeponencialmente distribuído.**

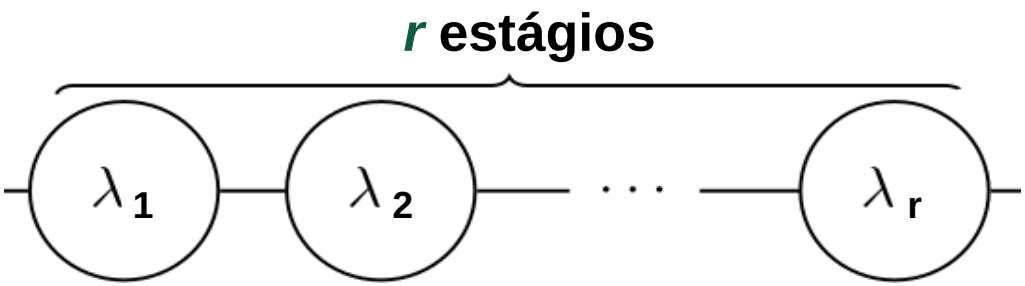

4.2.3 Hipoexponencial

Diz-se que uma **variável aleatória X** tem uma **distribuição Hipoexponencial de 2 estágios** se sua **funcão de densidade f(t)** é:

$$f(t) = \frac{\lambda_1 \lambda_2}{\lambda_2 - \lambda_1}\left(e^{-\lambda_1 t} - e^{-\lambda_2 t}\right), \quad t > 0$$

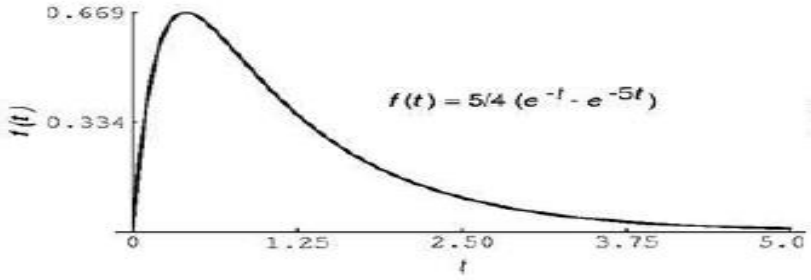

Hypo(1,5) pdf

E a **função de distribuição F(t)** é:

$$F(t) = 1 - \frac{\lambda_2}{\lambda_2 - \lambda_1}\left(e^{-\lambda_1 t}\right) + \frac{\lambda_1}{\lambda_2 - \lambda_1}\left(e^{-\lambda_2 t}\right), \quad t \geq 0$$

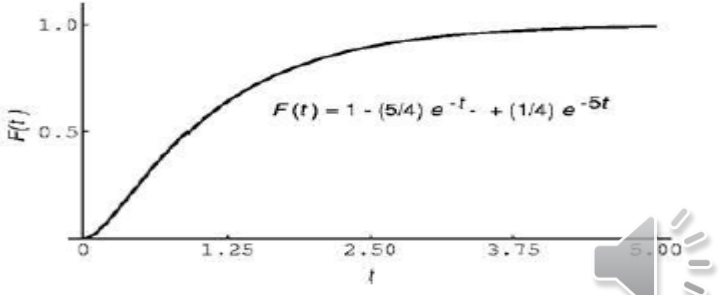

Hypo(1,5) CDF

4.2.4 Erlang

- Muitos processos na natureza podem ser divididos em ***r* estágios** (ou fases) **sequenciais.**
- Quando os ***r* estágios** têm **distribuições exponenciais idênticas**, a distribuição resultante é conhecida como **Erlang de r estágios.**
- É um **caso especial** da **distribuição Hipoexponencial** na qual o parâmetro **λ** é **o mesmo nos *r* estágios.**
- A **distribuição exponencial** é **um caso especial** da distribuição **Erlang com *r* =1.**

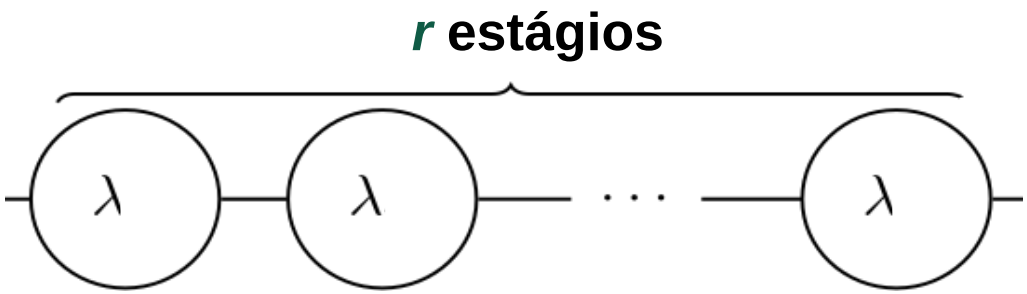

4.2.4 Erlang

Diz-se que uma **variável aleatória X** tem uma **distribuição Erlang de *r* estágios** se sua **função de densidade f(t)** é:

$$f(t) = \frac{\lambda^r t^{r-1} e^{-\lambda t}}{(r-1)!}, \quad t > 0, \lambda > 0, r = 1, 2, \cdots$$

E a **função de distribuição F(t)** é:

$$F(t) = 1 - \sum_{k=0}^{r-1} \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \quad t > 0, \lambda > 0, r = 1, 2, \cdots$$

4.2.5 Hiperexponencial

Se **um processo** consiste de ***k*** **fases (estágios) alternativas** - ou seja, durante qualquer experimento único, o processo passa **por uma e apenas uma** das muitas **fases** alternativas - e essas fases têm **distribuições exponenciais**, então a distribuição geral resultante é **hiperexponencial.**

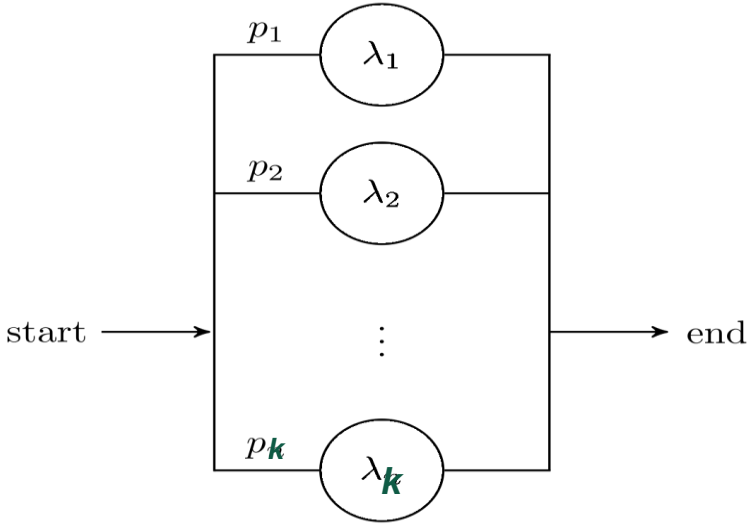

4.2.5 Hiperexponencial

Diz-se que uma **variável aleatória X** tem uma **distribuição hiperexponencial** de ***k* fases** se sua **função de densidade f(t)** é:

$$f(t) = \sum_{i=1}^{k} \alpha_i \lambda_i e^{-\lambda_i t}, \quad t > 0, \lambda_i > 0, \alpha_i > 0, \sum_{i=1}^{k} \alpha_i = 1$$

E a **função de distribuição F(t)** é:

$$F(t) = \sum_{i} \alpha_i (1 - e^{-\lambda_i t}), t \geq 0$$

4.2.6 Normal ou Gauss

- Esta **distribuição** é **extremamente importante** em aplicações estatísticas devido ao **teorema do limite central**, visto mais adiante.

- Diz-se que uma **variável aleatória X** tem uma **distribuição normal** se sua **função de densidade f(x)** é:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right], \qquad -\infty < x < \infty$$

- onde **- ∞ < μ < ∞** e **σ > 0** são dois **parâmetros** da distribuição. Estes dois parâmetros são, respectivamente, a **média** e o **desvio padrão** da distribuição, e são explicados mais à frente. Escreve-se **X ~ N(μ, σ²).**
- **Obs** - **σ**: desvio padrão; **σ²**: variância

f(x), μ =2, σ = 1

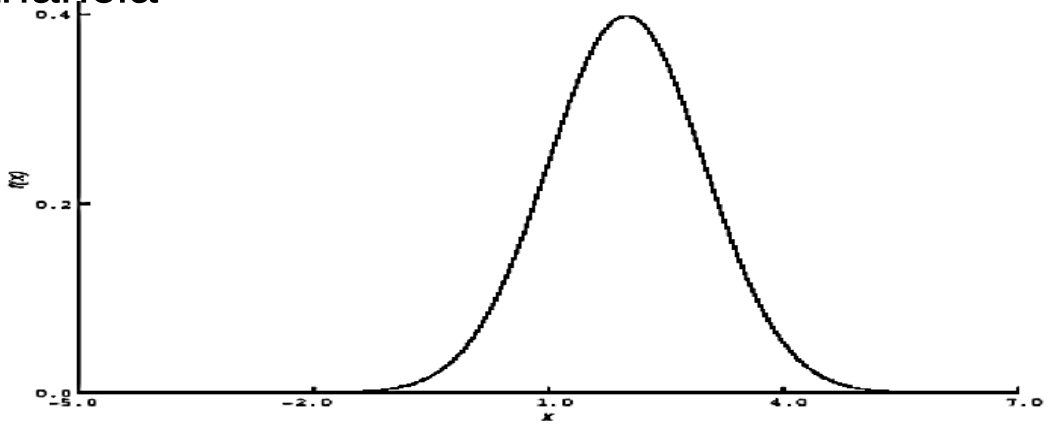

- A função de distribuição **F(x)** **não** possui **fórmula fechada**. Daí, as **probabilidades relacionadas** a **distribuições normais** são usualmente obtidas numericamente e registradas em **tabelas especiais** (veja link abaixo) para eventuais consultas.

- **Essas tabelas** na verdade pertencem à **distribuição normal padrão** (i.e., **Z ~ N(0, 1)**), que é uma **distribuição normal** de parâmetros **μ = 0** e **σ = 1**, e suas entradas são **os valores** de:

$$F_Z(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-\frac{t^2}{2}}\, dt$$

- Pode-se mostrar que a **função de densidade normal padrão** é **simétrica.** Daí, para **z > 0,** tem-se que: $\mathbf{F_Z(-z) = 1 - F_Z(z)}$**.** Ademais, para encontrar **P(a ≤ Z ≤ b**), usamos então **F(b) – F(a).**

http://wiki.icmc.usp.br/images/f/f9/Tabela_Normal.pdf

CDF da distribuição normal

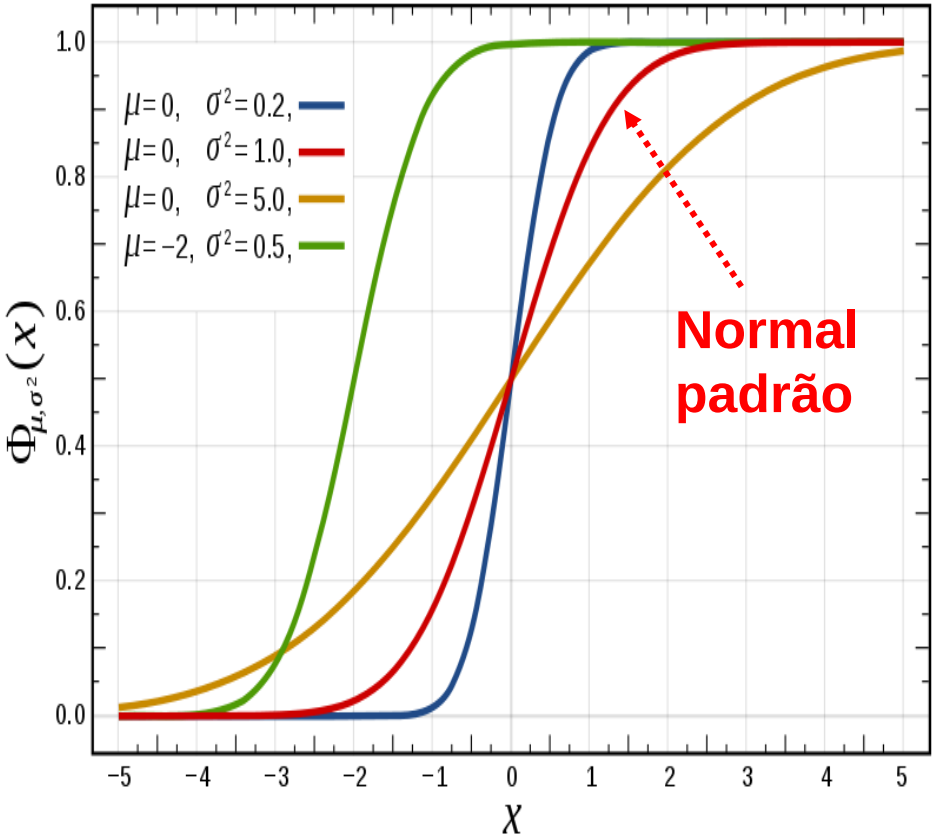

pdf da distribuição normal

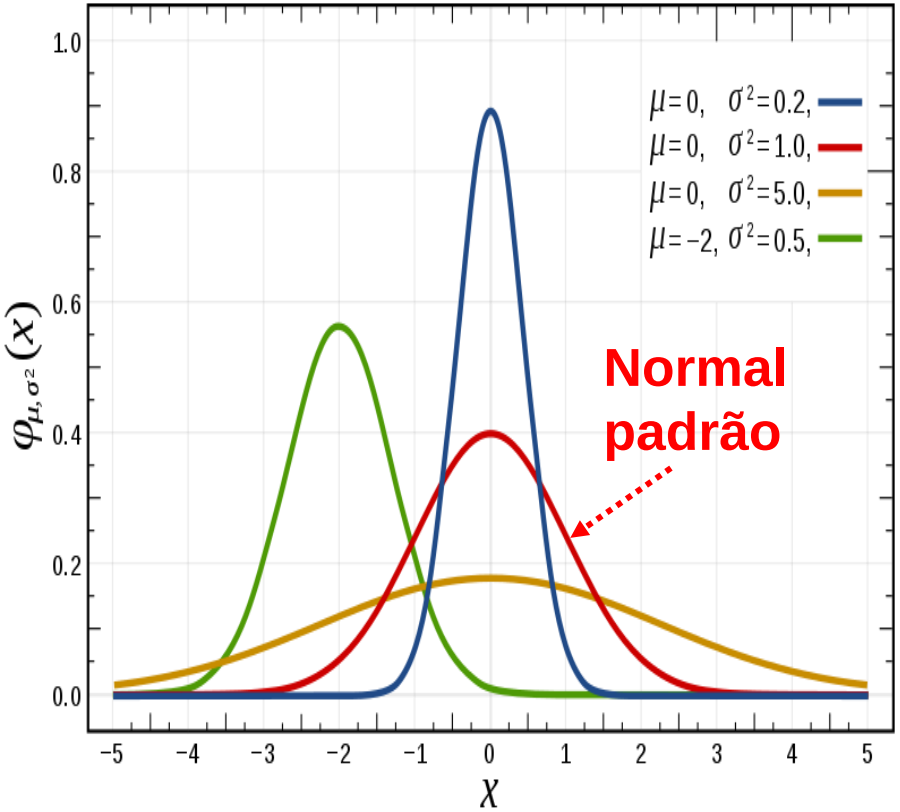

- Para um valor particular de **x,** de uma variável aleatória **X ~ N(μ, σ²),** o correspondente valor **z,** de uma variável aleatória **Z ~ N(0,1)**, é mostrado como sendo dado por **z = (x – μ)/σ**

- A **função de distribuição** de **X** pode então ser encontrada usando a seguinte relação:

$$\boldsymbol{F_Z(z)} = P(Z \leq z) \quad = P(\frac{X-\mu}{\sigma} \leq z)$$

$$= P(X \leq \mu + z\sigma) \quad = \boldsymbol{F_X(\mu + z\sigma)}$$

- **Alternativamente**:

$$\boxed{\boldsymbol{F_X(x) = F_Z(\frac{x-\mu}{\sigma})}}$$

- **Exemplo 3: Exemplo 3.5 (Trivedi, p. 139)**

- Um **sinal analógico** recebido em um detector (medido em microvolts) pode ser modelado como uma variável aleatória **normal**: **X ~ N(200, 256).**

1. Qual é a probabilidade de que o sinal **excederá** 240 microvolts?

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

- **Exemplo 3: Exemplo 3.5 (Trivedi, p. 139)**

1. Qual é a probabilidade de que o sinal **excederá** 240 microvolts?

$$\boldsymbol{P(X > 240)} = 1 - P(X \leq 240) = 1 - F_X(240)$$

$$= 1 - F_Z\left(\frac{240 - 200}{16}\right), \text{usando } F_X(x) = F_Z(\frac{x - \mu}{\sigma})$$

$$= 1 - F_Z(2{,}5) = 1 - 0{,}9938 \cong \mathbf{0{,}00621}, \text{conforme } \textbf{tabela} \text{ da } \textbf{normal padrão}$$

OBS: VIDE TABELA NO PRÓXIMO SLIDE

Tabela da Distribuição Normal Padrão

P(Z<z)

z	0,0	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964

4.3 Notação

- **X ~ Uniforme (a, b):** **X** é uma **v. a.** e tem uma distribuição de Bernoulli com parâmetros **a** **e** **b**.
- **X ~ EXP (λ):** **X** é uma **v. a.** e tem uma distribuição exponencial com parâmetro **λ.**
- **X ~ HYPO (λ1, λ2):** **X** é uma **v. a.** e tem uma distribuição hipoexponencial com parâmetros **λ1** e **λ2** (λ1 ≠ λ2) (obs: de 2 fases)
- **X ~ ERLANG (λ, r):** **X** é uma **v. a.** e tem uma distribuição de Erlang com parâmetros **λ** e **r**
- **X ~ HYPER (λ1, λ2, p1, p2):** **X** é uma **v. a.** e tem uma distribuição hiperexponencial com parâmetros **λ1, λ2, p1, p2** (obs: de 2 fases)
- **X ~ N(μ, σ²):** **X** é uma **v.a.** e tem uma distribuição de normal com parâmetros **μ** e **σ²**

4.4 Exemplos de Outras V.A. Contínuas

Pareto

Weibull

Gamma

1. **Pareto**: também conhecida como **exponencial dupla, hiperbólica, e lei de potência**. Aplicações, e.g., incluem tempo de CPU de um processo, tamanho de arquivo em servidor, número de bytes em rajadas FTP.

2. **Weibull**: Aplicações incluem, e.g., comportamento ON-OFF de usuário web, e tempo para falha de componente devido à fadiga.

3. **Gamma:** obtém-se pela **distribuição de Erlang**, considerando o número de fases não inteiro. Aplicações incluem tempo de falha de componentes.

Estudo extraclasse: TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

5. Teoremas Limites

Alguns dos mais importantes resultados em teoria da probabilidade estão na forma de **teoremas limites**. A seguir apresentamos dois deles.

ROSS, S. M. Stochastic processes. 2nd ed. New York: John Wiley & Sons, 1996. 510p.

https://www.probabilitycourse.com/chapter7/7_1_1_law_of_large_numbers.php

https://www.probabilitycourse.com/chapter7/7_1_2_central_limit_theorem.php

5.1 Lei dos Grandes Números

Teorema: Se $X_1, X_2, \ldots$ são v.a. independentes e identicamente distribuídas com média **μ**, então:

$$P\left\{\lim_{n\to\infty}\left(\frac{X_1+\cdots+X_n}{n}\right)=\mu\right\}=1$$

Deste teorema, decorre então o seguinte.

Seja $S_n = \sum_{i=1}^{n} X_i$, onde $X_1, X_2, \cdots$ são independentes e identicamente distribuídas, com média μ, então a Lei dos Grandes Números nos diz que:

com probabilidade 1, temos que $\frac{\boldsymbol{S_n}}{\boldsymbol{n}}$ converge para $\boldsymbol{E}[\boldsymbol{X_i}] = \mu$

5.2 Limite Central

Teorema: Se $X_1, X_2, \ldots$ são v.a. independentes e identicamente distribuídas com média **μ** e variância **σ²**, então:

$$\lim_{n\to\infty} P\left\{\frac{X_1+\cdots+X_n-n\mu}{\sigma\sqrt{n}} \le a\right\} = \overbrace{\int_{t=-\infty}^{t=a} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\, dt}^{\text{NORMAL PADRÃO}}$$

Deste teorema, decorre então o seguinte.

Seja $S_n = \sum_{i=1}^{n} X_i$, onde $X_1, X_2, \cdots$ são independentes e identicamente distribuídas, com média μ e variância σ^2, então o Limite Central nos diz que:

S_n tem distribuição normal quando $n \to \infty$

$$S_n \sim N(n\mu, n\sigma^2)$$

OBSERVE ...

Observe que (dividindo por *n*):

$$\lim_{n\to\infty} P\left\{\frac{(X_1+\cdots+X_n-n\mu)/n}{(\sigma\sqrt{n})/n}\leq a\right\}=\int_{t=-\infty}^{t=a}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$$

$$\lim_{n\to\infty} P\left\{Z_n=\frac{(\bar{X}-\mu)\sqrt{n}}{\sigma}\leq a\right\}=\int_{t=-\infty}^{t=a}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt \quad \Rightarrow \quad Z_n\sim N(0,1)$$

Observe que dividindo por $\sqrt{n}$ e lembrando que $F_X(x)=F_Z\left(\frac{x-\mu}{\sigma}\right)$

$$\lim_{n\to\infty} P\left\{Z_n=\frac{(\bar{X}-\mu)}{\sigma/\sqrt{n}}\leq a\right\}=\int_{t=-\infty}^{t=a}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt \quad \Rightarrow \quad \bar{X}\sim N(\mu,\sigma^2/n)$$

Relembrando...

Se X tem distribuição **normal** com média **μ** e variância **σ²**, então:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right], \qquad -\infty < x < \infty$$

Se Z tem distribuição **normal padrão, então: μ =0** e **σ = 1**, e:

$$f(z) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}z^2\right], \qquad -\infty < z < \infty$$

Então é mostrado que:

$$F_Z(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-\frac{t^2}{2}}\, dt \;=\; P(Z \le z) \;= P\left(\frac{X-\mu}{\sigma} \le z\right)$$

Mas veja que:

$$Var[S_n] = n.\sigma^2\,; \;\; \text{e} \;\; E[S_n] = n.\mu$$

Trivedi: pag. 137, 139, 182, 241

Mas atenção...

O **Teorema do Limite Central** não deve ser usado **indiscriminadamente**, pois há distribuições que **não** obedecem a ele.

Por exemplo, a variável aleatória **X** de **distribuição de Cauchy**, com pdf (v.a. contínua) **dada a seguir**, **não** tem variância finita; daí, a forma normal padrão **Zn** (slide anterior) **não** pode ser escrita.

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

Também, é **difícil** determinar o valor de **n** (número de variáveis, tamanho da amostra) acima do qual a aproximação pela **normal** é precisa, pois depende-se da **forma da distribuição** base **(** $\boldsymbol{F_{X_i}}$ **). Mas,** tamanhos moderados, tais como **10**, usualmente são considerados adequados.

Trivedi: pag. 241

6. Parâmetros Estatísticos

- A função de **distribuição** ou a função de **densidade** (ou **pmf** p($\boldsymbol{x_i}$)) caracteriza **completamente** o **comportamento** de uma variável aleatória ***X***.

- Frequentemente, **no entanto**, precisamos de uma **descrição mais concisa**, como um único número ou alguns números **(parâmetros),** em vez de uma **função inteira.**

- Citamos alguns desses parâmetros a seguir.

6.1 Esperança (Média)

A esperança $\boldsymbol{E[X]}$, de uma variável aleatória $\boldsymbol{X}$, é definida por

$$\boldsymbol{E[X] = \begin{cases} \sum_i x_i\, p(x_i), \text{ se } X \text{ é discreta} \\ \int_{-\infty}^{\infty} x\, f(x)\, dx, \text{ se } X \text{ é contínua} \end{cases}}$$

6.2 Mediana e Moda

- A **mediana** é definida como qualquer número ***x*** tal que **P(*X* < *x*) ≤ ½** e **P(*X* > *x*) ≤ ½.**

- A **moda** é definida como o número ***x***, para o qual **f(x)** ou **p(x_i)** atinge seu **máximo.**

- São duas quantidades (**parâmetros**) às vezes usadas para descrever uma **variável aleatória *X***.

- A **média, mediana e moda** são usualmente chamadas de **medidas de tendência central** de uma **variável aleatória X**.

6.3 Variância

A variância, ***Var*[*X*]**, de uma variável aleatória ***X*,** é definida por

$$\boldsymbol{Var[X] = \sigma_X^2} \quad = \begin{cases} \sum_i (x_i - E[X])^2 p(x_i), & \textbf{se } X \textbf{ é discreta} \\ \int_{-\infty}^{\infty} (x - E[X])^2 f(x) dx, & \textbf{se } X \textbf{ é contínua} \end{cases}$$

***Var*[*X*]** é sempre um número **não negativo. Pode-se mostrar também que:**

$$\boldsymbol{Var[X] = E\left[(X - E[X])^2\right] = E\left[X^2\right] - (E[X])^2}$$

6.4 Desvio Padrão

- O **desvio padrão**, $\boldsymbol{\sigma_X}$, de uma variável aleatória $\boldsymbol{X}$, é definida como a raiz quadrada da **variância**.

$$\boldsymbol{\sigma_X = \sqrt{Var[X]}}$$

- A **variância** e o **desvio padrão** são **medidas de dispersão** de uma distribuição.

Se ***X*** tiver uma distribuição **concentrada** de modo que ***X*** tome valores próximos a **E[X]** com grande probabilidade, então a **variância** é pequena. Para uma **distribuição difusa**, a **variância** é **grande.**

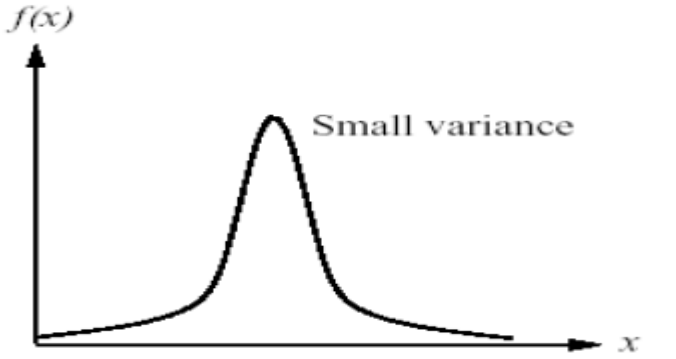

The pdf of a "concentrated" distribution

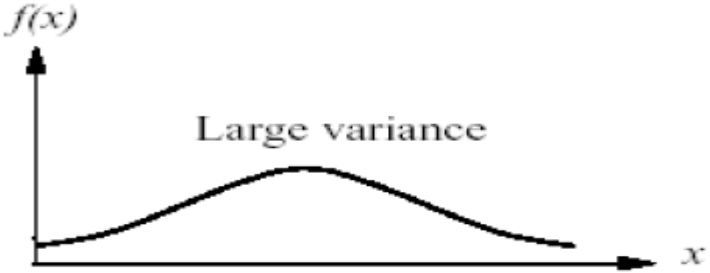

The pdf of a "diffused" distribution

6.5 Coeficiente de Variação

- O **desvio padrão** $\boldsymbol{\sigma_X}$ é expresso nas **mesmas unidades** que o valor individual da variável aleatória ***X*.** Se o **dividirmos** pela **média**, obteremos uma medida relativa da **dispersão** da **distribuição** de ***X***, denotada como **coeficiente de variação**:

$$C_X = \frac{\sigma_X}{E[X]}$$

- O **coeficiente de variação** é útil porque o **desvio padrão** dos dados deve sempre ser entendido **no contexto** da **média** dos dados. Em contraste, o valor do **coeficiente de variação** é **independente** da unidade em que a medição foi feita, portanto, é um **número adimensional.** Para **comparação** entre conjuntos de dados com **unidades diferentes** ou **médias significativamente diferentes**, deve-se usar o **coeficiente de variação** em vez do **desvio padrão.**

- **Exemplo 4: Exemplo (Taboga, 2017)**

- Seja **X** uma variável aleatória **discreta** definida para os seguintes valores:

$$R_X = \{0, 1, 2, 3, 4\}$$

- A **função de probabilidade** é dada por: $p_X(x) = \begin{cases} \frac{1}{5} & \text{if } x \in R_X \\ 0 & \text{if } x \notin R_X \end{cases}$

1. Calcule a **esperança de X**, isto é, o valor de **E[X]**

Taboga, Marco (2017). "Expected value", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/fundamentals-of-probability/expected-value.

- **Exemplo 4: Exemplo (Taboga, 2017)**
- Seja **X** uma variável aleatória **discreta** definida para os seguintes valores: $R_X = \{0, 1, 2, 3, 4\}$
- A **função de probabilidade** é dada por: $p_X(x) = \begin{cases} \frac{1}{5} & \text{if } x \in R_X \\ 0 & \text{if } x \notin R_X \end{cases}$

1. Calcule a **esperança de X**, isto é, o valor de **E[X]**

$$
\begin{aligned}
\mathrm{E}[X] &= \sum_{x \in R_X} x p_X(x) \\
&= 0 \cdot p_X(0) + 1 \cdot p_X(1) + 2 \cdot p_X(2) + 3 \cdot p_X(3) + 4 \cdot p_X(4) \\
&= 0 \cdot \frac{1}{5} + 1 \cdot \frac{1}{5} + 2 \cdot \frac{1}{5} + 3 \cdot \frac{1}{5} + 4 \cdot \frac{1}{5} \\
&= \frac{1+2+3+4}{5} \\
&= \frac{10}{5} = 2
\end{aligned}
$$

- **Exemplo 5: Exemplo (Taboga, 2017)**

- Seja **X** uma variável aleatória **contínua** definida no seguinte intervalo:

$$R_X = [1, 3]$$

- A **função de densidade** é dada por:

$$f_X(x) = \begin{cases} \frac{1}{2} & \text{se } x \in [1, 3] \\ 0 & \text{caso contrário} \end{cases}$$

1. Calcule a **esperança de X**, isto é, o valor de **E[X]**

Taboga, Marco (2017). "Expected value", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/fundamentals-of-probability/expected-value.

- **Exemplo 5: Exemplo (Taboga, 2017)**
- Seja **X** uma variável aleatória **contínua** definida no seguinte intervalo:

$$R_X = [1, 3]$$

- A **função de densidade** é dada por:

$$f_X(x) = \begin{cases} \frac{1}{2} & \text{se } x \in [1, 3] \\ 0 & \text{caso contrário} \end{cases}$$

1. Calcule a **esperança de X**, isto é, o valor de **E[X]**

$$\begin{aligned}
\mathrm{E}[X] &= \int_{-\infty}^{\infty} x f_X(x) dx \\
&= \int_{-\infty}^{1} x f_X(x) dx + \int_{1}^{3} x f_X(x) dx + \int_{3}^{\infty} x f_X(x) dx \\
&= \int_{-\infty}^{1} x 0 dx + \int_{1}^{3} x \frac{1}{2} dx + \int_{3}^{\infty} x 0 dx \\
&= 0 + \left[\frac{1}{4} x^2 \right]_1^3 + 0 \\
&= \frac{1}{4} 3^2 - \frac{1}{4} 1^2 = \frac{9-1}{4} = \frac{8}{4} = 2
\end{aligned}$$

- **Exemplo 6: Exemplo (Taboga, 2017)**

- Seja **X** uma variável aleatória **discreta** definida para os seguintes valores:

$$R_X = \{0, 1, 2, 3\}$$

- A **função de probabilidade** é dada por:

$$p_X(x) = \begin{cases} \frac{1}{4} & \text{if } x \in R_X \\ 0 & \textbf{caso contrário} \end{cases}$$

1. Calcule a **esperança de X**, isto é, o valor de **E[X]**
2. Calcule a **esperança de X²**, isto é, o valor de **E[X²]**
3. Calcule a **variância de X,** isto é, o valor de $\boldsymbol{Var}[\boldsymbol{X}]$

Taboga, Marco (2017). "Variance", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/fundamentals-of-probability/variance.

- **Exemplo 6: Exemplo (Taboga, 2017)**
- Seja **X** uma variável aleatória **discreta** definida para os seguintes valores: $R_X = \{0, 1, 2, 3\}$
- A **função de probabilidade** é dada por: $p_X(x) = \begin{cases} \frac{1}{4} & \text{if } x \in R_X \\ 0 & \textbf{caso contrário} \end{cases}$

1. Calcule a **esperança de X**, isto é, o valor de **E[X]**

$$
\begin{aligned}
\mathrm{E}[X] &= \sum_{x \in R_X} x p_X(x) \\
&= 0 \cdot p_X(0) + 1 \cdot p_X(1) + 2 \cdot p_X(2) + 3 \cdot p_X(3) \\
&= 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{4} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{4} \\
&= \frac{6}{4} = \frac{3}{2}
\end{aligned}
$$

- **Exemplo 6: Exemplo (Taboga, 2017)**
- Seja **X** uma variável aleatória **discreta** definida para os seguintes valores: $R_X = \{0, 1, 2, 3\}$
- A **função de probabilidade** é dada por: $p_X(x) = \begin{cases} \frac{1}{4} & \text{if } x \in R_X \\ 0 & \textbf{caso contrário} \end{cases}$

2. Calcule a **esperança de X²**, isto é, o valor de **E[X²]**

$$
\begin{aligned}
\mathrm{E}[X^2] &= \sum_{x \in R_X} x^2 p_X(x) \\
&= 0^2 \cdot p_X(0) + 1^2 \cdot p_X(1) + 2^2 \cdot p_X(2) + 3^2 \cdot p_X(3) \\
&= 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{4} + 4 \cdot \frac{1}{4} + 9 \cdot \frac{1}{4} \\
&= \frac{14}{4} = \frac{7}{2}
\end{aligned}
$$

- **Exemplo 6: Exemplo (Taboga, 2017)**
- Seja **X** uma variável aleatória **discreta** definida para os seguintes valores: $R_X = \{0, 1, 2, 3\}$
- A **função de probabilidade** é dada por: $p_X(x) = \begin{cases} \frac{1}{4} & \text{if } x \in R_X \\ 0 & \textbf{caso contrário} \end{cases}$

2. Calcule a **variância de X**, isto é, o valor de **Var[X]**

$$\begin{aligned} \mathrm{Var}[X] &= \mathrm{E}\left[X^2\right] - \mathrm{E}[X]^2 \\ &= \frac{7}{2} - \left(\frac{3}{2}\right)^2 \\ &= \frac{14}{4} - \frac{9}{4} = \frac{5}{4} \end{aligned}$$

6.6 Alguns Valores de Parâmetros Estatísticos

6.6.1 V.A. Discretas

$$X \sim \boldsymbol{Bernoulli}(p):$$

$$E[X] = p; \qquad Var[X] = p.q; \qquad C_X = \sqrt{\frac{q}{p}}$$

$$X \sim \boldsymbol{Binomial}(n, p):$$

$$E[X] = n.p; \qquad Var[X] = n.p.q; \qquad C_X = \sqrt{\frac{q}{n.p}}$$

6.6.1 V.A. Discretas

$$X \sim \boldsymbol{Geometric}(p):$$

$$E[X] = \frac{1}{p}; \qquad Var[X] = \frac{q}{p^2}; \qquad C_X = \sqrt{1-p}$$

$$X \sim \boldsymbol{Poisson}(\alpha):$$

$$E[X] = \alpha; \qquad Var[X] = \alpha; \qquad C_X = \frac{1}{\sqrt{\alpha}}$$

6.6.2 V.A. Contínuas

***X* ~ Uniforme (a, b)**

$$E[X] = \frac{b-a}{2}; \qquad Var[X] = \frac{(b-a)^2}{12}; \qquad C_X = \frac{b-a}{b+a}\sqrt{\frac{1}{3}}$$

***X* ~ EXP (λ)**

$$E[X] = \frac{1}{\lambda}; \qquad Var[X] = \frac{1}{\lambda^2}; \qquad C_X = 1$$

6.6.2 V.A. Contínuas

X ~ HYPO (λ1, λ2, …, λn):

$$E[X] = \sum_{i=1}^{n} \frac{1}{\lambda_i}; \qquad Var[X] = \sum_{i=1}^{n} \frac{1}{{\lambda_i}^2}; \qquad C_X = \sqrt{\frac{\sum_1^n \frac{1}{{\lambda_i}^2}}{(\sum_1^n \frac{1}{\lambda_i})^2}}$$

X ~ N(μ, σ²)

$$E[X] = \mu; \qquad Var[X] = \sigma^2; \qquad C_X = \frac{\sigma}{\mu}$$

7. Desigualdades

- A função de **distribuição** (equivalentemente à função de densidade ou à pmf) fornece uma **caracterização completa** de uma **variável aleatória,** e a probabilidade de qualquer evento relativo à **variável aleatória** pode ser determinada a partir dela.

- Medidas como a **média** ou a **variância** fornecem uma quantidade **limitada de informações** sobre a variável aleatória.

- Mas **pode** ser **possível** obter **aceitáveis aproximações** nas **probabilidades de vários eventos** mesmo com base em **informações limitadas**, utilizando as **desigualdades** de Markov e Chebyshev.

7.1 Desigualdade de Markov

Seja $\boldsymbol{X}$ uma variável aleatória não negativa e $\boldsymbol{E}[\boldsymbol{X}] = \boldsymbol{\mu}$, onde $\boldsymbol{\mu}$ é assumido como finito. Então a **desigualdade de Markov** afirma que para **t > 0**

$$\boldsymbol{P}(\boldsymbol{X} \geq \boldsymbol{t}) \leq \frac{\boldsymbol{\mu}}{\boldsymbol{t}}$$

7.2 Desigualdade de Chebyshev

Seja ***X*** uma **variável aleatória** não negativa, e $\boldsymbol{E}\,[\boldsymbol{X}] = \boldsymbol{\mu}$ e $\boldsymbol{Var}[\boldsymbol{X}] = \boldsymbol{\sigma}^2$, onde ambos são considerados finitos. Então a **desigualdade de Chebyshev** afirma que para **t > 0**:

$$\boldsymbol{P}(|\boldsymbol{X} - \boldsymbol{\mu}| \geq \boldsymbol{t}) \leq \frac{\boldsymbol{\sigma}^2}{\boldsymbol{t}^2}$$

- **Exemplo 7: Problema 1 (Trivedi, p. 242)**

- O **tempo médio** de CPU por requisição é **4,39 s** para um servidor. Classificamos a requisição como **trivial** se ela leva **menos que 1 s** de tempo de CPU, como **moderada** se ela leva entre **1 e 5 s** de tempo de CPU, e **complexa** quando **superior a 5 s** de tempo de CPU.

1. Obtenha uma **aproximação** (limite) de probabilidade para que uma requisição seja **complexa**.
2. Obtenha uma **aproximação** (limite) de probabilidade para que uma requisição não seja **trivial.**
3. Assuma agora que o tempo de CPU é **exponencialmente distribuído** com média **4,39 s. Recalcule** então as aproximações.

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

- **Exemplo 7: Problema 1 (Trivedi, p. 242)**

- O **tempo médio de CPU** por requisição é **4,39 s** para um servidor. Classificamos a requisição como **trivial** se ela leva **menos que 1 s** de tempo de CPU, como **moderada** se ela leva **entre 1 e 5 s** de tempo de CPU, e **complexa** quando superior a **5 s** de tempo de CPU.

1. Obtenha uma aproximação (limite) de probabilidade para que uma requisição seja **complexa.**

Usando a **desigualdade de Markov**, temos:

$$\boldsymbol{P(X \geq t) \leq \frac{\mu}{t}}$$

$$P(X > 5) \leq \frac{E[X]}{5} = \frac{4{,}39}{5} = \mathbf{0{,}876}$$

- **Exemplo 7: Problema 1 (Trivedi, p. 242)**

- O **tempo médio de CPU** por requisição é **4,39 s** para um servidor. Classificamos a requisição como **trivial** se ela leva **menos que 1 s** de tempo de CPU, como **moderada** se ela leva **entre 1 e 5 s** de tempo de CPU, e **complexa** quando superior a **5 s** de tempo de CPU.

2. Obtenha uma aproximação (limite) de probabilidade para que uma requisição não seja **trivial.**

Usando a **desigualdade de Markov**, temos:

$$\boldsymbol{P(X \geq t) \leq \frac{\mu}{t}} \qquad P(X \geq 1) \leq \frac{E[X]}{1} = \frac{4{,}39}{1} = \mathbf{4,39}\ \textbf{(não útil!!)}$$

- **Exemplo 7: Problema 1 (Trivedi, p. 242)**

- O **tempo médio de CPU** por requisição é **4,39 s** para um servidor. Classificamos a requisição como **trivial** se ela leva **menos que 1 s** de tempo de CPU, como **moderada** se ela leva **entre 1 e 5 s** de tempo de CPU, e **complexa** quando superior a **5 s** de tempo de CPU.

3. Assuma agora que o tempo de CPU é **exponencialmente distribuído** com média **4,39 s. Recalcule** então as **aproximações**.

Agora ***X* ~ EXP (λ), onde λ= 1/(4,39).** Considere o caso de **complexa.**

$$F(x) = P(X \leq x) = 1 - e^{-\lambda x}, \text{onde } x = 5$$

$$1 - F(x) = 1 - P(X \leq x) = \boldsymbol{P(X > x)} = e^{-\frac{-5}{4,39}} = e^{-1,13895} = \mathbf{0,32}$$

- **Exemplo 7: Problema 1 (Trivedi, p. 242)**

- O **tempo médio de CPU** por requisição é **4,39 s** para um servidor. Classificamos a requisição como **trivial** se ela leva **menos que 1 s** de tempo de CPU, como **moderada** se ela leva **entre 1 e 5 s** de tempo de CPU, e **complexa** quando superior a **5 s** de tempo de CPU.

3. Assuma agora que o tempo de CPU é **exponencialmente distribuído** com média **4,39 s. Recalcule** então as aproximações.

Agora ***X* ~ EXP (λ), onde λ= 1/(4,39).** Considere o caso de **não trivial.**

$$F(x) = P(X \leq x) = 1 - e^{-\lambda x}, \text{onde } x = 1$$

$$1 - F(x) = 1 - P(X \leq x) = \boldsymbol{P(X > x)} = e^{-\frac{1}{4,39}} \cong \mathbf{0,7963}$$

8. Síntese Final

- Este módulo apresentou **brevemente** o tema **Variáveis Aleatórias Contínuas**

- O tema foi desenvolvido sob o enfoque geral de **Avaliação de Desempenho de Redes.**

- Os slides desta aula estão disponíveis em **www.carlokleber.shorturl.com**

- A **lista de exercícios**, disponível no site acima, propicia a oportunidade de praticar, complementar e fixar o conteúdo ministrado.

Prática e Estudo Individual

Acesse o MOODLE tempestivamente, acesse a aba atividades e realize a atividade prevista.

Referências

- JAIN, R. The art of computer systems performance analysis: technique for experimental design, measurement, simulation, and Modeling. New York: John Wiley & Sons, 1991. 685p.
- TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.
- ROSS, S. M. Stochastic processes. 2nd ed. New York: John Wiley & Sons, 1996. 510p.
- Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/
- Leão, R. M. M (2015). “Estatística e Modelos Probabilísticos”, Notas de aula. Online http://www.land.ufrj.br/~classes/est-prob-2015/

Fim

Prof. Carlo Kleber da Silva Rodrigues
carlo.kleber@ufabc.edu.br