# Avaliação de Desempenho de Redes

## MCZA004-13

## Processos Estocásticos

Prof. Carlo Kleber

# Sumário

1. Introdução
2. Definição
3. Discreto e Contínuo
4. Preliminares de Filas
5. Classificação
6. O Processo de Poisson
7. Síntese final

Parte Prática

Referências

# 1. Introdução

- Neste módulo temos estes **quatro** objetivos **principais:**

1. **Definir** processos estocásticos
2. **Iniciar** o estudo de filas
3. **Classificar** os processos estocásticos
4. **Estudar** o processo de Poisson.

# 2. Definição

- Uma **família** (coleção) de **variáveis aleatórias** que é **indexada** por um **parâmetro** como o tempo é conhecida como um **processo estocástico** (ou processo aleatório).

- Formalmente, um **processo estocástico** é uma **família de variáveis aleatórias** $\{X(t) \mid t \in T\}$, definido em um dado espaço de probabilidade, **indexado** pelo parâmetro $t$, onde $t$ varia ao longo de um conjunto $T$ de **índices**. Ou seja, para cada $t$ no conjunto $T$ **de índices**, $X(t)$ é uma **variável aleatória.**

- Os **valores assumidos** pela variável aleatória $X(t)$ são chamados de **estados**, e o **conjunto de todos os valores possíveis** forma o **espaço de estados** do processo. O **espaço de estado** será denotado por $I$.

- Lembre que uma **variável aleatória** é uma **função** definida no **espaço amostral** $\boldsymbol{S}$ do **experimento subjacente**. Assim, a **família de variáveis aleatórias** (i.e., o **processo estocástico**) é na verdade **uma família** de funções $\{\boldsymbol{X}(\boldsymbol{t}, \boldsymbol{s}) \mid \boldsymbol{s} \in \boldsymbol{S}, \boldsymbol{t} \in \boldsymbol{T}\}$.

- Para um $\boldsymbol{t} = \boldsymbol{t_1}$: $\boldsymbol{X_{t_1}}(\boldsymbol{s}) = \boldsymbol{X}(\boldsymbol{t_1}, \boldsymbol{s})$ é uma **variável aleatória** denotada por $\boldsymbol{X}(\boldsymbol{t_1})$ conforme $\boldsymbol{s}$ varia ao longo do espaço amostral $\boldsymbol{S}$. Em algum outro instante fixo de tempo $\boldsymbol{t_2}$: temos **outra** variável aleatória $\boldsymbol{X_{t_2}}(\boldsymbol{s}) = \boldsymbol{X}(\boldsymbol{t_2}, \boldsymbol{s})$ denotada por $\boldsymbol{X}(\boldsymbol{t_2})$ conforme $\boldsymbol{s}$ varia ao longo do espaço amostral $\boldsymbol{S}$**.**

- Para um ponto de amostra fixo $\boldsymbol{s_1} \in \boldsymbol{S}$**,** a expressão $\boldsymbol{X_{s_1}}(\boldsymbol{t}) = \boldsymbol{X}(\boldsymbol{t}, \boldsymbol{s_1})$ é uma função do tempo $\boldsymbol{t}$, chamada de uma **função amostral** ou uma **realização do processo.** Quando ambos $\boldsymbol{s}$ e $\boldsymbol{t}$ são variados, temos **a família de variáveis aleatórias** que constituem **um processo estocástico.**

## Exemplo 1: Exemplo 6.1 (Trivedi, p. 289)

Considere o **experimento** de escolher aleatoriamente um **resistor** $\boldsymbol{s}$ de um conjunto $\boldsymbol{S}$ de resistores de um circuito elétrico e medir a tensão $\boldsymbol{X}(\boldsymbol{t}, \boldsymbol{s})$ no resistor no tempo $\boldsymbol{t}$.

**Funções (ou caminhos) amostrais** (ou **realizações do processo**) para os **dois resistores diferentes** são mostradas **no próximo slide.**

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002.

## Exemplo 1: Exemplo 6.1 (Trivedi, p. 289)

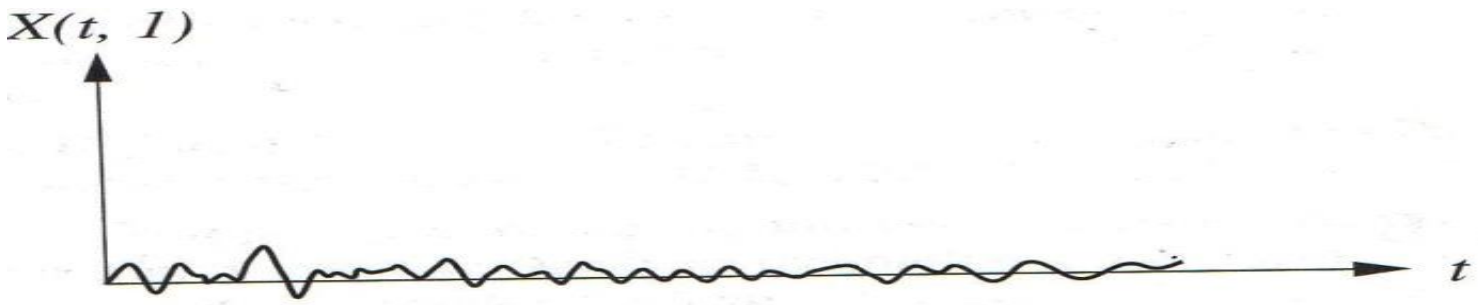


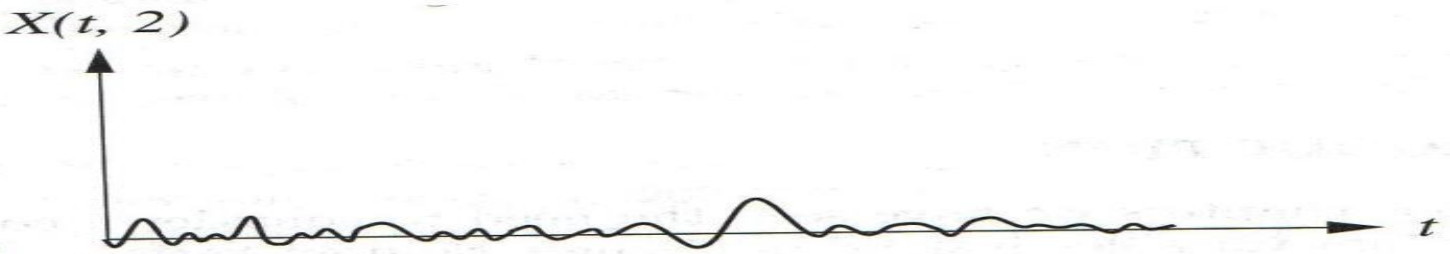

**Exemplo 1: Exemplo 6.1 (Trivedi, p. 289)**

- Em um tempo fixo $\boldsymbol{t} = \boldsymbol{t_1}$ , suponha que medimos **as tensões em todos os resistores** no conjunto $\boldsymbol{S}$, contamos **o número de resistores** com um nível de tensão menor ou igual a $\boldsymbol{x_1}$, e **dividimos essa contagem** pelo número total de resistores em $\boldsymbol{S}$.

- Usando então a interpretação da frequência de probabilidade, temos a **função de distribuição** $\boldsymbol{F_{X(t_1)}(x_1) = P(X(t_1) \leq x_1)}$**,** da variável aleatória $\boldsymbol{X(t_1)}$ . Este cálculo pode ser repetido em **outros instantes** de tempo $\boldsymbol{t_2, t_3, \cdots}$ para obter as **funções de distribuição** de $\boldsymbol{X(t_2), X(t_3), \cdots}$

- Note que $\boldsymbol{F_{X(t_1)}(x_1)}$ se refere então a **proporção** dos **resistores** do conjunto $\boldsymbol{S}$ que têm no tempo fixo $\boldsymbol{t} = \boldsymbol{t_1}$ uma tensão **menor ou igual** a $\boldsymbol{x_1}$.

# 3. Discreto e Contínuo

- Se o **espaço de estado** (valores assumidos pela v.a. $\boldsymbol{X(t)}$) de um **processo estocástico** for **discreto**, então ele é chamado de **processo de estado discreto**, frequentemente referido como uma **cadeia**. Neste caso, o **espaço de estado** é usualmente assumido como $\{\mathbf{0}, \mathbf{1}, \mathbf{2}, \cdots\}$.

- Alternativamente, se o **espaço de estado** é **contínuo**, então temos um **processo de estado contínuo.**

- Da mesma forma, se o **conjunto de índices** $\boldsymbol{T}$ é **discreto**, então temos um **processo de tempo discreto**; caso contrário, temos um **processo de tempo contínuo**.

- Um **processo de tempo discreto** também é chamado de **sequência estocástica** e usualmente é denotado por $\{\boldsymbol{X_n} \mid \boldsymbol{n} \in \boldsymbol{T}\}$.

# 3. Discreto e Contínuo

| | | Time, Index set $T$ | |
|---|---|---|---|
| | | Discrete | Continuous |
| State Space $I$ | Discrete | Discrete-time stochastic chain | Continuous-time stochastic chain |
| | Continuous | Discrete-time Continuous-state process | Continuous-time Continuous-state process |

# 4. Preliminares de Filas

- A **teoria das filas** provê muitos exemplos de **processos estocásticos**.
- Uma **fila** pode ser formada quando **clientes** (jobs) chegam a uma **estação** (servidor) para **serem atendidos** (receber serviço).

https://pt.wikipedia.org/wiki/Teoria_das_filas

- Suponha que os **tempos sucessivos entre chegadas** $Y_1, Y_2, \cdots$, entre chegadas são **variáveis aleatórias** independentes identicamente distribuídas com uma **distribuição** $F_Y$.

- Da mesma forma, os **tempos de serviço** $S_1, S_2, \cdots$ são considerados **variáveis aleatórias** independentes identicamente distribuídas com uma **distribuição** $F_S$.

- Seja $m$ o **número de servidores** na estação.

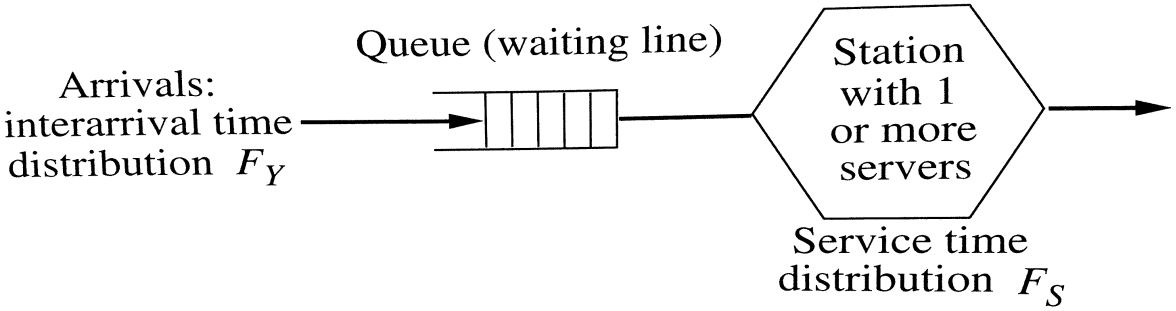

- Usamos a notação $F_Y/F_S\ /\ m$ para descrever o **sistema de filas.**
- $m$ denota o número de servidores.
- Para os **tipos específicos** de distribuição do **tempo entre chegadas** $F_Y$ e de distribuição do **tempo de serviço** $F_S$, usamos os símbolos:

- $M$ : para a distribuição **exponencial** (sem memória)
- $D$ : **determinístico** ou **constante.**
- $E_k$ : para uma distribuição **Erlang** de **k** estágios
- $H_k$ : para uma distribuição **hiperexponencial** de **k** estágios
- $G$ : para uma distribuição **em geral** (**arbitrária**)

- Assim, $M\ /\ G\ /\ 1$ denota uma **fila** de **servidor único** com tempos entre chegadas **exponenciais** e uma distribuição de serviço **arbitrária**. O exemplo mais frequente de fila é, no entanto, o $M/M/1$.

- Além da natureza do tempo entre chegadas e das distribuições de tempo de serviço, também precisamos especificar uma **disciplina de atendimento** que decide como **o servidor deve ser alocado** para os **jobs (clientes) que aguardam serviço.**

- A menos que especificado de outra forma, presumiremos que os **jobs (clientes)** são selecionados para serviço **na ordem de chegada**; ou seja, assumiremos a disciplina de agendamento **FCFS** (first-come, first-served) ou, equivalentemente, **FIFO** (first-in, first-out).

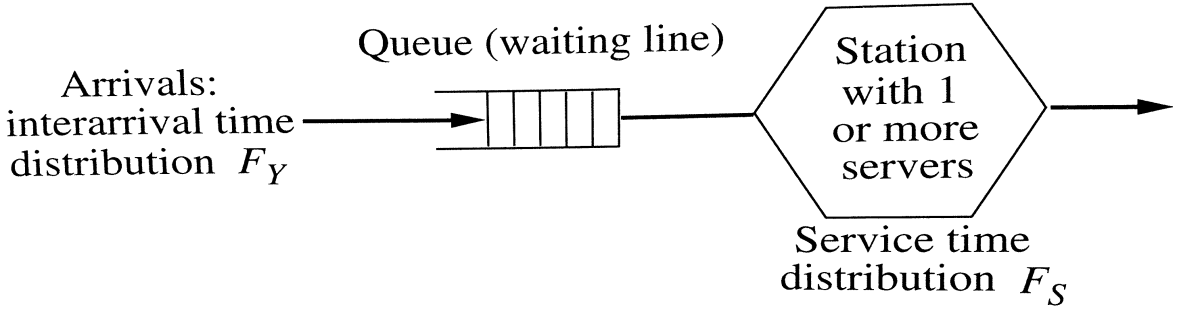

# Exemplo 2: Exemplo 6.2 (Trivedi, p. 291)

Seja $N_k$ o **número de clientes** no sistema no instante da partida do **k-ésimo cliente** (após a finalização do serviço). O **processo estocástico** $\{N_k \mid k = 1, 2, ...\}$ é um processo de **estado discreto** e **tempo discreto**, com **espaço de estado** $I = \{0, 1, 2, ...\}$ e **conjunto de índices** $T = \{1, 2, 3, ...\}$. Um **caminho amostral** deste processo segue.

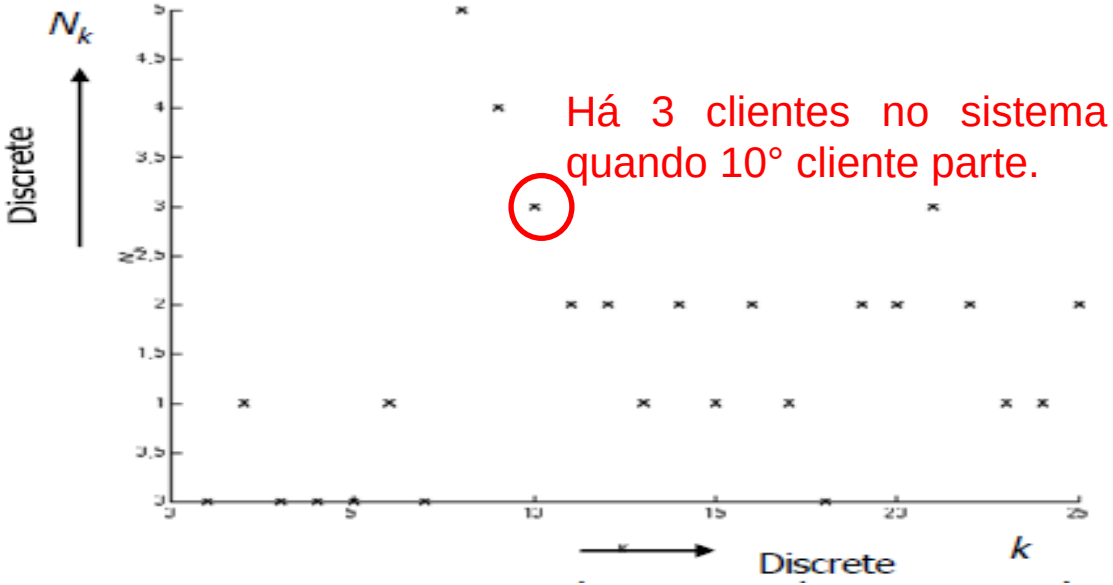

## Exemplo 3: Exemplo 6.2 (Trivedi, p. 291)

Seja $N_k$ o **número de clientes** no sistema no instante de tempo $t$. Então $\{X(t) \mid t \in T\}$ é um processo de **estado discreto** e **tempo contínuo**, com espaço de estado $I$ **= {0, 1, 2, ...}** e conjunto de índices $T$ **= {$t$ | 0 ≤ $t$ < ∞ }.**

**Um caminho amostral deste processo segue.**

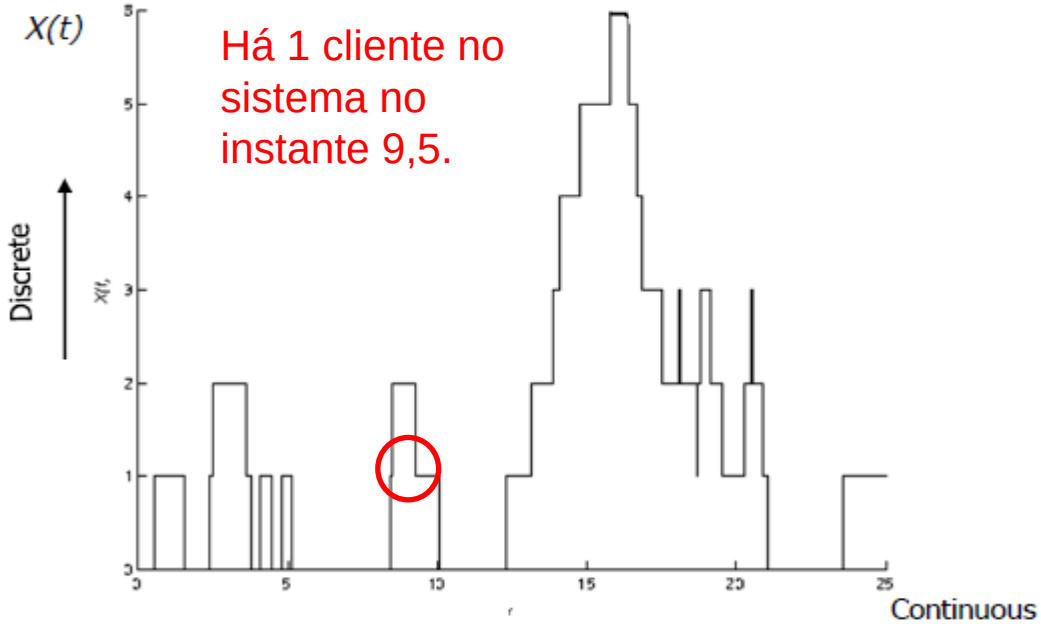

## Exemplo 4: Exemplo 6.2 (Trivedi, p. 291)

Seja $W_k$ o tempo que **o k-ésimo** cliente tem de esperar no sistema antes de receber serviço. Então $\{W_k \mid k \in T\}$ é um processo de **estado contínuo** e **tempo discreto**, com espaço de estado $I = \{x \mid 0 \leq x < \infty\}$ e conjunto de índices $T = \{0, 1, 2, ...\}$. Um caminho amostral deste processo segue.

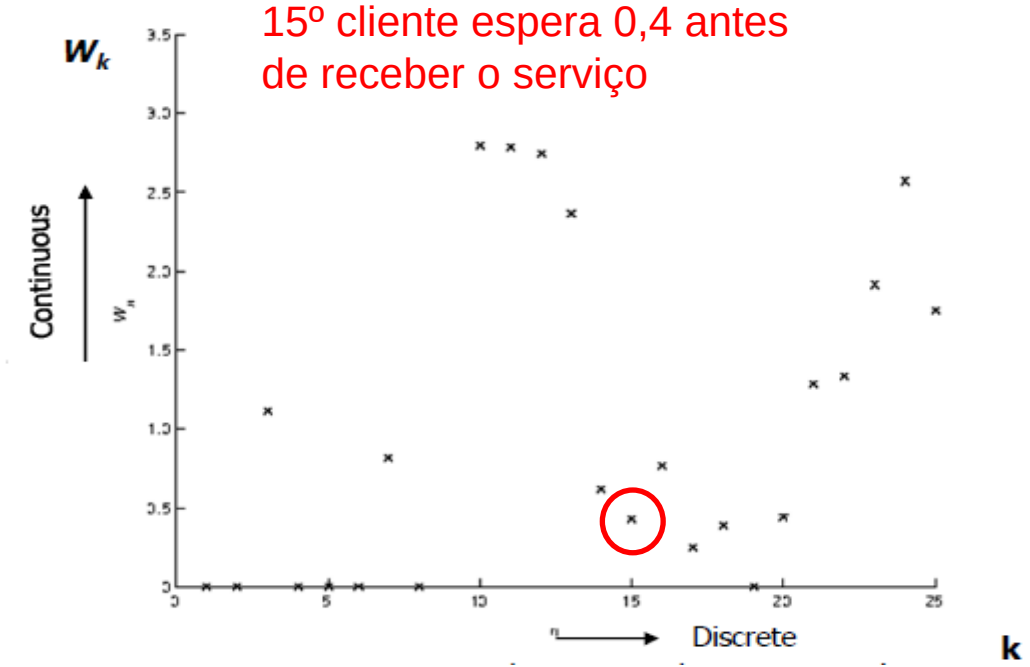

## Exemplo 5: Exemplo 6.2 (Trivedi, p. 291)

Seja $Y(t)$ o tempo de serviço necessário (acumulado) para todos os jobs ainda no sistema em um instante de tempo $t$. Então $\{Y(t) \mid t \in T\}$ é um processo de **estado contínuo** e **tempo contínuo**, com espaço de estado $I = [0, \infty)$ e conjunto de índices $T = \{t \mid 0 \leq t < \infty\}$. Um caminho amostral deste processo segue.

Tempo de serviço necessário é 1,5 no instante 8,2

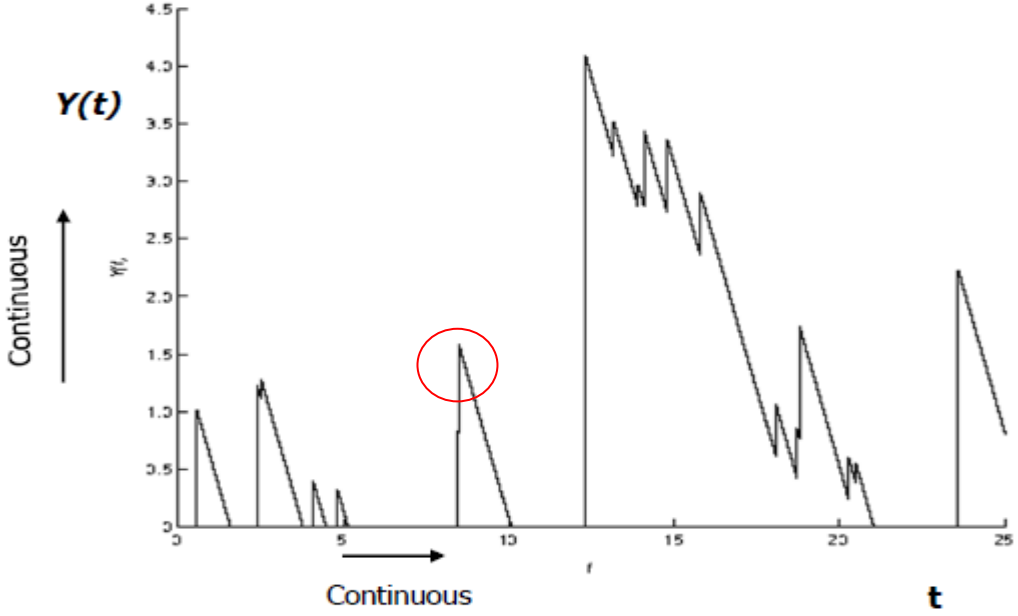

# 5. Classificação

- Para um tempo fixo $\boldsymbol{t = t_1}$, o termo $\boldsymbol{X(t_1)}$ é uma variável aleatória simples que descreve o estado do **processo estocástico** no tempo $\boldsymbol{t_1}$. Para um número fixo $\boldsymbol{x_1}$, a probabilidade do evento $[\boldsymbol{X(t_1) \leq x_1}]$ provê a **CDF** da variável aleatória $\boldsymbol{X(t_1)}$, denotada por:

$$\boldsymbol{F(x_1; t_1) = F_{X(t_1)}(x_1) = P[X(t_1) \leq x_1]}$$

- $\boldsymbol{F(x_1; t_1)}$ é conhecida como a distribuição de **primeira ordem do processo estocástico** $\{\boldsymbol{X(t)} \mid \boldsymbol{t \geq 0}\}$. Dados dois instantes de tempo $\boldsymbol{t_1}$ e $\boldsymbol{t_2}$, os termos $\boldsymbol{X(t_1)}$ e $\boldsymbol{X(t_2)}$ são duas variáveis aleatórias no mesmo espaço de probabilidade. Sua **distribuição conjunta** é conhecida como **distribuição de segunda ordem** do **processo estocástico** e é dada por:

$$\boldsymbol{F(x_1, x_2; t_1, t_2) = P[X(t_1) \leq x_1, X(t_2) \leq x_2]}$$

- Definimos então a **distribuição conjunta de n-ésima ordem** do processo estocástico $\{X(t), t \in T\}$ por:

$$F(x; t) = P[X(t_1) \leq x_1, X(t_2) \leq x_2, \cdots, X(t_n) \leq x_n]$$

- Para todos $\boldsymbol{x} = (x_1, x_2, \cdots, x_n) \in \mathbb{R}^n$ e $t = (t_1, t_2, \cdots, t_n) \in T^n$, $t_1 < t_2, \cdots, t_n$

- **Obs-** $\mathbb{R}$ : **conj. de números reais**; e para os conjuntos A e B, o **produto cartesiano** A × B é o conjunto de todos os pares ordenados (a, b) onde a ∈ A e b ∈ B: $A \times B = \{ (a, b) \mid a \in A \text{ and } b \in B \}.$

- **Obs-** E o **produto cartesiano** pode ser **generalizado** para o produto cartesiano **sobre *n* conjuntos** $X_1, X_2, \cdots, X_n$ : $X^n$

$$X_1 \times \cdots \times X_n = \{(x_1, \ldots, x_n) : x_i \in X_i\}.$$

https://www.ncl.ac.uk/webtemplate/ask-assets/external/maths-resources/numeracy/types-of-numbers.html

$$\boxed{F(x;t) = P[X(t_1) \leq x_1, X(t_2) \leq x_2, \cdots, X(t_n) \leq x_n]}$$

- Essa **descrição completa** de um **processo** não é uma **tarefa fácil. Alguns processos estocásticos** de grande interesse prático, **entretanto**, permitem uma descrição **muito mais simples:**

**Estacionário Estrito Senso**

**Independente**

**Renovação**

**Markov**

**Estacionário Amplo Senso**

# 5.1 Estacionário Estrito Senso

# 5.1 Estrito Senso

- Um **processo estocástico** $\{X(t) \mid t \in T\}$ é considerado **estacionário no sentido estrito** se: para $n \geq 1$, a **distribuição conjunta de $n$-ésima ordem** satisfaz a condição:

$$F(x;t) = F(x;t+\tau), \text{ para } \textbf{todo escalar } \tau \text{ tal que } t+\tau \in T$$

- Seja $\mu(t) = E\,[X(t)]$ a **média** do **processo estocástico** $X(t)$ em $t$. Se o **processo estocástico** $X(t)$ é **estacionário estrito senso**, segue então que $\mu(t) = \mu$ para todo $t \in T$.

# 5.1 Estrito Senso

- Processo **estacionário** ou processo **estacionário estrito senso (ou estacionário no sentido estrito)** **são denominações equivalentes.**

- Parâmetros como **média e variância** **não mudam** ao longo do tempo em **processos estacionários estrito senso.**

- A **autocorrelação** de um processo $\{X(t) \mid t \in T\}$ é definida por:

$$R(t_1, t_2) = E[X(t_1).X(t_2)]$$

- Se o processo é **estacionário estrito senso** então é **possível** mostrar que a função de **autocorrelação** $R(t_1, t_2)$ depende **apenas** da diferença de tempo $\boldsymbol{\tau = t_2 - t_1}$, podendo então ser escrita como:

$$R(t_1, t_2) = R(0, t_2 - t_1) = R(\tau), \;\; t_2 \geq t_1 \geq 0$$

# 5.2 Independente

# 5.2 Independente

- Um **processo estocástico** $\{X(t) \mid t \in T\}$ é considerado um **processo independente** se a **distribuição conjunta de $n$-ésima ordem** satisfaz a condição :

$$F(x;t) = \prod_{i=1}^{n} F(x_i;t_i) = \prod_{i=1}^{n} P[X(t_i) \leq x_i]$$

- Esse **produtório** das distribuições individuais significa que os **valores observados** em $t + \tau$ **não** sofrem influências **daqueles observados** em $t$ para todos os escalares $\tau$ tais que $t + \tau \in T$.

# 5.3 Renovação

# 5.3 Renovação

- Um **processo de renovação** é definido como um processo **independente** de tempo discreto $\{\boldsymbol{X_n} \mid \boldsymbol{n} = \mathbf{1}, \mathbf{2}, \cdots\}$, onde $\boldsymbol{X_1}, \boldsymbol{X_2}, \cdots$, são variáveis aleatórias **independentes, identicamente distribuídas, não negativas.**

- Como **exemplo**, considere **um sistema** em que o reparo (ou substituição) após uma falha é realizada instantaneamente. Neste caso, os **intervalos de tempo** entre falhas sucessivas são **variáveis aleatórias independentes e identicamente distribuídas** de um **processo de renovação** $\{\boldsymbol{X_n} \mid \boldsymbol{n} = \mathbf{1}, \mathbf{2}, \cdots\}$.

# 5.3 Renovação

- Embora a consideração de um **processo independente** **simplifique a análise**, tal consideração **é difícil de ser sempre garantida**, e podemos precisar **na prática** considerar **algum** **tipo de dependência** entre as variáveis.

- A **mais simples e mais importante** tipo de dependência é a **dependência de primeira ordem** ou **dependência de Markov**, explicada a seguir.

# 5.4 Markov

# 5.4 Markov

- Um **processo estocástico** $\{X(t) \mid t \in T\}$ é chamado de um **processo de Markov** se, para qualquer $t_0 < t_1 < t_2 < \cdots < t_n < t$, a **distribuição condicional** de $X(t)$, dados os valores de $X(t_0), X(t_1), \cdots, X(t_n)$, **depende** apenas de $X(t_n)$**:**

$$P[X(t) \leq x \mid X(t_n) = x_n, X(t_{n-1}) = x_{n-1}, \cdots, X(t_0) = x_0] =$$

$$P[X(t) \leq x \mid X(t_n) = x_n]$$

- Essa definição se aplica à **processos de Markov** de **estado contínuo** e **discreto**. Os **processos de Markov** de **estado discreto** são denominados de **Cadeias de Markov (**de **tempo discreto** ou de **tempo contínuo)**.

# 5.4.1 Cadeia de Markov Homogênea no Tempo

- A **cadeia de Markov** é considerada **homogênea no tempo** se a função de distribuição condicional tiver a propriedade de **invariância** com relação à origem (de tempo) $\boldsymbol{t_n}$ **:**

$$\boldsymbol{P[X(t) \leq x \mid X(t_n) = x_n] = P[X(t - t_n) \leq x \mid X(0) = x_n]}$$

- A **probabilidade de transição** entre **estados** é, portanto, **independente** da origem (de tempo) $\boldsymbol{t_n}$. **Apenas** os **estados em si e o intervalo de tempo** $\boldsymbol{t - t_n}$ realmente importam.

# 5.4.1 Cadeia de Markov Homogênea no Tempo

- Segue então que, na **cadeia de Markov homogênea**, a **história passada** do processo é **inteiramente sintetizada** no **estado atual, sem importar** há quanto tempo **já se está** neste **estado atual** para efeito de cálculo da **probabilidade de transição.**

- Portanto, a **distribuição do tempo *Y*** que o **processo passa em um determinado estado** deve ser **sem memória:**

Illustration by Jiin Choi

$$P[Y \leq r + t | Y \geq t] = P[Y \leq r]$$

https://perplex.city/memorylessness-at-the-bus-stop-f2c97c59e420

# 5.4.1 Cadeia de Markov Homogênea no Tempo

- Isso implica que o tempo que uma **Cadeia de Markov homogênea** de **tempo contínuo** passa em um determinado estado tem uma **distribuição exponencial.**

- Ainda, isso implica que o tempo que uma **Cadeia de Markov homogênea** de **tempo discreto** passa em um determinado estado tem uma **distribuição geométrica**.

# 5.5 Estacionário Amplo Senso

# 5.5 Amplo Senso

- Para muitas aplicações, a **estacionariedade estrito senso** de processos estocásticos é **muito restritiva.**

- **Uma** outra forma de **estacionariedade** pode ser então empregada: **estacionariedade amplo senso.**

- Os **processos estacionários amplo senso** requerem **apenas** que a **média** não varie ao longo do tempo, que a **autocovariância** dependa apenas da diferença de tempo $\boldsymbol{\tau} = \boldsymbol{t_2} - \boldsymbol{t_1}$, e que $\boldsymbol{E}\left[\boldsymbol{X^2}(\boldsymbol{t})\right]$ seja **finito** para todo $\boldsymbol{t} \in \boldsymbol{T}$.

https://en.wikipedia.org/wiki/Stationary_process#Weak_or_wide-sense_stationarity

https://en.wikipedia.org/wiki/Autocovariance

# 5.5 Amplo Senso

- Lembre que **autocorrelação** de um processo $\{X(t) \mid t \in T\}$ é definida por:

$$R(t_1, t_2) = E[X(t_1).X(t_2)]$$

- A **autocovariância** de um processo $\{X(t) \mid t \in T\}$ é definida por:

$$Cov[X(t_1), X(t_2)] = R(t_1, t_2) - \mu(t_1)\mu(t_2)$$

- Dado que, por definição de **amplo senso**, a **autocovariância** depende apenas da diferença $\boldsymbol{\tau} = t_2 - t_1$, então a **autocorrelação** $R(t_1, t_2)$ neste caso (i.e., que a média não varia) também **dependerá apenas** da diferença de tempo $\boldsymbol{\tau} = t_2 - t_1$.

# 5.5 Amplo Senso

- Em **síntese**, um **processo estocástico** $\{X(t) \mid t \in T\}$ é então considerado **estacionário amplo senso** se:

$$\mu(t) = E[X(t)] = \mu \text{ para todo } t \in T.$$

$$R(t_1, t_2) = R(0, t_2 - t_1) = R(\tau), \; t_2 \geq t_1 \geq 0$$

$$E\left[X^2(t)\right] < \infty$$

- **Note** que um processo estacionário **estrito senso** com $E\left[X^2(t)\right]$ finito é também um processo estacionário **amplo senso.**

# 6. Processo de Poisson

$$\{N(t) \mid t \geq 0\}$$

# 6.1 Entendimento

- O **processo de Poisson** é um processo de **tempo contínuo** e **estado discreto** que é bom para muitas **situações práticas**.

- O interesse está em contar o **número de eventos** que ocorrem em um **intervalo de tempo.**

- O **evento de interesse** pode, **por exemplo**, corresponder a:

1. O **número de chamadas** para um tronco de uma central telefônica
2. O **número de chegadas de jobs** para um servidor de arquivos
3. O **número de componentes com falha** em um grande grupo de componentes inicialmente sem falhas

# 6.2 Definição

- Suponha que os **eventos** ocorrem **sucessivamente** no tempo, de forma que os **intervalos entre eventos sucessivos** são **independentes** e **identicamente distribuídos** de acordo com uma **distribuição exponencial:**

$$F_X(x) = 1 - e^{-\lambda x}$$

- Assuma que o **número de eventos** no **intervalo de tempo** $(0, t]$ é $N(t)$. Então o **processo estocástico** $\{N(t) | \, t \geq 0\}$ é um processo de **Poisson** de taxa **média** $\lambda$. Nos **Exemplos** 1 e 2 do slide anterior, $\lambda$ é taxa média de **chegada**, enquanto no **Exemplo** 3 é a taxa média de **falha.**

- O **processo de Poisson** é um **processo (de contagem) de renovação** (jobs, falhas, etc.), para o qual a distribuição de tempo entre eventos é **exponencial.**

# 6.3 Características

1. Seja $X$ a **variável aleatória** que denota o **intervalo de tempo entre eventos.** Segue que $X$ tem **distribuição exponencial.**

$$F_X(x) = 1 - e^{-\lambda x}$$

2. Seja $N(t)$ o **número de eventos** em $(0, t]$. Seja $S_k$ a variável aleatória que denota o tempo para a ocorrência do ***k*-ésimo** evento de $N(t)$**.** Tem-se que:

$$S_k = \sum_{i=1}^{k} X_i$$

onde: $X_i$ tem distribuição exponencial de parâmetro $\lambda$. Segue então que $S_k$ é uma variável aleatória de **Erlang.**

# 6.3 Características

3. O **número de eventos** $\boldsymbol{N(t)}$ no intervalo $(\mathbf{0},\ \boldsymbol{t}]$ tem **distribuição** de **Poisson** com parâmetro $\boldsymbol{\lambda t}$**.**

$$\boldsymbol{P[N(t) \leq k] = \sum_{j=0}^{k} e^{-\lambda t} \left(\frac{(\lambda t)^j}{j!}\right)}$$

4. Seja $\boldsymbol{\gamma_t}$ **o tempo,** a partir de ***t,*** para que ocorra o próximo evento. O processo de Poisson **não tem memória** e, assim, $\boldsymbol{\gamma_t}$ tem **distribuição exponencial**.

$$\boldsymbol{F_{\gamma_t}(x) = P[\gamma_t \leq x] = 1 - e^{-\lambda x}}$$

# 6.3 Características

- **De 4**, decorrem:

- **Incrementos independentes**: os **eventos** que ocorrem em **intervalos** que não se **superpõem** são mutuamente **independentes**. Ou seja, o **número de eventos que ocorrem** em intervalos disjuntos **é independente.**

- **Incrementos estacionários:** o **número de eventos** que ocorrem em um **dado intervalo** de tempo depende **apenas** do **tamanho** do intervalo.

# 6.4 Superposição e Decomposição

# 6.4.1 Superposição

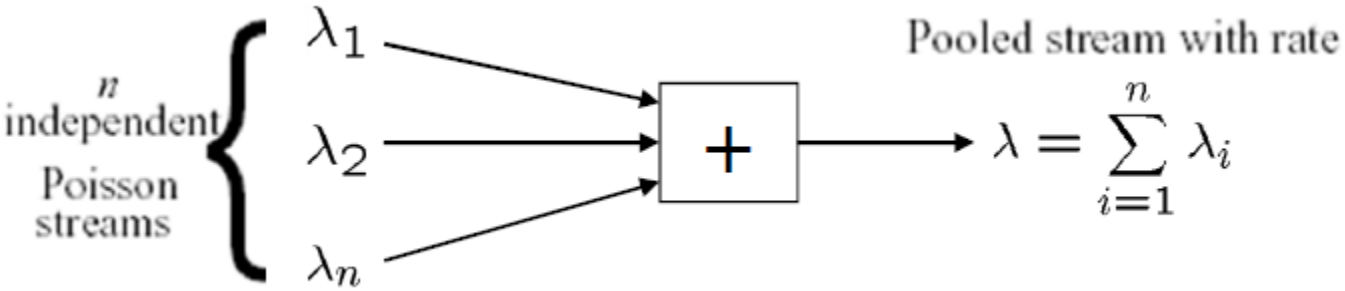


- Suponha que $\boldsymbol{n}$ **processos de Poisson** sejam **sobrepostos**, cada um de taxa $\boldsymbol{\lambda_i}$ , para $\boldsymbol{i} = \mathbf{0}, \mathbf{1}, \mathbf{2}, \cdots, \boldsymbol{n}$.

- O **processo resultante**, que descreve esta **superposição** (**soma**), é também um **processo de Poisson** com taxa resultante $\boldsymbol{\lambda} = \sum_{\boldsymbol{i}=\mathbf{1}}^{\boldsymbol{n}} \boldsymbol{\lambda_i}$

# 6.4.2 Decomposição

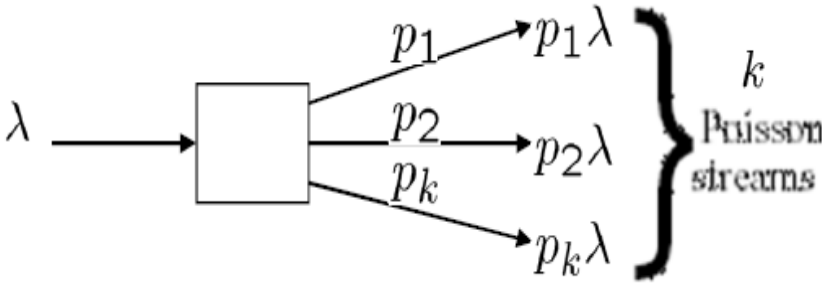


- Suponha que um **processo de Poisson** de **taxa** $\boldsymbol{\lambda}$ seja **decomposto** (dividido) em $\boldsymbol{n}$ **outros processos** (ramos), cada um deles selecionado com **probabilidade** $\boldsymbol{p_i}$, para $\boldsymbol{i} = \mathbf{0}, \mathbf{1}, \mathbf{2}, \cdots, \boldsymbol{n}$.

- **Cada** um desses processos resultantes (ramificações) também é **um processo de Poisson** com **taxa resultante** $\boldsymbol{\lambda_i = p_i\lambda}$, para $\boldsymbol{i} = \mathbf{0}, \mathbf{1}, \mathbf{2}, \cdots, \boldsymbol{n}$.

## Exemplo 6: Exercício 11.1 (Concepts)

O número de clientes que chegam a uma mercearia pode ser modelado por um **processo de Poisson** com **taxa de chegada λ = 10** clientes por hora.

1. Encontre a probabilidade de haver **2 clientes** entre 10h e 10h20.

2. Encontre a probabilidade de haver **3 clientes** entre 10h e 10h20, e **7 clientes** entre 10h20 e 11h.

https://www.probabilitycourse.com/chapter11/11_1_2_basic_concepts_of_the_poisson_process.php

## Exemplo 6: Exercício 11.1 (Concepts)

O número de clientes que chegam a uma mercearia pode ser modelado por um **processo de Poisson** com **taxa de chegada λ = 10** clientes por hora.

1. Encontre a probabilidade de que haja **2 clientes** entre 10h e 10h20.

Aqui, **λ = 10** e o intervalo entre 10:00 e 10:20 tem comprimento **τ = 1/3** hora. Assim, se **X** é o número de chegadas naquele intervalo, podemos escrever **X~Poisson(10/3).** Portanto:

$$P(X=2) = \frac{e^{-\frac{10}{3}}\left(\frac{10}{3}\right)^2}{2!} \approx 0.2$$

## Exemplo 6: Exercício 11.1 (Concepts)

2. Encontre a probabilidade de haver **3 clientes** entre 10h e 10h20 e **7 clientes** entre 10h20 e 11h.

- Aqui, temos dois intervalos não sobrepostos:
  **T1** = (10h00, 10h20] e **T2** = (10h20, 11h00].
- Assim, podemos escrever:
  P(3 chegadas em T1 e 7 chegadas em T2) =
  **P(3 chegadas em T1) x P(7 chegadas em T2).**

- Como os comprimentos dos intervalos são **T1 = 1/3** e **T2 = 2/3** respectivamente, obtemos: $\lambda\tau 1=10/3$ e $\lambda\tau 2=20/3$ . **Finalmente:**

**P(3 chegadas em T1) x P(7 chegadas em T2)**

$$= \frac{e^{-\frac{10}{3}}\left(\frac{10}{3}\right)^3}{3!} \cdot \frac{e^{-\frac{20}{3}}\left(\frac{20}{3}\right)^7}{7!}$$

$$\approx 0.0325$$

## Exemplo 7: Exercício 11.2 (Concepts)

Seja **N(t)** um processo de **Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os correspondentes **tempos entre chegadas**. Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas (i.i.d.), com **Xi ~ EXP(λ), i = 1, 2, ⋯**

1. Encontre a **probabilidade** de que a **primeira chegada** ocorra após **t = 0,5,** ou seja, **P(X1> 0,5).**
2. Dado que **não** tivemos chegadas antes de **t = 1**, encontre **P(X1> 3).**
3. Dado que a **terceira chegada** ocorreu no tempo **t = 2**, encontre a probabilidade de que a **quarta chegada** ocorra **após t = 4.**

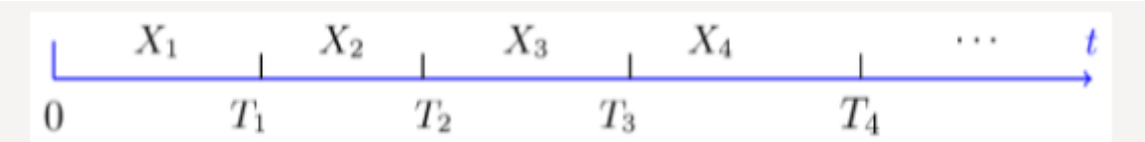


https://www.probabilitycourse.com/chapter11/11_1_2_basic_concepts_of_the_poisson_process.php

# Exemplo 7: Exercício 11.2 (Concepts)

Seja **N(t)** um processo de **Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os correspondentes **tempos entre chegadas**. Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

1. Encontre a **probabilidade** de que a **primeira chegada** ocorra após **t = 0,5,** ou seja, **P(X1 > 0,5).**
   - Como **X1~EXP(2),** podemos escrever:

$$P(X_1 > 0.5) = e^{-(2\times 0.5)} \approx 0.37$$

- **Outra forma**, seria considerar que não houve chegada no intervalo de tempo de **(0 ; 0,5].** Assim, usando **Poisson**:

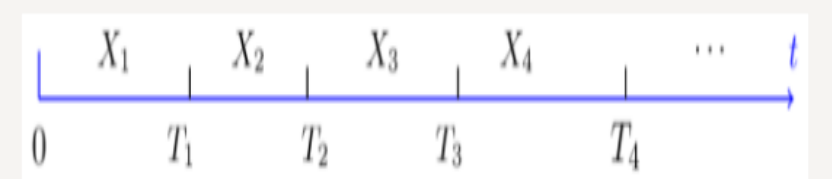


$$P(X_1 > 0.5) = P(\text{no arrivals in } (0, 0.5]) = e^{-(2\times 0.5)} \approx 0.37$$

# Exemplo 7: Exercício 11.2 (Concepts)

Seja **N(t)** um processo de **Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os correspondentes **tempos entre chegadas**. Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

2. Dado que **não** tivemos chegadas antes de ***t* = 1**, encontre **P(X1> 3).**

- Como **X1~EXP(2),** podemos escrever:

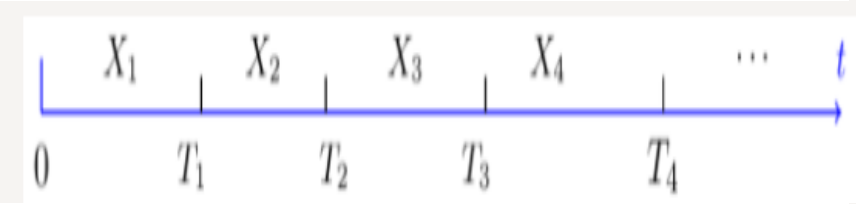


$$\begin{aligned} P(X_1 > 3 | X_1 > 1) &= P(X_1 > 2) \\ &= e^{-2\times 2} \\ &\approx 0.0183 \end{aligned}$$

- Isso é possível porque **X1** é uma **v.a. sem memória**, ou seja, a probabilidade de **X1 >1** não influencia a probabilidade do que ainda está por vir (i.e., que transcorram **ainda mais duas unidades** de tempo)

## Exemplo 7: Exercício 11.2 (Concepts)

Seja **N(t)** um processo de **Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os correspondentes **tempos entre chegadas**. Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

2. Dado que **não** tivemos chegadas antes de ***t* = 1**, encontre **P(X1> 3).**

- **Outra maneira** de resolver isso é notar que o **número de chegadas** em **(1, 3]** é independente das chegadas em **(0, 1].** Assim, usando **Poisson** para contar as chegadas**,** temos:

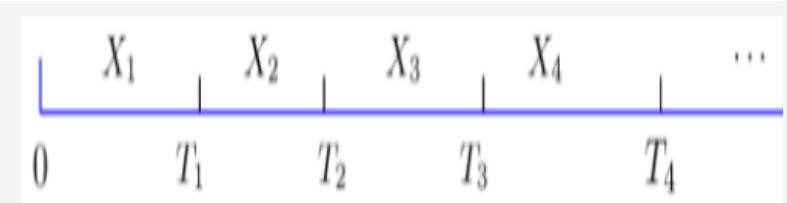


$$
\begin{aligned}
P(X_1 > 3 | X_1 > 1) &= P(\text{no arrivals in } (1,3] \mid \text{no arrivals in } (0,1]) \\
&= P(\text{no arrivals in } (1,3]) \text{ (independent increments)} \\
&= e^{-2\times 2} \\
&\approx 0.0183
\end{aligned}
$$

## Exemplo 7: Exercício 11.2 (Concepts)

Seja **N(t)** um processo de **Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os correspondentes **tempos entre chegadas**. Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

3. Dado que a **terceira chegada** ocorreu no tempo **t = 2**, encontre a probabilidade de que a **quarta chegada** ocorra **após t = 4.**

- O tempo entre **a terceira e a quarta chegada** é **X4~EXP(2)**. Assim, a **probabilidade condicional** desejada é igual a:

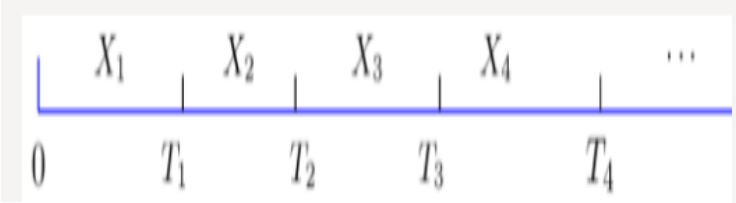


$$P(X_4 > 2 | X_1 + X_2 + X_3 = 2) = P(X_4 > 2) \text{ (independence of the } X_i\text{'s)}$$
$$= e^{-2\times 2}$$
$$\approx 0.0183$$

- Isso é possível porque **X1, X2, ⋯** são v.a. **independentes, então P(X1 dado X2) = P(X1/X2) = P(X1)**

https://pt.wikipedia.org/wiki/Vari%C3%A1veis_aleat%C3%B3rias_independentes

# Exemplo 8: Exercício 11.2 (Concepts)

Seja **N(t)** um **processo de Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os **correspondentes** tempos **entre chegadas.** Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

1. Começo a **observar** o processo no tempo **t = 10**. Seja **T** o tempo da **primeira chegada** que vejo. Em outras palavras, **T** é o tempo da primeira chegada após **t = 10**. Encontre **E[T] e Var[T].**

2. Começo a **observar** o processo no tempo **t = 10**. Seja **T** o tempo da **primeira chegada** que vejo após t=10. Encontre a **esperança condicional** e a **variância condicional** de **T,** visto que fui informado de que a **última chegada** ocorreu no **tempo t = 9**.

https://www.probabilitycourse.com/chapter11/11_1_2_basic_concepts_of_the_poisson_process.php

## Exemplo 8: Exercício 11.2 (Concepts)

Seja **N(t)** um **processo de Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os **correspondentes** tempos **entre chegadas.** Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

1. Começo a **observar** o processo no tempo **t = 10**. Seja **T** o tempo da **primeira chegada** que vejo. Em outras palavras, **T** é o tempo da primeira chegada após **t = 10**. Encontre **E[T] e Var[T].**

- Quando eu começar a observar o processo no tempo t = 10, verei um processo de Poisson. Assim, o tempo a partir da primeira chegada em t = 10 é **exponencial** de parâmetro **λ = 2**. Em outras palavras, podemos escrever:
- T = 10 + X, onde X ~ **EXP(λ).**
- Sabe que: E[X] = 1/ λ e Var[X] = 1/ λ². **Então:**

$$
\begin{aligned}
ET &= 10 + EX \\
&= 10 + \frac{1}{2} = \frac{21}{2}, \\
\mathrm{Var}(T) &= \mathrm{Var}(X) \\
&= \frac{1}{4}.
\end{aligned}
$$

## Exemplo 8: Exercício 11.2 (Concepts)

2. Começo a **observar** o processo no tempo **t = 10**. Seja **T** o tempo da **primeira chegada** que vejo após t=10. Encontre a **esperança condicional** e a **variância condicional** de **T,** visto que fui informado de que a **última chegada** ocorreu no **tempo t = 9**.

- As chegadas antes de t = 10 são **independentes** das chegadas depois de t = 10. Assim, saber que a última chegada ocorreu no tempo t = 9 **não impacta a distribuição da primeira chegada** após t = 10. Assim, se **A é o evento** em que a última chegada ocorreu em t = 9, podemos escrever

$$
\begin{aligned}
E[T|A] &= E[T] \\
&= \frac{21}{2}, \\
\mathrm{Var}(T|A) &= \mathrm{Var}(T) \\
&= \frac{1}{4}.
\end{aligned}
$$

# Exemplo 9: Exercício (Concepts)

Seja **N(t)** um processo de **Poisson** com taxa **λ = 2**, e sejam **X1, X2, ⋯** os correspondentes **tempos entre chegadas**. Veja que **X1, X2, ⋯** são v.a. independentes e identicamente distribuídas, com **Xi ~ EXP(λ), i = 1, 2, ⋯**

1. Sabemos a **distribuição** dos tempos **entre** chegadas. Encontre então a **distribuição** dos **tempos de chegadas.**

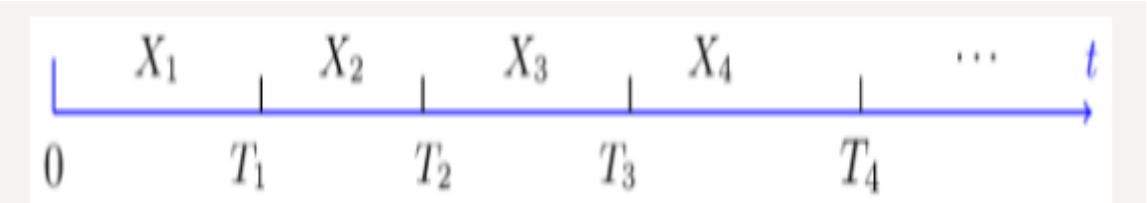


https://www.probabilitycourse.com/chapter11/11_1_2_basic_concepts_of_the_poisson_process.php

## Exemplo 9: Exercício (Concepts)

- **Como sabemos** a distribuição dos tempos **entre chegadas**, podemos encontrar a **distribuição dos tempos de chegadas:**

$$
\begin{aligned}
T_1 &= X_1, \\
T_2 &= X_1 + X_2, \\
T_3 &= X_1 + X_2 + X_3, \\
&\vdots
\end{aligned}
$$

- Mais especificamente, **Tn** é a soma de **n** variáveis aleatórias exponenciais independentes de parâmetro **λ**. Sabemos que, se **Tn = X1 + X2 + ··· + Xn**, onde os **Xi** são variáveis aleatórias **exponenciais** de parâmetro **λ**, independentes, então **Tn~GAMMA(n, λ)** (ou Tn~GAM(n, λ) **.** Observe que aqui **n é inteiro**. Então **Tn~GAMMA(n, λ)** se torna **Tn~ERLANG(n, λ):**

$$T_n \sim Erlang(n, \lambda) = Gamma(n, \lambda), \quad \text{for } n = 1, 2, 3, \cdots.$$

# Exemplo 9: Exercício (Concepts)

- A função de densidade de probabilidade de **Tn**, para **n = 1, 2, 3, ...** é:

$$f_{T_n}(t) = \frac{\lambda^n t^{n-1} e^{-\lambda t}}{(n-1)!}, \quad \text{for } t > 0.$$

- Se **X ~ EXP(λ),** então:

$$E[X] = \frac{1}{\lambda},$$
$$\mathrm{Var}(X) = \frac{1}{\lambda^2}.$$

- Como **Tn = X1 + X2 + X3 + ...+ Xn**, onde **Xi ~ EXP(λ), i = 1, 2, ⋯ ,** tem-se:

$$E[T_n] = n.E[X] = n/\lambda \qquad Var[T_n] = n.Var[X] = n/\lambda^2$$

- Mas note que os **tempos de chegada** não são independentes. Em particular:

$$T_1 \leq T_2 \leq T_3 \leq \cdots.$$

# Exemplo 9: Exercício (Concepts)

- **Síntese: Tempos de chegadas para processos de Poisson**

Se **N(t)** é um processo de **Poisson** com taxa **λ**, então os tempos de chegada **T1, T2, ⋯** têm distribuição **Gamma (n, λ).** Em particular, para **n = 1,2,3, ⋯,** temos

$$E[T_n] = \frac{n}{\lambda}, \text{ and } \mathrm{Var}(T_n) = \frac{n}{\lambda^2}.$$

- A conclusão acima sugere uma maneira de simular (gerar) um processo de **Poisson com taxa λ**. Primeiro, geramos variáveis aleatórias i.i.d. **X1, X2, X3, ⋯,** onde **Xi~EXP(λ).** Em seguida, os tempos de chegada são fornecidos por:

$$\begin{aligned} T_1 &= X_1, \\ T_2 &= X_1 + X_2, \\ T_3 &= X_1 + X_2 + X_3, \\ &\vdots \end{aligned}$$

# 7. Síntese Final

- Este módulo apresentou **brevemente** o tema **Processos Estocásticos**
- O tema foi desenvolvido sob o enfoque geral de **Avaliação de Desempenho de Redes.**
- Os slides desta aula estão disponíveis em **www.carlokleber.shorturl.com**
- A **lista de exercícios**, disponível no site acima, propicia a oportunidade de praticar, complementar e fixar o conteúdo ministrado.

# Prática e Estudo Individual

**Acesse o MOODLE tempestivamente, acesse a aba atividades e realize a atividade prevista.**

# Referências


- JAIN, R. The art of computer systems performance analysis: technique for experimental design, measurement, simulation, and Modeling. New York: John Wiley & Sons, 1991. 685p.
- TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.
- ROSS, S. M. Stochastic processes. 2nd ed. New York: John Wiley & Sons, 1996. 510p.
- Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/
- Leão, R. M. M (2015). “Estatística e Modelos Probabilísticos”, Notas de aula. Online http://www.land.ufrj.br/~classes/est-prob-2015/
- H. Pishro-Nik, "Introduction to probability, statistics, and random processes", available at https://www.probabilitycourse.com, Kappa Research LLC, 2014.

# Fim

JUNTOS

SOMOS MELHORES

Prof. Carlo Kleber da Silva Rodrigues
carlo.kleber@ufabc.edu.br