Avaliação de Desempenho de Redes

MCZA004-13

Cadeia de Markov e Simulação

Prof. Carlo Kleber

Sumário

1. Introdução
2. Cadeia de Markov de Tempo Discreto
3. Cadeia de Markov de Tempo Contínuo
4. Fundamentos da Simulação
5. Síntese final

Parte Prática

Referências

1. Introdução

- Neste módulo temos então os seguintes objetivos:

- **Explicar** Cadeia de Markov.
- **Explicar** os fundamentos da técnica de Simulação.

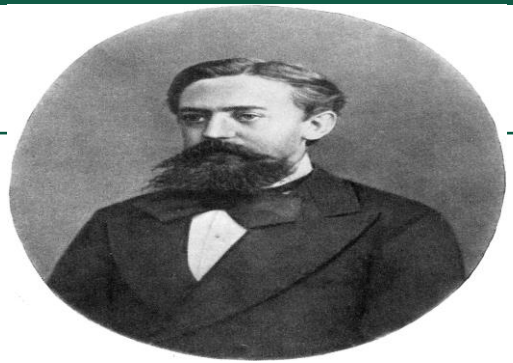

Andrei Andreyevich Markov:
Riazan, 14 de junho de 1856 — São Petersburgo, 20 de julho de 1922) foi um matemático russo.

Em matemática, uma **cadeia de Markov** é um caso particular de **processo estocástico** com **estados discretos** (o parâmetro, em geral o tempo, pode ser discreto ou contínuo) com a propriedade de que a distribuição de probabilidade do **próximo estado** depende apenas do **estado atual** e não na **sequência de eventos que precederam**, uma **propriedade chamada de Markoviana**, em homenagem ao matemático **Andrei Andreyevich Markov.**

Cadeia de Markov de Tempo Discreto

2.1 Definição

- Um **processo de Markov** é um **processo estocástico** cujo comportamento dinâmico é tal que as distribuições de probabilidade para seu desenvolvimento futuro dependem **apenas do estado presente** e **não de como o processo chegou a esse estado**.

- Se assumirmos que o **espaço de estados**, $\boldsymbol{I}$, é **discreto** (finito ou infinito contável), então o **processo de Markov** é conhecido como **Cadeia de Markov.**

- Se assumirmos ainda que o **espaço de parâmetros (índices),** $\boldsymbol{T}$, também é **discreto**, então temos uma **Cadeia de Markov de Tempo Discreto (em inglês, DTMC).** Como o espaço de parâmetros (índices) é discreto, **assuma** $\boldsymbol{T = \{0, 1, 2, \cdots\}}$ sem perda de generalidade.

2.1 Definição

- Observe o **estado de um sistema** em um **conjunto discreto** de **pontos no tempo**.

- As **observações sucessivas** definem as variáveis aleatórias X_0, X_1, X_2, $\cdots$, X_n, $\cdots$, nos instantes de tempo $0, 1, 2, \cdots, n, \cdots$, respectivamente.

- Se $X_n = i_n$, então o estado do sistema no instante de tempo n é i_n.

- X_0 é o **estado inicial** do sistema.

2.2 Propriedade de Markov

- A **propriedade de Markov** pode então ser declarada sucintamente como:

$$\boldsymbol{P(X_n = i_n \mid X_0 = i_0, X_1 = i_1, \cdots, X_{n-1} = i_{n-1}) = P(X_n = i_n \mid X_{n-1} = i_{n-1})}$$

- **Intuitivamente**, isso implica que, dado o **estado atual** do sistema, o **futuro** é independente de seu **passado**.

2.2 Propriedade de Markov

- Seja $p_j(n)$ a **pmf** da variável aleatória X_n, ou seja, esta é a probabilidade de o sistema estar no estado j no instante de tempo n:

$$p_j(n) = P(X_n = j)$$

- E seja a **pmf condicional:**

$$p_{ij}(m,n) = P(X_n = j \mid X_m = i), \qquad 0 \leq m \leq n$$

- A qual denota a **probabilidade** de que o **processo** faça **uma transição** do **estado** i no instante m para o **estado** j no instante n. Assim, $p_{ij}(m,n)$ é conhecida como a **função de probabilidade de transição** da **cadeia de Markov.**

2.3 Cadeia Homogênea no Tempo

- Focamos aqui em **Cadeias de Markov Homogêneas no Tempo ou Cadeias de Markov Estacionárias** - aquelas em que $p_{ij}(m,n)$ não depende dos instantes absolutos m e n da observação da cadeia (i.e., quando os estados i e j são observados), mas apenas da diferença (intervalo) entre esses instantes: $n - m$.

- Neste caso, a **cadeia de Markov** é dita ter **probabilidades de transição estacionárias.** Para **tais cadeias**, usamos a seguinte notação:

$$P[X_{m+n} = j \mid X_m = i] = p_{ij}(n)$$

- Que denota as probabilidades de transição no intervalo n. Assim, $p_{ij}(n)$ é a probabilidade de que uma **Cadeia de Markov Homogênea** se mova do estado i para j em exatamente n passos (i.e., unidades de tempo).

http://leg.ufpr.br/~lucambio/CM/CMI.html

- As probabilidades de transição de **1 passo** $p_{ij}(1)$ são simplesmente escritas como p_{ij}, assim:

$$p_{ij} = p_{ij}(1) = P(X_n = j \mid X_{n-1} = i), \qquad n \geq 1$$

- As probabilidades de transição de **0 passo** $p_{ij}(0)$ são simplesmente escritas assim:

$$p_{ij}(0) = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$$

2.4 Probabilidade Conjunta

- É **possível mostrar que**, considerando a **propriedade de Markov**, a função de probabilidade de massa conjunta (de **n-ésima ordem**) pode ser calculada assim:

$$P(X_0 = i_0\,, X_1 = i_1\,, X_2 = i_2, \cdots, X_n = i_n) = p_{i_0}(0).p_{i_0,i_1} \cdots p_{i_{n-1},i_n}$$

- Isso implica que **todas as probabilidades de transição** de interesse podem ser determinadas a partir da pmf inicial $p_{i_0}(0) = P(X_0 = i_0)$, e das probabilidades de **transição de 1 passo** p_{ij}

- **Veja que** $p_{i_0}(0) = P(X_0 = i_0)$, é a probabilidade de estar no estado i_0 no **instante** 0, ou seja, no **início do processo.**

2.5 Matriz de Transição de 1 Passo

- A pmf da variável aleatória X_0, usualmente denotada por **vetor de probabilidade inicial,** é especificada por:

$$p(0) = [p_0(0), p_1(0), p_3(0), \cdots]$$

- Em que $p_j(0)$ é a **probabilidade** de que o sistema está no **estado** j no **início** do processo (i.e., j é o **estado inicial da cadeia**).

- As **probabilidades de transição** de **um passo** são compactamente especificadas na forma de uma **matriz de probabilidade de transição P**:

$$P = [p_{ij}] = \begin{bmatrix} p_{00} & p_{01} & p_{02} \cdots \\ p_{10} & p_{11} & p_{12} \cdots \\ \vdots & \vdots & \vdots \end{bmatrix}$$

- Onde p_{ij} é a **probabilidade** de o sistema passar do estado i para o estado j em **exatamente um passo.**

- A **matriz** P é também denominada de matriz **de Markov** ou de **Matriz Estocástica.** As seguintes propriedades são satisfeitas para uma **matriz estocástica:**

1. Número de linhas = número de colunas (i.e., é **matriz quadrada**)
2. Só possui elementos **positivos** (i.e., $0 \leq p_{ij} \leq 1$, são probabilidades)
3. A **soma dos elementos** de cada linha é igual a 1.

https://en.wikipedia.org/wiki/Stochastic_matrix

2.6 Diagrama de Transição de 1 Passo

- Uma **descrição equivalente** das **probabilidades de transição de um passo** pode ser dada por um **grafo direcionado** denominado **diagrama de transição de estado** (**diagrama de estado**, para abreviar) da **Cadeia de Markov.**

- Um **nó** rotulado $\boldsymbol{i}$ do **diagrama de estado** é o **estado** $\boldsymbol{i}$ da **Cadeia de Markov,** e um **arco** (aresta) rotulado $\boldsymbol{p_{ij}}$ do **nó** $\boldsymbol{i}$ para $\boldsymbol{j}$ é a probabilidade condicional (ou a **probabilidade de transição** de um passo) assim definida: $\boldsymbol{P(X_n = j \,|X_{n-1} = i) = p_{ij}}$

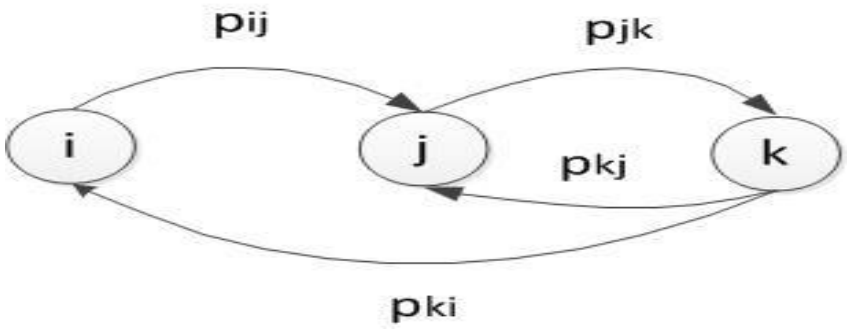

- **Exemplo 1**: **Example 7.1 (TRIVEDI, p. 339, 2002)**
- Observamos o estado de um sistema (ou um componente) em instantes (pontos) discretos no tempo. Dizemos que o sistema está no **estado 0** (zero) se está **operacional** (funcionando). Se o sistema está **em reparo**, então o sistema está **no estado 1** (um). Responda a seguinte questão.

1. Assuma que o sistema possui a **propriedade de Markov**. Tem-se então que o sistema pode ser representado por uma **cadeia de Markov** de dois estados discretos e de tempo discreto. Apresente então o **diagrama de estados** para este sistema, considerando a **probabilidade de transição** do estado 0 para 1 igual a **"a"**, e a **probabilidade de transição** do estado 1 para 0 igual a **"b"**. Considerando que a cadeia seja homogênea, apresente também a **matriz estocástica.**

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 1**: **Example 7.1 (TRIVEDI, p. 339, 2002)**

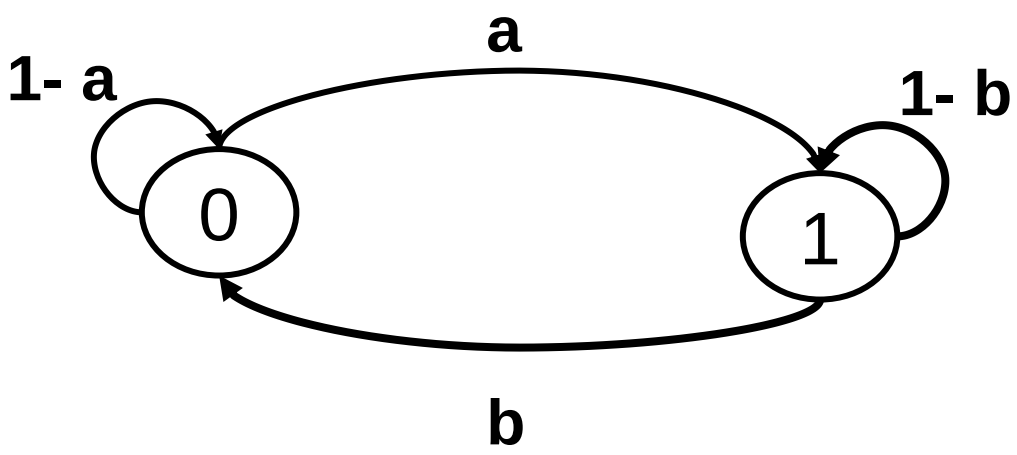

$$P = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}, \; 0 \leq a, b \leq 1$$

- **Exemplo 2**: **Example 7.3 (TRIVEDI, p. 340, 2002)**
- Considere uma **sequência de execuções** consecutivas de um software em **pontos discretos no tempo**. Cada execução tem dois resultados possíveis: **sucesso** e **falha**. Associe com a **n-ésima execução** uma variável aleatória $\boldsymbol{X_n}$ assumindo os valores **0** e **1**, que distingue o resultado da execução entre **sucesso** e **fracasso:**

$$\boldsymbol{X_n} = \begin{cases} \mathbf{0}, & \textbf{denota um sucesso na execução } \boldsymbol{n} \\ \mathbf{1}, & \textbf{denota uma falha na execução } \boldsymbol{n} \end{cases}$$

- Considere agora que a **sequência de execuções** é definida como uma **sequência de ensaios de Bernoulli** onde o **resultado de uma execução** depende do resultado **da execução anterior.** Responda então a questão que segue.

1. Ante o exposto, modele **formalmente** o sistema como uma **cadeia de Markov.** Sua resposta deve incluir formulações de probabilidade e a **matriz estocástica.**

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 2**: **Example 7.3 (TRIVEDI, p. 340, 2002)**

- A **modelagem** proposta obedece ao seguinte. A sequência de execuções é definida como uma **sequência de ensaios dependentes de Bernoulli**, em que assumem-se:

$$P(X_{n+1} = 1 \mid X_n = 0) = 1 - p$$

$$P(X_{n+1} = 1 \mid X_n = 1) = q$$

- Daí, a **sequência de ensaios dependentes** de Bernoulli $\{X_n\}$ acima define uma **cadeia de Markov de tempo discreto com dois estados discretos**. Um dos estados denotado por **0** é considerado **como sucesso**, e o outro denotado por **1** é visto **como falha.** Assumindo que o software não muda ao longo do tempo, i.e., que a cadeia é **homogênea**, a **matriz estocástica** é então dada como segue.

$$P = \begin{bmatrix} p & 1-p \\ 1-q & q \end{bmatrix}, \qquad 0 \le p, q \le 1$$

2.7 Transição de *n* Passos

- Desejamos obter uma expressão para avaliar a **probabilidade de transição** de n passos $p_{ij}(n)$ a partir das **probabilidades de transição** de **um passo** $p_{ij}(1) = p_{ij}$. Lembremos que:

$$p_{ij}(n) = P(X_{m+n} = j \mid X_m = i)$$

- Dado que $X_0 = i$, a probabilidade de que o processo vá **para o estado** k no ***m*-ésimo passo** é $p_{ik}(m)$. E, dado que $X_m = k$, a probabilidade de que o processo atinja o **estado** j no passo (m + n) é $p_{kj}(n)$.

- A **propriedade Markov** implica que esses **dois eventos (transições)** são **independentes.**

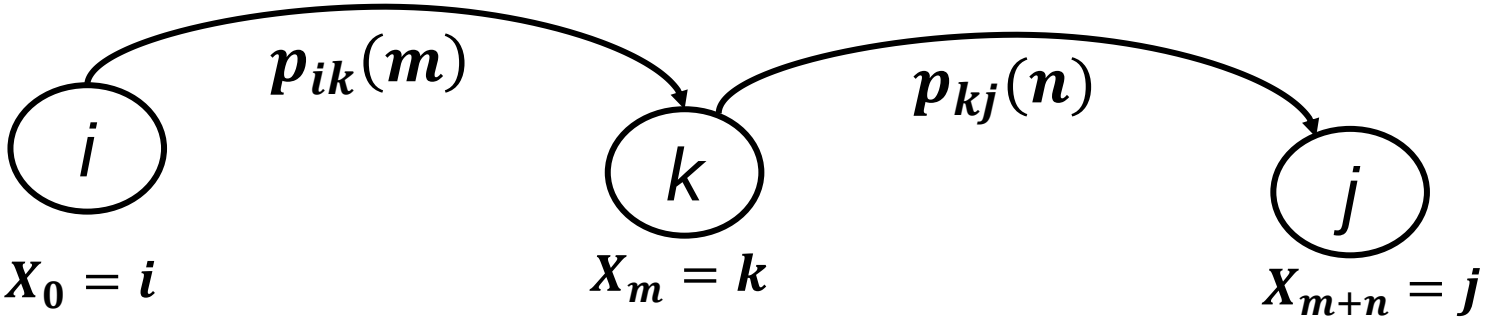

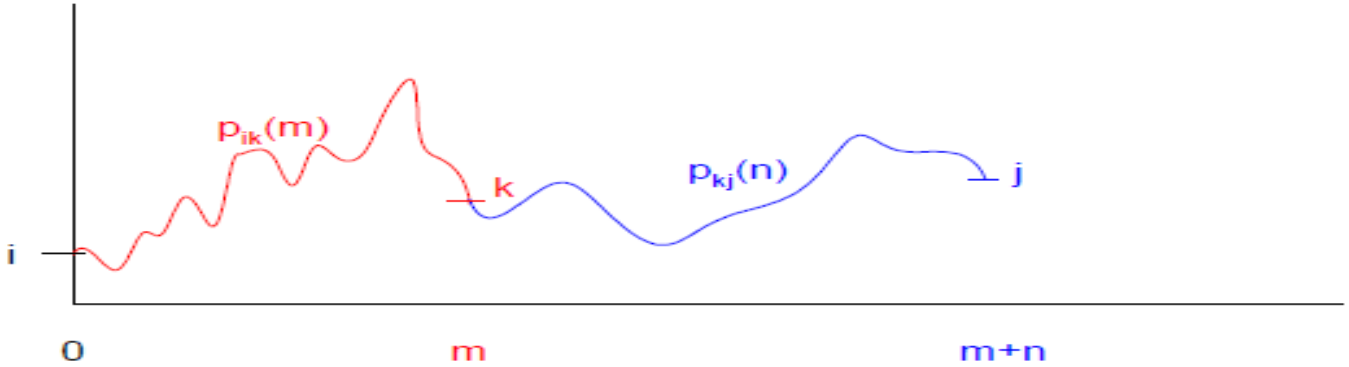

2.7 Transição de n Passos

- Agora, usando o **teorema da probabilidade total** (ou o fato de que a cadeia deve estar em algum estado no passo $\boldsymbol{m}$), obtemos:

$$\boldsymbol{p_{ij}(m+n) = \sum_{k} p_{ik}(m) p_{kj}(n)}$$

- Essa equação é uma forma da **equação de Chapman-Kolmogorov,** que fornece um **meio eficiente** de calcular as **probabilidades de transição de $\boldsymbol{n}$ passos,** como visto a seguir.

- Seja $\boldsymbol{P(n)}$ a matriz cuja entrada $\boldsymbol{(i,\ j)}$ é $\boldsymbol{p_{ij}(n)}$, isto é, seja $\boldsymbol{P(n)}$ a **matriz de probabilidades de transição** de $\boldsymbol{n}$ passos.

- Podemos então escrever a equação de **Chapman-Kolmogorov** considerando $\boldsymbol{m} = \mathbf{1}$ e $\boldsymbol{n}$ substituído por $\boldsymbol{n} - \mathbf{1}$:

$$\boldsymbol{p_{ij}(n) = \sum_{k} p_{ik} . p_{kj}(n-1)}$$

- E na forma de **matriz**, fica então:

$$\boldsymbol{P(n) = P.P(n-1) = P.P.P(n-2) = \cdots = P^{n}}$$

- Assim, a matriz de **probabilidades de transição** de $\boldsymbol{n}$ passos $\boldsymbol{P(n)}$ é obtida multiplicando-se a matriz de **probabilidades de transição** de **um** passo $\boldsymbol{P}$ por ela mesma $\boldsymbol{n-1}$ vezes.

- Em **outras palavras**, o problema de encontrar as **probabilidades de transição de *n* passos** é reduzido a uma potenciação de uma **dada matriz.**

- Note que a matriz $\boldsymbol{P(n)}$ consiste em **probabilidades** e suas somas de linhas são iguais **à unidade**, sendo, portanto, uma **matriz estocástica.**

2.8 Estado do Sistema no passo n

- Podemos obter a pmf (marginal) da variável aleatória X_n (i.e., o estado do sistema no tempo n) usando as **probabilidades de transição** de n passos e o **vetor de probabilidade inicial** da seguinte forma:

$$p_j(n) = P(X_n = j) = \sum_i P(X_0 = i).P(X_n = j \mid X_0 = i)$$

$$= \sum_i p_i(0).p_{ij}(n)$$

- Se a pmf de X_n é expressa **na forma de vetor (linha da matriz),** tem-se:

$$p(n) = [p_0(n), p_1(n), \cdots, p_j(n), \cdots]$$

- Finalmente, a partir dos resultados anteriores, podemos obter as seguintes expressões para o cálculo prático de $p(n)$:

$$\boldsymbol{p(n) = p(0).P(n)} \quad \text{e} \quad \boldsymbol{p(n) = p(0).P^n}$$

- Assim, os **vetores de probabilidade** (dependentes de $\boldsymbol{n}$ passos) de uma **cadeia de Markov homogênea** são **completamente** determinados a partir da **matriz de probabilidade de transição de um passo** $\boldsymbol{P}$ e do **vetor de probabilidade inicial** $\boldsymbol{p(0)}$.

- Se o **espaço de estado** $\boldsymbol{I}$ de uma **cadeia de Markov** $\{\boldsymbol{X_n}\}$ é **finito**, então o cálculo de $\boldsymbol{P^n}$ é **relativamente** simples, e uma expressão para a pmf de $\boldsymbol{X_n}$, expressa como vetor (linha da matriz) para $\boldsymbol{n \geq 0}$, pode ser obtida usando os **resultados acima.**

- Todavia, para **cadeias de Markov** com um **espaço de estado infinito** contável, o cálculo de $\boldsymbol{P^n}$ **não é simples.**

- Portanto, **métodos alternativos** para determinar o comportamento **assintótico** (isto é, conforme $\boldsymbol{n}$ se aproxima do infinito) de $\boldsymbol{P^n}$ e $\boldsymbol{p(n)}$ devem ser considerados. Por exemplo, veja **Seção 2.10.**

2.9 Teorema 1 (Theorem 7.1, TRIVEDI, p. 340, 2002)

- Dada uma **cadeia de Markov** de **dois estados** com **matriz de probabilidade de transição** (de 1 passo):

$$P = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}, \qquad 0 \le a, b \le 1, |1-a-b| < 1$$

- A matriz de **probabilidade de transição** de n passos $P(n) = P^n$ é então dada por:

$$P(n) = \begin{bmatrix} \dfrac{b + a(1-a-b)^n}{a+b} & \dfrac{a - a(1-a-b)^n}{a+b} \\ \dfrac{b - b(1-a-b)^n}{a+b} & \dfrac{a + b(1-a-b)^n}{a+b} \end{bmatrix}$$

Obs: valores de a e b que não satisfazem as restrições acima estão fora do escopo deste módulo.

- **Exemplo 3**: **Example 7.2 (TRIVEDI, p. 339, 2002)**

- Considere um **canal de comunicação** constituído pela interligação em sequência de ***n*** **subcanais de comunicação binários** (que transmitem bits), perfazendo assim um total de ***n*** estágios a serem percorridos para cada bit inserido no canal. Seja X_n o bit (dígito binário) que sai do **n-ésimo estágio do canal**, e seja X_0 o bit que entra no **primeiro estágio do canal.**
- Assuma que os **subcanais de comunicação** são estocasticamente **idênticos** e que não mudam com o tempo. Assuma também que **uma transmissão sem erro** do **bit 0** em um subcanal tem probabilidade **(1 - a),** e que uma transmissão sem erro do **bit 1** em um subcanal tem probabilidade **(1 - b).**
- Considerando a modelagem do sistema descrito acima por meio de uma **cadeia de Markov homogênea**, pede-se:

1. Apresente um **diagrama de estados** do sistema.
2. Apresente a **matriz de probabilidade de transição** (de 1 passo).
3. Apresente um **diagrama representativo dos canais** do sistema.

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 3**: **Example 7.2 (TRIVEDI, p. 339, 2002)**

1. Apresente um **diagrama de estados** do sistema.

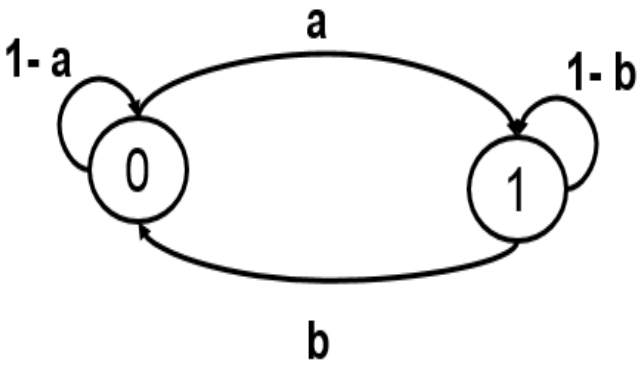

2. Apresente a **matriz de probabilidade de transição** (de 1 passo).

$$P = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}, \; 0 \leq a, b \leq 1$$

- **Exemplo 3**: **Example 7.2 (TRIVEDI, p. 339, 2002)**

3. Apresente um diagrama representativo dos canais do sistema.

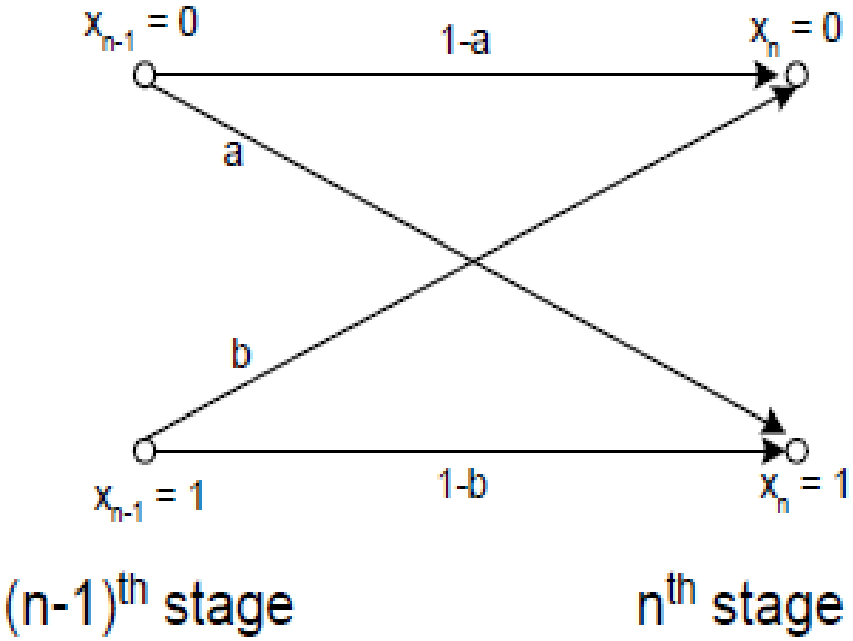

- **Exemplo 4**: **Example 7.4 (TRIVEDI, p. 344, 2002)**

- Considere o **canal de comunicação descrito no Exemplo 3.** Assuma que a = ¼ e b = ½ . Também assuma que as probabilidades iniciais são $\boldsymbol{P(X_0 = 0) = \frac{1}{3}}$ e $\boldsymbol{P(X_0 = 1) = \frac{2}{3}}$. Pede-se então:

1. Apresente a matriz de transição de ***n*** passos: $\boldsymbol{P(n) = P^n}$
2. Calcule a probabilidade de que um bit inicial 1 (i.e., $\boldsymbol{X_0 = 1}$) seja transmitido corretamente por **dois** canais sucessivos.
3. Calcule a probabilidade de que um bit inicial 1 (i.e., $\boldsymbol{X_0 = 1}$) seja transmitido corretamente por **três** canais sucessivos.
4. Apresente o vetor de probabilidade inicial (i.e., o estado inicial do sistema): $\boldsymbol{p(0)}$
5. Apresente o vetor de probabilidade de *n* passos (i.e., o estado do sistema no passo *n*): $\boldsymbol{p(n) = p(0).P^n}$

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 4**: **Example 7.4 (TRIVEDI, p. 344, 2002)**

1. Apresente a matriz de transição de $\boldsymbol{n}$ passos: $\boldsymbol{P}(\boldsymbol{n}) = \boldsymbol{P}^{\boldsymbol{n}}$. Conforme **Teorema 1**, tem-se então:

$$P^n = \begin{bmatrix} \frac{2}{3} + \frac{1}{3}\left(\frac{1}{4}\right)^n & \frac{1}{3} - \frac{1}{3}\left(\frac{1}{4}\right)^n \\ \frac{2}{3} - \frac{2}{3}\left(\frac{1}{4}\right)^n & \frac{1}{3} + \frac{2}{3}\left(\frac{1}{4}\right)^n \end{bmatrix} \quad , \; n \geq 0$$

2. Calcule a probabilidade de que um bit inicial 1 (i.e., $\boldsymbol{X_0} = \mathbf{1}$) seja transmitido corretamente por **dois** canais sucessivos.

$$P(X_2 = 1 | X_0 = 1) = p_{11}(2) = 3/8$$

- **Exemplo 4**: **Example 7.4 (TRIVEDI, p. 344, 2002)**

3. Calcule a probabilidade de que um bit inicial 1 (i.e., $\boldsymbol{X_0 = 1}$) seja transmitido corretamente por **três** canais sucessivos.

$$P(X_3 = 1 | X_0 = 1) = p_{11}(3) = 11/32$$

4. Apresente o vetor de probabilidade inicial (i.e., o estado inicial do sistema): $\boldsymbol{p(0)}$

$$\mathbf{p}(0) = [p_0(0) \quad p_1(0)] = [1/3 \quad 2/3]$$

5. Apresente o vetor de probabilidade de ***n* passos** (i.e., o estado do sistema no passo *n*): $\boldsymbol{p(n) = p(0).P^n}$

$$\mathrm{p(n) = p(0)P^n} = \Big[\underbrace{\tfrac{2}{3} - \tfrac{1}{3}\left(\tfrac{1}{4}\right)^n}_{p_0(n)}, \ \underbrace{\tfrac{1}{3} + \tfrac{1}{3}\left(\tfrac{1}{4}\right)^n}_{p_1(n)} \Big]$$

2.10 Classificação de Estados

- Observe a **matriz de transição de *n* passos** calculada no **Exemplo 4.**

$$P^n = \begin{bmatrix} \frac{2}{3} + \frac{1}{3}\left(\frac{1}{4}\right)^n & \frac{1}{3} - \frac{1}{3}\left(\frac{1}{4}\right)^n \\ \frac{2}{3} - \frac{2}{3}\left(\frac{1}{4}\right)^n & \frac{1}{3} + \frac{2}{3}\left(\frac{1}{4}\right)^n \end{bmatrix}, \; n \geq 0$$

- Veja que conforme $\boldsymbol{n} \to \infty$, as probabilidade de transição de ***n*** passos $\boldsymbol{p_{ij}(n)}$ se tornam independentes de ***n*.**

2.10 Classificação de Estados

- Como já visto na **Seção 2.8**, usando então a definição de $\boldsymbol{p_{ij}(n)}$ e o **teorema da probabilidade total**, podemos escrever o seguinte:

$$\boldsymbol{p_j(n) = P(X_n = j) = \sum_i p_i(0).p_{ij}(n)}$$

- Como $\boldsymbol{p_{ij}(n)}$ não depende de $\boldsymbol{n}$ no limite (vide matriz $\boldsymbol{P^n}$ do **Ex. 4**), concluímos então que $\boldsymbol{p_j(n)}$ converge para uma constante conforme $\boldsymbol{n \to \infty}$. Esta constante é independente do **vetor de probabilidade inicial** (conforme descondicionado pelo somatório em $\boldsymbol{i}$ acima). Denotam-se então **probabilidades limites** (de estado) por:

$$\boldsymbol{v_j = \lim_{n\to\infty} p_j(n), \qquad j = 0, 1, \cdots}$$

2.10 Classificação de Estados

- Muitas (mas **não todas**) **cadeias de Markov** apresentam o **comportamento descrito** anteriormente.

- Para **investigar mais adequadamente** esse tema (i.e., quando $n \to \infty$ ou **cresce muito**), precisamos primeiro classificar os estados da **cadeia de Markov** naqueles que o sistema **visita infinitamente** e naqueles que recebem **um número de visitas finito.**

- Para o **estudo do comportamento estacionário**, precisamos nos concentrar naqueles do **primeiro tipo** (i.e., visita **infinitamente**).

2.10 Classificação de Estados

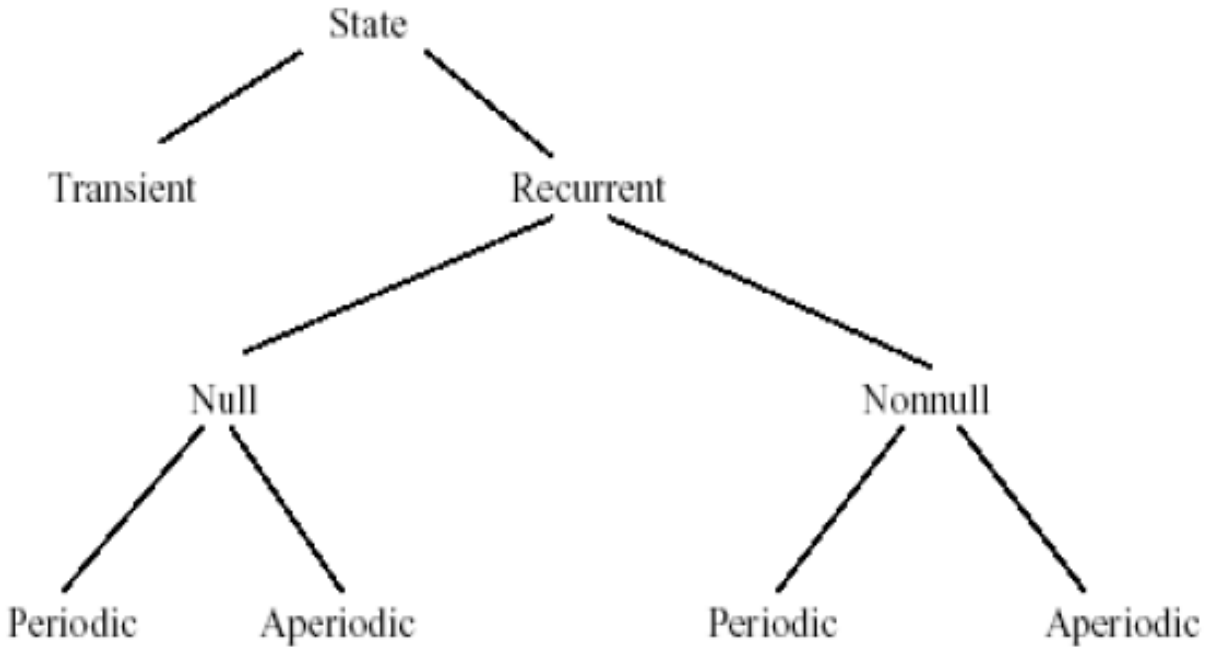

2.10.1 Transiente

- Um estado $\boldsymbol{i}$ é considerado **transiente (ou não recorrente)** se, e somente se, houver uma **probabilidade positiva** de que o processo **não retornará** a este estado.

- Seja $\boldsymbol{X_{ji}}$ o **número de visitas** ao estado $\boldsymbol{i}$, partindo do estado $\boldsymbol{j}$. Então, pode ser mostrado que:

$$\boldsymbol{E[X_{ji}] = \sum_{n=0}^{\infty} p_{ji}(n)}$$

- Segue-se que se o estado $\boldsymbol{i}$ é transiente, então $\sum_{n=0}^{\infty} \boldsymbol{p_{ji}(n)}$ **é finito** para todo $\boldsymbol{j}$; portanto, $\boldsymbol{p_{ji}(n)}$ **se aproxima de 0** conforme $\boldsymbol{n}$ **se aproxima do infinito.**

2.10.1 Transiente

- No diagrama abaixo: ***i***, ***j*** e ***m*** são estados **transientes**. Veja que se o estado ***k*** for alcançado, os estados ***i***, ***j*** e ***m*** **nunca** mais serão visitados.

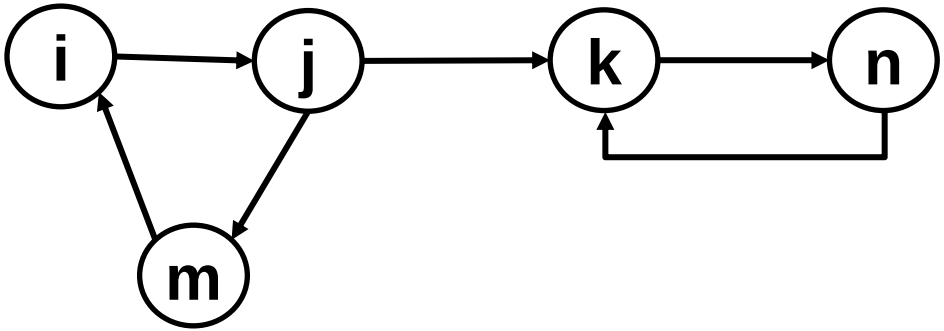

2.10.2 Recorrente

- Um estado $\boldsymbol{i}$ é considerado **recorrente** se, e somente se, partindo do estado $\boldsymbol{i}$, o processo eventualmente retornar ao estado $\boldsymbol{i}$ com probabilidade **um**.

- Uma **caracterização** alternativa de um **estado recorrente** é que:

$$\boldsymbol{E[X_{ii}] = \sum_{n=0}^{\infty} p_{ii}(n)} \text{ é infinito.}$$

- ***i*** e ***j*** são estados **recorrentes.**

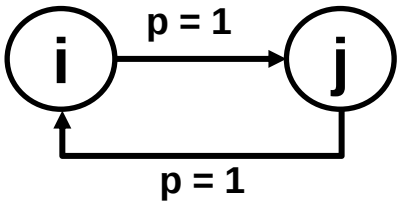

- Para estados **recorrentes,** o tempo de **reentrada** é importante.

- Seja $f_{ij}(n)$ a probabilidade condicional de que a **primeira visita** ao estado j, partindo do estado i, ocorra **exatamente** em n passos.

- Se $i = j$, então nos referimos a $f_{ii}(n)$ como a probabilidade de que o **primeiro retorno** (visita) ao estado i ocorra em exatamente n passos.

- Seja f_{ij} a probabilidade de **visitar,** em algum momento, o estado j, partindo do estado i. Então $f_{ij} = \sum_{n=1}^{\infty} f_{ij}(n)$.

- A probabilidade f_{ij} relaciona-se com a **probabilidade de transição** assim:

$$p_{ij}(n) = \sum_{k=1}^{n} f_{ij}(k) p_{jj}(n-k), \qquad n \geq 1$$

- Segue que o estado $\boldsymbol{i}$ é **recorrente** se $\boldsymbol{f_{ii} = 1}$, e **transiente** se $\boldsymbol{f_{ii} < 1}$.

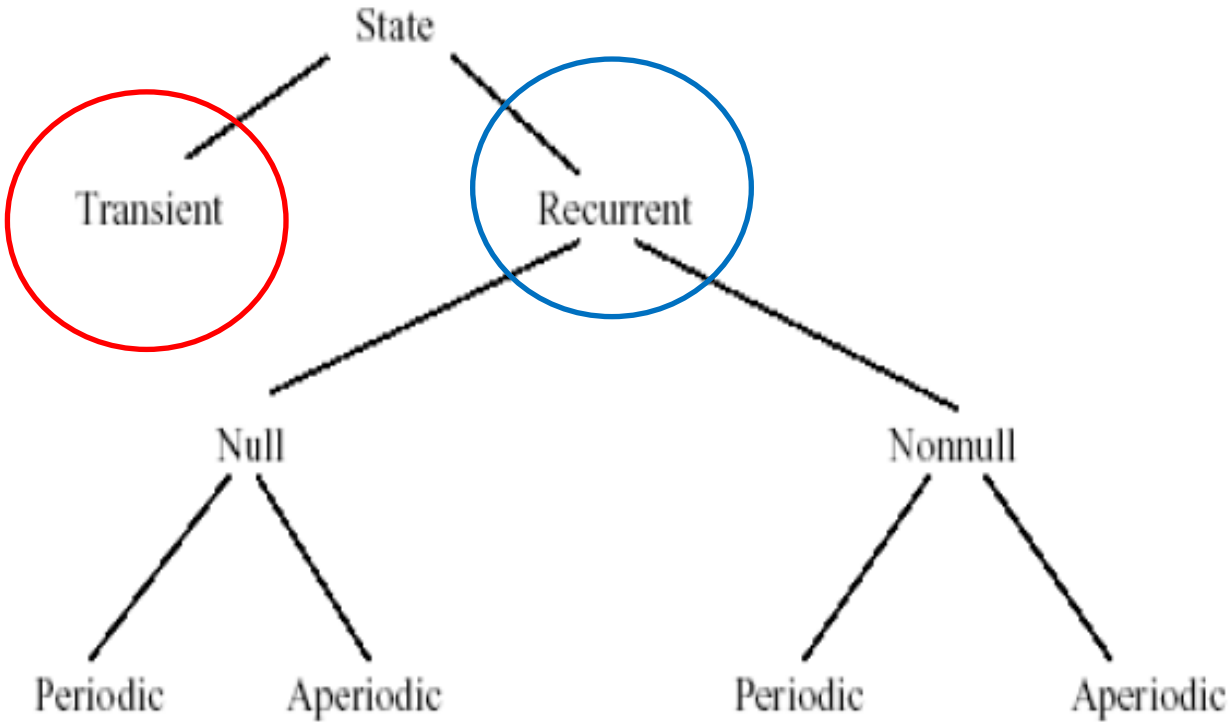

- Se $f_{ii} = 1$ (estado recorrente), define-se o **tempo médio de recorrência** do estado $\boldsymbol{i}$ por $\mu_i = \sum_{n=1}^{\infty} n f_{ii}(n)$.

- Um **estado recorrente** $\boldsymbol{i}$ é considerado **recorrente não nulo** (ou recorrente positivo) se seu **tempo médio de recorrência** μ_i for **finito,** e é considerado **recorrente nulo** se seu **tempo médio de recorrência** μ_i for **infinito.**

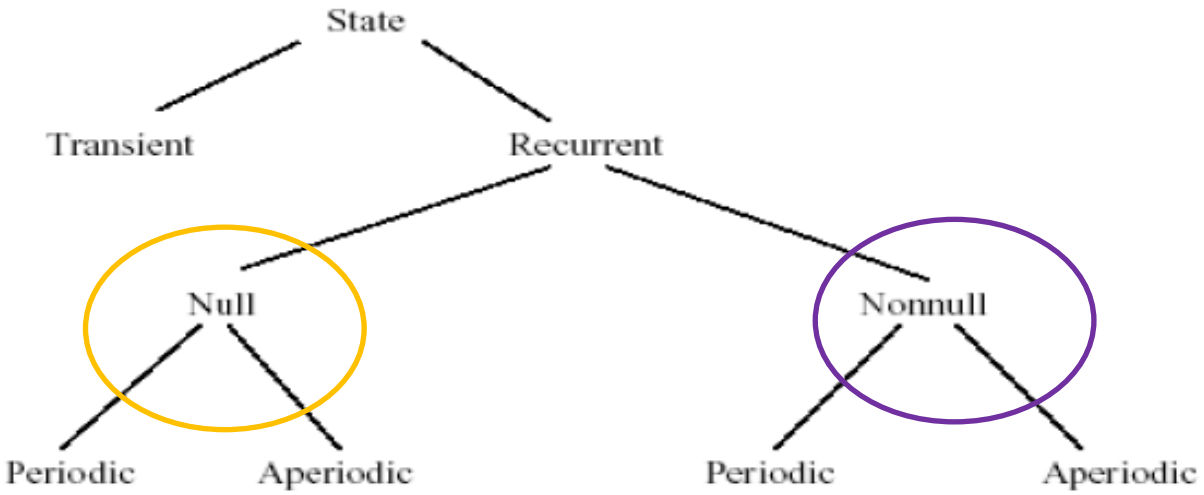

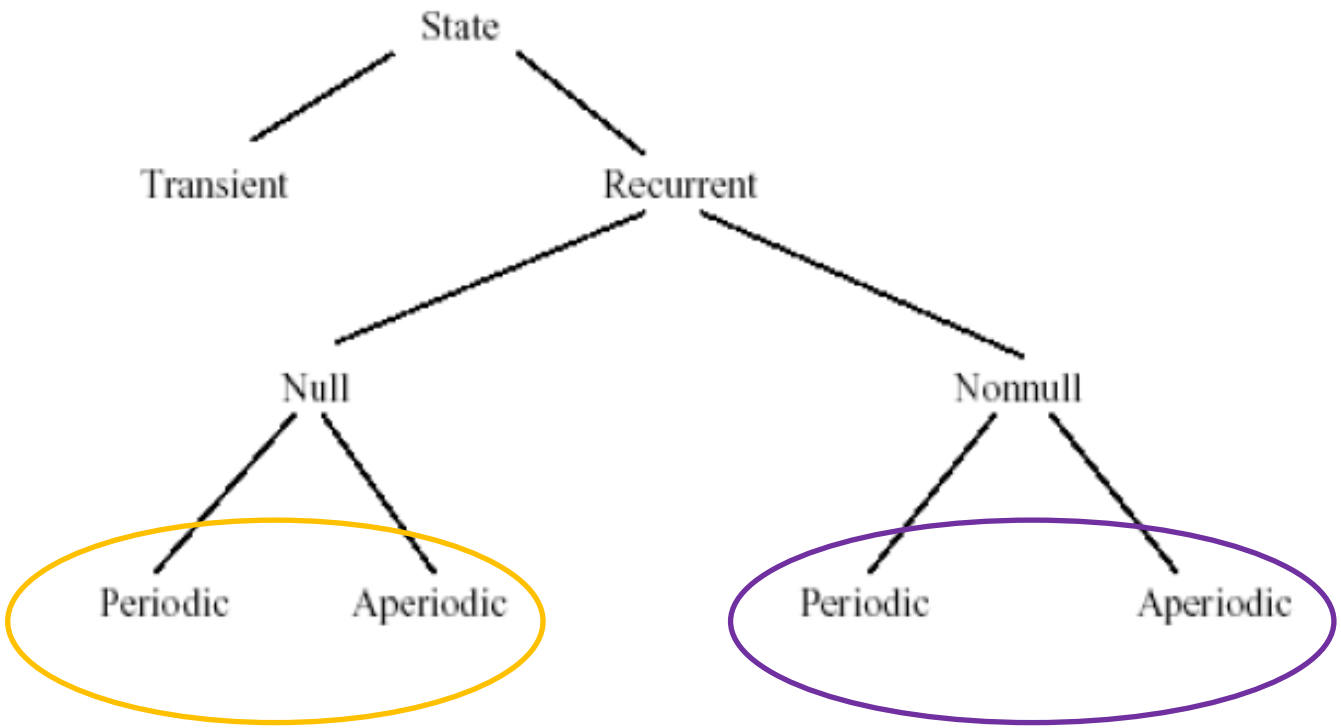

- **O que é Período?**

- **Período**
- Para um **estado recorrente** $\boldsymbol{i}$, $\boldsymbol{p_{ii}(n) > 0}$ para algum $\boldsymbol{n \geq 1}$. Defina o **período** do estado $\boldsymbol{i}$, denotado por $\boldsymbol{d_i}$, como o **máximo divisor comum (MDC)** do conjunto de inteiros positivos $\boldsymbol{n}$ tal que $\boldsymbol{p_{ii}(n) > 0}$

- **Aperiódico e periódico: depende do valor de $\boldsymbol{d_i}$**
- Um **estado recorrente** $\boldsymbol{i}$, é dito **aperiódico** se seu período $\boldsymbol{d_i = 1}$, e **periódico** se $\boldsymbol{d_i > 1}$.

- **Periódico**
- ***n* = 2, 4, 6, ...**
- **MDC =** $\boldsymbol{d_i = 2}$

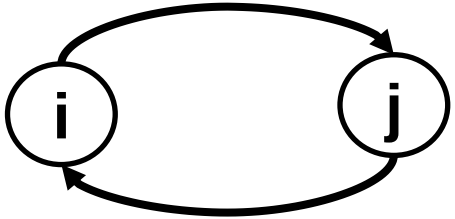

- **Aperiódico:**
- ***n* = 1, 2, 3, 4, ...**
- **MDC =** $\boldsymbol{d_i = 1}$

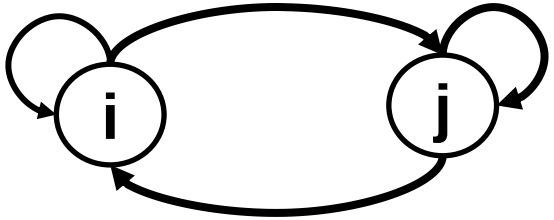

Lembrete: O mínimo múltiplo comum (**MMC** ou M.M.C) e o máximo divisor comum (**MDC** ou M.D.C) podem ser calculados simultaneamente através da **decomposição em fatores primos.**

- Por meio da fatoração, o **MMC** de dois ou mais números é determinado pela **multiplicação direta dos fatores**.
- Já o **MDC** é obtido pela **multiplicação dos números que os dividem ao mesmo tempo.**

Exemplo: fatoração dos números 40 e 60.

40	60	2
20	30	2
10	15	2
5	15	3
5	5	5
1	1	

A multiplicação dos fatores primos 2 x 2 x 2 x 3 x 5 tem como forma fatorada 2^3 x 3 x 5.

Portanto, o MMC de 40 e 60 é: 2^3 x 3 x 5 = 120.

Na fatoração de 40 e 60, podemos perceber que o número 2 foi capaz de dividir duas vezes o quociente da divisão e o número 5 uma vez.

40	**60**	**2**
20	**30**	**2**
10	15	2
5	15	3
5	**5**	**5**
1	1	

Portanto, o MDC de 40 e 60 é: 2^2 x 5 = 20.

https://www.todamateria.com.br/mmc-e-mdc/

- **Absorvente**
- Um estado $\boldsymbol{i}$ é considerado um estado **absorvente** se, e somente se, $\boldsymbol{p_{ii}(1) = p_{ii} = 1}$. A definição de **período** **não se aplica** neste caso.

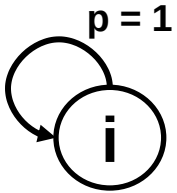

2.10.3 Relação entre Estados

- Tendo definido as propriedades dos estados individuais, agora definimos **a relação** entre os estados.

- **Estados comunicantes:**
- Dois estados $\boldsymbol{i}$ e $\boldsymbol{j}$ comunicam-se entre si (i.e., são **comunicantes**) se houver caminhos direcionados de $\boldsymbol{i}$ para $\boldsymbol{j}$ e vice-versa.

- **Conjunto fechado de estados**
- Um conjunto $\boldsymbol{C}$ de **estados comunicantes** é um **conjunto fechado** se nenhum estado **fora** de $\boldsymbol{C}$ puder ser alcançado a partir de qualquer estado em $\boldsymbol{C}$.

2.10.3 Relação entre Estados

- **Cadeia de Markov Irredutível**

- Uma **cadeia de Markov** é considerada **irredutível** se **todos os estados** puderem **ser alcançados** a partir de **todos os outros estados** em um **número finito** de passos.

- Em outras palavras, para todo $\boldsymbol{i}$, $\boldsymbol{j} \in \boldsymbol{I}$, existe um inteiro $\boldsymbol{n} \geq \mathbf{1}$ tal que $\boldsymbol{p_{ij}(n) > 0}$.

- **TODOS** os **estados** de uma **cadeia de Markov irredutível** são do **mesmo tipo.**

- **Portanto:**
- Se **UM** estado de uma **cadeia irredutível** é **aperiódico,** então o mesmo ocorre com **TODOS os outros estados**, e tal **Cadeia de Markov** é chamada **APERIÓDICA.**
- Se **UM** estado de uma **cadeia irredutível** é **periódico**, então o mesmo acontece com **TODOS os outros estados** e eles têm o **mesmo período.**
- Se **UM** estado de uma **cadeia irredutível** é **transiente**, então o mesmo ocorre com **TODOS os outros estados**.
- Se **UM** estado de uma **cadeia irredutível** é **recorrente**, então o mesmo ocorre com **TODOS os outros estados**.

2.10.4 Considerações

- **As probabilidades de transição de n passos $p_{ij}(n)$** de cadeias de Markov **finitas, irredutíveis e aperiódicas** se tornam **independentes** de i e de n conforme $n \to \infty$. A probabilidade limite (**probabilidade de estar no estado j ,** i.e**.,** v_j) pode ser mostrada como dada por:

$$v_j = \lim_{n\to\infty} p_j(n) = \lim_{n\to\infty} \sum_i p_i(0) p_{ij}(n) = \lim_{n\to\infty} p_{ij}(n)$$

- Mas isso implica que P^n converge para uma matriz V com **linhas idênticas** $v = [v_0, v_1, v_2, \cdots]$ conforme $n \to \infty$**.**

(Kishor Trivedi, p. 350)

2.10.4 Considerações

- Assuma que, para uma dada **cadeia de Markov,** as **probabilidades limites** v_j existem para todos os estados $j \in I$, onde v_j não depende do estado inicial i. Então, pode ser mostrado que: $\sum_{j \in I} v_j \leq 1$.

- Além disso, ou todos $v_j = 0$ (isso pode acontecer apenas para uma cadeia com um **número infinito de estados**) ou $\sum_{j \in I} v_j = 1$.

- **Neste último caso** ($\sum_{j \in I} v_j = 1$), os números v_j, $j \in I$, formam um vetor de **probabilidade de estado estacionário**.

- Assim, precisamos (**desejamos**) que as **probabilidades limites existam**, que sejam **independentes do estado inicial**, e que formem um **vetor de probabilidade.**

2.10.4 Considerações

- **Após um longo período**, espera-se (deseja-se) que a **influência** do **estado inicial** (dos estados transientes) desapareça e a **cadeia** atinja um estado estável **(estacionário).**

- v_j às vezes é interpretada como a **proporção** do tempo em que a **cadeia de Markov** permanece no estado ***j.***

A partir **do teorema da probabilidade total**, temos:

$$p_j(n) = \sum_i p_i(n-1)p_{ij}$$

Então, se temos:

$$\lim_{n\to\infty} p_j(n) = v_j = \lim_{n\to\infty} p_j(n-1),$$ ***(Obs: n → n-1, pois é n é infinito)***

Obtemos:

$$v_j = \sum_i v_i p_{ij}, \qquad j = 0, 1, 2, \cdots$$

Ou em notação de matriz:

$$v = vP \qquad \textbf{(Eq. 1)}$$

Isso nos dá um sistema de **equações lineares** nas incógnitas $[v_0, v_1, \cdots]$. Como v é um vetor de probabilidade, também esperamos que:

$$v_j \geq 0, \ \sum_j v_j = 1 \qquad \textbf{(Eq. 2)}$$

Qualquer vetor x que satisfaça **(Eq. 1)** e **(Eq. 2)** também é conhecido como um **vetor de probabilidade estacionário** da cadeia de Markov.

2.10.5 Teoremas para Estado Estacionário

Para os teoremas a seguir, temos então:

- v_j é a **probabilidade limite** de estar no estado “j”.
- $p_j(n)$ é a **probabilidade** de estar no estado “j” **em *n* passos.**
- $p_{ij}(n)$ é a **prob.** de ir do **estado “i” para o estado “j”** em ***n* passos.**

2.10.5 Teoremas para Estado Estacionário

- **Teorema 2** (**Theorem 7.2, TRIVEDI, p. 351, 2002**)

- Se X(t) é uma cadeia de Markov **aperiódica**, então os seguintes **limites** existem:

$$v_j = \lim_{n \to \infty} p_j(n)$$

- **Teorema 3** (**Theorem 7.3, TRIVEDI, p. 351, 2002**)

- Se X(t) é uma cadeia de Markov **aperiódica e irredutível**, então os seguintes **limites** existem e são independentes do vetor de probabilidade inicial **p(0):**

$$v_j = \lim_{n \to \infty} p_j(n) = \lim_{n \to \infty} p_{ij}(n)$$

2.10.5 Teoremas para Estado Estacionário

- **Teorema 4** (**Theorem 7.4, TRIVEDI, p. 351, 2002**)

- Se ***X*(t)** é uma **cadeia de Markov** **aperiódica**, **irredutível**, com todos os estados **recorrentes não nulos**, então o **vetor de probabilidade limite** $\boldsymbol{v} = [\boldsymbol{v_0}, \boldsymbol{v_1}, \ldots]$ é o **único vetor de probabilidade** satisfazendo $\boldsymbol{v} = \boldsymbol{v}.\boldsymbol{P}$ e $\boldsymbol{v_j} \geq \mathbf{0}, \sum_j \boldsymbol{v_j} = \mathbf{1}$. Daí, $\boldsymbol{v}$ é também conhecido como **vetor de probabilidade de estado estacionário.**

- **Obs**: então $\boldsymbol{v_j} = \lim_{\boldsymbol{n}\to\infty} \boldsymbol{p_j}(\boldsymbol{n})$ existe, é **único** e **não depende** da distribuição inicial **p(0)**. Neste caso, tem-se que $\boldsymbol{v_j}$ é a probabilidade de estar no **estado *j*** no **estado estacionário.**

- Pode ser mostrado que **todos os estados** de uma **cadeia de Markov irredutível** e **finita** são **recorrentes não nulos**.

- **Então**, para uma **cadeia de Markov irredutível, aperiódica e finita**, podemos obter **probabilidades de estado estacionário** resolvendo um **sistema de equações lineares (usando (Eq. 1)** e **(Eq. 2))**, pois o **Teorema 4** se aplica.

- No caso de **cadeias** com um **número infinito de estados**, usualmente empregamos o método de **funções geradoras** ou o **método de explorar a estrutura da matriz de transição de probabilidade *P.***

- Os **exemplos** dados a seguir ajudam no **entendimento dessas abordagens,** sendo que o caso de cadeia **infinita** é visto na **Seção 2.12.**

- **Exemplo 5**: **Example 7.8 (TRIVEDI, p. 352, 2002)**
- Considere um canal de comunicação constituído por ***n*** subcanais binários sucessivos, estocasticamente idênticos. O ruído está tão presente que sempre há a inversão do bit transmitido em cada subcanal por toda transmissão. Modele este canal como uma **cadeia de Markov**. A matriz de transição ***P*** é dada por:

$$\boldsymbol{P} = \begin{bmatrix} \mathbf{0} & \mathbf{1} \\ \mathbf{1} & \mathbf{0} \end{bmatrix}$$

1. Apresente o diagrama de estados.
2. Apresente a matriz de transição de ***n*** passos: $\boldsymbol{P}(\boldsymbol{n}) = \boldsymbol{P}^{\boldsymbol{n}}$
3. Esta cadeia de Markov é periódica ou aperiódica? Justifique sua resposta
4. Para vetor de probabilidade inicial **p(0) = [p, 1 - p],** calcule o vetor de probabilidade de ***n* passos** (i.e., o estado no passo *n*): $\boldsymbol{p}(\boldsymbol{n}) = \boldsymbol{p}(\mathbf{0}).\boldsymbol{P}^{\boldsymbol{n}}$
5. As probabilidades limites existem? Justifique sua resposta.
6. Calcule as probabilidades de estado estacionário.

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 5**: **Example 7.8 (TRIVEDI, p. 352, 2002)**

1. Apresente o diagrama de estados.

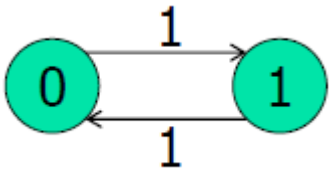

2. Apresente a matriz de transição de ***n*** passos: $\boldsymbol{P(n) = P^n}$

$$\boldsymbol{P^n} = \begin{cases} \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ \mathbf{0} & \mathbf{1} \end{bmatrix}, \textbf{se } \boldsymbol{n} \text{ é } \textbf{par} \\ \begin{bmatrix} \mathbf{0} & \mathbf{1} \\ \mathbf{1} & \mathbf{0} \end{bmatrix}, \textbf{se } \boldsymbol{n} \text{ é } \textbf{ímpar} \end{cases}$$

Por **indução**, vemos que esta **cadeia de Markov** tem o seguinte comportamento. Começando no estado **0 (ou 1),** retornamos ao estado 0 (ou estado 1) depois de um número par de passos. Portanto, o tempo entre visitas a um dado estado exibe um comportamento **periódico**. Assim, temos uma **cadeia de Markov periódica de dois estados**. Também, veja que o **Teorema 1 não** se aplica, pois a = b = 1.

- **Exemplo 5**: **Example 7.8 (TRIVEDI, p. 352, 2002)**

3. Esta cadeia de Markov é periódica ou aperiódica? Justifique sua resposta.

- **Periódica, conforme explicado na letra anterior. Daí, Teoremas 2, 3 e 4 não se aplicam.**

4. Para vetor de probabilidade inicial **p(0) = [p, 1- p],** calcule o **vetor de probabilidade** de ***n* passos** (i.e., o estado no passo *n*): $\boldsymbol{p(n) = p(0).P^n}$

$$\boldsymbol{p(n)} = \begin{cases} [\boldsymbol{p}, & \boldsymbol{1-p}], & \textbf{se } \boldsymbol{n} \text{ é } \textbf{par} \\ [\boldsymbol{1-p}, & \boldsymbol{p}], & \textbf{se } \boldsymbol{n} \text{ é } \textbf{ímpar} \end{cases}$$

5. Portanto, como visto acima, ***p(n)*** **não** tem um limite (não converge para um valor). É **interessante** notar que, embora as **probabilidades limites não existam**, as **probabilidades estacionárias** $\boldsymbol{v = [v_0, v_1]}$ são **únicas** e podem ser computadas usando o sistema de equações obtidas de:

$$\boldsymbol{v = v.P} \quad \textbf{(Eq.1)} \qquad \boldsymbol{v_j \geq 0, \sum_j v_j = 1.} \quad \textbf{(Eq. 2)}$$

- **Exemplo 5**: **Example 7.8 (TRIVEDI, p. 352, 2002)**

6. A seguir estão as probabilidades estacionárias

$$\begin{cases} [\boldsymbol{v_0}\ ,\boldsymbol{v_1}] = [\boldsymbol{v_0}\ ,\boldsymbol{v_1}]\begin{bmatrix} \boldsymbol{p_{00}} & \boldsymbol{p_{01}} \\ \boldsymbol{p_{10}} & \boldsymbol{p_{11}} \end{bmatrix} \\ \sum_j v_j = 1. \end{cases}$$

Substituir as probabilidades pelos valores informados ao início.

$$\begin{cases} \boldsymbol{v_0 = v_0 . p_{00} + v_1 . p_{10}} \\ \boldsymbol{v_1 = v_0 . p_{01} + v_1 . p_{11}} \\ \boldsymbol{v_0 + v_1 = 1} \end{cases}$$

$$\boldsymbol{v = [v_0,\ v_1] = [\frac{1}{2}, \frac{1}{2}]}$$

Obs: É possível então ter um vetor de probabilidade de **estado estacionário** sem atender os **Teoremas 2, 3 e 4.**

- **Exemplo 6**: **Example 7.10 (TRIVEDI, p. 352, 2002)**

- Considere uma **cadeia de Markov de dois estados**, representada pelo diagrama de estados e matriz de transição ***P*** abaixo, com a condição $\mathbf{0} < \boldsymbol{a}, \boldsymbol{b} < \mathbf{1}$. Calcule então o vetor de probabilidade de estado estacionário $\boldsymbol{v}$. Note que esta cadeia é **finita, irredutível e aperiódica.**

$$P = \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}$$

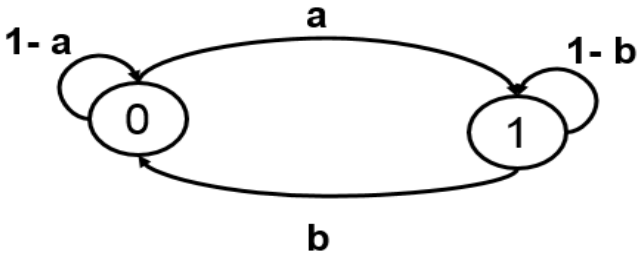

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 6**: **Example 7.10 (TRIVEDI, p. 352, 2002)**

- Veja que neste caso tem-se que $|\mathbf{1}-\boldsymbol{a}-\boldsymbol{b}|<\mathbf{1}$ e que o **Teorema 1** se aplica. Então podemos escrever:

$$\lim_{n\to\infty} P^n = \begin{bmatrix} \dfrac{b+a(1-a-b)^n}{a+b} & \dfrac{a-a(1-a-b)^n}{a+b} \\ \dfrac{b-b(1-a-b)^n}{a+b} & \dfrac{a+b(1-a-b)^n}{a+b} \end{bmatrix} = \begin{bmatrix} \dfrac{b}{a+b} & \dfrac{a}{a+b} \\ \dfrac{b}{a+b} & \dfrac{a}{a+b} \end{bmatrix} = \begin{bmatrix} v_0 & v_1 \\ v_0 & v_1 \end{bmatrix}$$

- Veja que as linhas da matriz obtida no limite **são idênticas** e cada uma delas corresponde ao **vetor de probabilidades de estado estacionário**, pois a cadeia é finita, irredutível e aperiódica. Assim, o **vetor de probabilidade de estado estacionário** é:

$$v = [v_0, v_1] = [\frac{b}{a+b}, \frac{a}{a+b}]$$

- **Exemplo 6**: **Example 7.10 (TRIVEDI, p. 352, 2002)**
- O resultado anterior pode **também** ser derivado pelo **Teorema 4**, pois a cadeia aqui é **irredutível, finita e aperiódica** (neste caso "finita" equivale a "com todos estados recorrentes não nulos" do teorema). **Então usando** $\boldsymbol{v = v.P}$ $\mathbf{(Eq.\,1)}$

$$[v_0, v_1] = [v_0, v_1]\begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix}$$

- **Ou:**

$$\begin{cases} v_0 = (1-a).v_0 + b.v_1 \\ v_1 = a.v_0 + (1-b).v_1 \end{cases}$$

$$\Downarrow$$

$$\begin{cases} a.v_0 - b.v_1 = 0 \\ -a.v_0 + b.v_1 = 0 \end{cases}$$

- **Exemplo 6**: **Example 7.10 (TRIVEDI, p. 352, 2002)**

- As **duas equações** anteriores são **linearmente dependentes**, e portanto precisamos de mais uma equação (i.e., $\boldsymbol{v_j \geq 0,\ \sum_j v_j = 1.}$ $\mathbf{Eq.\,2}$):

$$\boldsymbol{v_0 + v_1 = 1}$$

- Resolvendo o **sistema de equações**, obtemos o **vetor de probabilidade estacionária** como derivado antes:

$$\boldsymbol{[v_0, v_1] = \left[\frac{b}{a+b}, \frac{a}{a+b}\right]}$$

- **Exemplo 7**: **Example 7.11 (TRIVEDI, p. 353, 2002)**

- Considere uma **cadeia de Markov de dois estados**, representada pelo diagrama de estados e matriz de transição ***P*** abaixo. **Classifique** os estados e, ainda, **calcule** as probabilidades limites de estado**.**

$$P = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$$

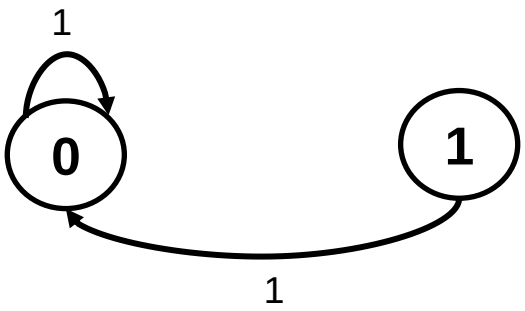

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 7**: **Example 7.11 (TRIVEDI, p. 353, 2002)**

- Como pode ser observado no diagrama de estados informado anteriormente, o estado **0** é **absorvente**. Por sua vez, o estado **1** é **transiente.**

- Tem-se que a cadeia informada não é **irredutível**, mas as probabilidades limites de estado existem (pois o **Teorema 2** se aplica e, assim, $\boldsymbol{v_j = \lim_{n\to\infty} p_j(n)}$), sendo: $\boldsymbol{v_0 = 1}$ **e** $\boldsymbol{v_1 = 0}$. Isso quer dizer que a cadeia eventualmente permanecerá no estado 0 (depois de no máximo uma transição).

- **Exemplo 8**: **Example 7.12 (TRIVEDI, p. 354, 2002)**
- Considere um modelo de um programa executando em um sistema computacional com m dispositivos I/O e uma CPU. O programa estará em um dos $m+1$ estados denotados por $0, 1, \cdots, m$, considerando que no estado 0 o programa está executando na CPU, e no estado i $(1 \leq i \leq m)$ o programa está executando uma operação de I/O no dispositivo i. Assuma que a requisição para o dispositivo i ocorra ao término de um ciclo de trabalho da CPU com probabilidade q_i, independente da história passada do programa. O programa terminará ao fim de um ciclo de trabalho da CPU com probabilidade q_0 de forma que $\sum_{i=0}^{m} q_i = 1$. Assumimos que o sistema está saturado de forma que ao término de um programa, um outro programa estatisticamente idêntico entra no sistema computacional instantaneamente. Com estas considerações, o sistema pode ser modelado como uma cadeia de Markov de tempo discreto. Responda o que se pede.

1. Apresente o **diagrama de estados.**
2. Apresente o **matriz de probabilidade de transição.**
3. Calcule o **vetor de probabilidade de estado estacionário.**

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 8**: **Example 7.12 (TRIVEDI, p. 354, 2002)**

1. Apresente o **diagrama de estados.**

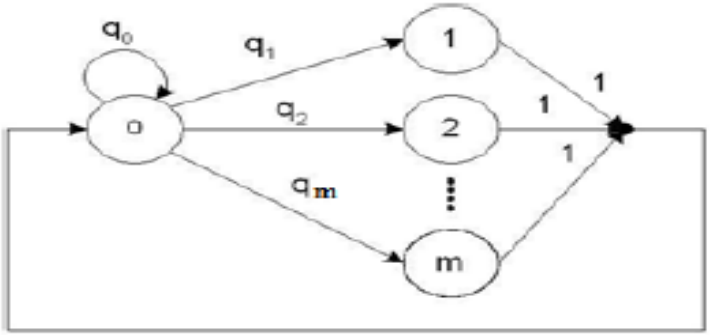

2. Apresente o **matriz de probabilidade de transição.**

$$P = \begin{bmatrix} q_0 & q_1 & \cdot & \cdot & \cdot & q_m \\ 1 & 0 & \cdot & \cdot & \cdot & 0 \\ 1 & 0 & \cdot & \cdot & \cdot & 0 \\ \vdots & \vdots & & & \vdots & \\ 1 & 0 & \cdot & \cdot & \cdot & 0 \end{bmatrix}$$

- **Exemplo 8**: **Example 7.12 (TRIVEDI, p. 354, 2002)**

3. Calcule o **vetor de probabilidade de estado estacionário.**

- Se assumimos que $\mathbf{0} < \boldsymbol{q_i} < \mathbf{1}$ $(\boldsymbol{i} = \mathbf{0}, \mathbf{1}, \cdots, \boldsymbol{m})$, então é imediato verificar que esta cadeia de Markov **finita** é irredutível e aperiódica. Portanto, o **Teorema 4** se aplica. O **vetor de probabilidade de estado estacionário** é então obtido a partir de um sistema de equações lineares, como mostrado a seguir.

$$\boldsymbol{v} = \boldsymbol{v}.\boldsymbol{P} \quad (\mathbf{Eq.\,1})$$

- Ou:

$$\begin{cases} \boldsymbol{v_0} = \boldsymbol{v_0}.\boldsymbol{q_0} + \sum_{j=1}^{m} \boldsymbol{v_j} & (\mathrm{I}) \\ \boldsymbol{v_j} = \boldsymbol{v_0}.\boldsymbol{q_j}, \qquad \boldsymbol{j} = \mathbf{1}, \mathbf{2}, \cdots, \boldsymbol{m} & (\mathrm{II}) \end{cases}$$

- Também (as eqs acima são **linearmente dependentes**): $\sum_{j=0}^{m} \boldsymbol{v_j} = \mathbf{1}$ $\quad$ $\mathbf{Eq.\,2}$ **(III)**

- **Exemplo 8**: **Example 7.12 (TRIVEDI, p. 354, 2002)**
- Substituindo **(II)** em **(III)** temos:

$$v_0 + v_0 \sum_{j=1}^{m} q_j = 1 \qquad \textbf{(IV)}$$

- Substituindo então $\sum_{j=0}^{m} q_j = 1 - q_0$ em **(IV)** temos:

$$v_0(1 + 1 - q_0) = 1$$

- Daí, finalmente: $\begin{cases} v_0 = \dfrac{1}{2-q_0} \\ v_j = \dfrac{q_j}{2-q_0}, j = 1, 2, \cdots, m \end{cases}$

- A **interpretação** é que, em um intervalo de tempo ***T***, o número médio de vistas ao estado *j* (ou o percentual de tempo médio gasto no estado ***j***) é $v_j.T$ em estado estacionário.

2.11 Distribuição de Tempo entre Mudanças de Estados

- A **história passada** de uma **cadeia de Markov homogênea** é sumarizada em **seu estado corrente.** Assuma que o estado no passo $\boldsymbol{n}$ é $\boldsymbol{X_n = i}$.

- A probabilidade de que o próximo estado seja $\boldsymbol{j}$, isto é, que $\boldsymbol{X_{n+1} = j}$, deve depender **apenas do estado corrente** $\boldsymbol{i}$ e não do tempo que a cadeia passou no estado corrente (ou seja, do tempo de permanência no estado corrente).

- Seja $\boldsymbol{T_i}$ o **tempo que a cadeia permanece no estado** $\boldsymbol{i}$. Note que, sendo uma cadeia discreta no tempo, tem-se que o tempo de permanência vai ser refletido pelo número de passos que a cadeia permanece nesse estado. Em outras palavras, $\boldsymbol{T_i}$ é igual a **um** mais o número de transições $\boldsymbol{i \to i}$ realizadas antes de sair do estado $\boldsymbol{i}$.

- Segue então que a distribuição de $\boldsymbol{T_i}$ deve ser **sem memória** para que $\{\boldsymbol{X_n} | \boldsymbol{n} = \boldsymbol{0}, \boldsymbol{1}, \cdots\}$ constitua uma **cadeia de Markov homogênea.**

- Dado que a cadeia acabou de entrar no estado $\boldsymbol{i}$ no ***n*-ésimo** passo, no **próximo passo** ela permanecerá neste estado com probabilidade $\boldsymbol{p_{ii}}$ e irá deixar este estado com probabilidade $\sum_{j \neq i} \boldsymbol{p_{ij}} = \mathbf{1} - \boldsymbol{p_{ii}}$.

- Temos então uma sequência de **ensaios de Bernoulli** com probabilidade de sucesso $\mathbf{1} - \boldsymbol{p_{ii}}$, onde sucesso é definido como o evento em que a cadeia sai do estado $\boldsymbol{i}$. O evento $\boldsymbol{T_i} = \boldsymbol{n}$ corresponde a ***n*** ensaios **até** (incluindo) o primeiro sucesso. Daí, $\boldsymbol{T_i}$ tem distribuição **geométrica**:

$$\boldsymbol{P(T_i = n) = (1 - p_{ii})p_{ii}^{n-1}, i \in I.}$$

- Usando as propriedades da **distribuição geométrica**, o **número médio** de passos que a cadeia passa no estado $\boldsymbol{i}$, por visita ao estado $\boldsymbol{i}$, é dado por:

$$\boldsymbol{E[T_i] = \frac{1}{1 - p_{ii}}, i \in I}$$

- A correspondente **variância** é:

$$\boldsymbol{Var[T_i] = \frac{p_{ii}}{(1-p_{ii})^2}, i \in I}$$

- Um "evento" é a mudança de estado, então os **sucessivos tempos entre eventos** de uma cadeia de Markov discreta no tempo são **variáveis aleatórias independentes e geometricamente distribuídas.**

2.12 Processo de Nascimento e Morte

TRIVEDI, SEÇÃO 7.8, Pag. 385

- Consideramos nesta seção um **tipo especial** de **cadeia de Markov discreta no tempo**: possui **exclusivamente** transições de um passo entre vizinhos adjacentes (ou para si próprio), com um número **infinito** de estados.
- As **transições de estado** são de apenas dois tipos: **"nascimentos",** que **aumentam** a variável de estado em **um**, e **"mortes",** que **diminuem** a variável de estado em **um**.
- A **matriz de transição** é uma **matriz tridiagonal**. Uma matriz **tridiagonal** é uma matriz quadrada cujos únicos elementos **não nulos** estão na **diagonal principal** e nas **diagonais imediatamente acima** e **abaixo da principal.** Um **sistema tridiagonal** é um sistema de equações lineares cuja matriz associada é **tridiagonal**,

2.12 Processo de Nascimento e Morte

- Para **simplificar** a notação, temos:

$$\boldsymbol{b_i = p_{i,i+1}}, \qquad \boldsymbol{i \geq 0} \text{ (probabilidade de um nascimento no estado i\}},$$

$$\boldsymbol{d_i = p_{i,i-1}}, \qquad \boldsymbol{i \geq 1} \text{ (probabilidade de uma morte no estado i\}},$$

$$\boldsymbol{a_i = p_{i,i}}, \qquad \boldsymbol{i \geq 0} \text{ (probabilidade de continuar no estado i\}}.$$

- Note que $\boldsymbol{a_i + b_i + d_i = 1}$ para todo $\boldsymbol{i}$.

- **Matriz de Transição (dimensão infinita)**

$$P = \begin{bmatrix} a_0 & b_0 & 0 & \cdot & \cdot & \cdot & & & & & \cdot & \cdots \\ d_1 & a_1 & b_1 & 0 & \cdot & \cdot & & & & & \cdot & \cdots \\ 0 & d_2 & a_2 & b_2 & 0 & \cdot & \cdot & & & & \cdot & \cdots \\ \vdots & \vdots & \vdots & & & & & & & & \vdots & \vdots \\ \vdots & \vdots & \vdots & & & & & & & & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & d_{i-1} & a_{i-1} & b_{i-1} & 0 & 0 & \cdot & \cdot & \cdots \\ 0 & 0 & 0 & \cdots & 0 & d_i & a_i & b_i & 0 & 0 & \cdot & \cdots \\ 0 & 0 & 0 & \cdots & \cdot & 0 & d_{i+1} & a_{i+1} & b_{i+1} & 0 & 0 & \cdots \\ \vdots & \vdots & \vdots & & & & & & & & \vdots & \vdots \end{bmatrix}$$

- **Diagrama de estados (infinito)**

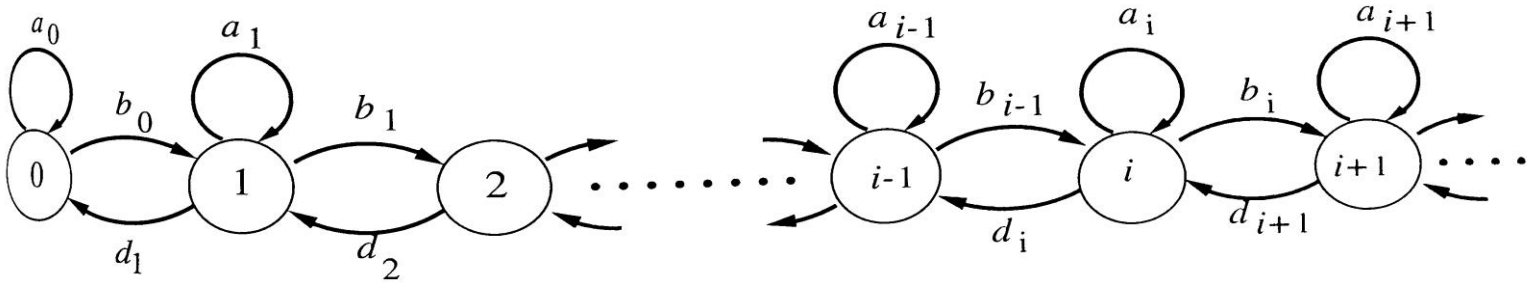

- Lembre que $(a_i + b_i + d_i) = 1$ para todo i. Se assumirmos que $b_i > 0$ e $d_i = 0$ para todo i, então **todos os estados** da cadeia de Markov são **transientes.**

- Da mesma forma, se assumirmos $b_i = 0$ and $d_i > 0$ para todo i, então **todos os estados** são **transientes**, **exceto** o estado marcado como 0, que será um estado **absorvente**.

- **Assumiremos** então que $0 < b_i, d_i < 1$ para todo $i \geq 1$ e $b_0 > 0$; portanto, a **cadeia de Markov** é **irredutível e aperiódica**, implicando pelo **Teorema 3** que as **probabilidades limites** existem e são independentes do **vetor de probabilidade inicial.**

- Para o **vetor de probabilidade de estado estacionário** v (**se existir**, i.e., todos os estados são **recorrentes não nulos**), usamos: $v = v.P$

- Usando então $v = v.P$, temos:

$$v_o = a_0.v_0 + d_1.v_1 \ (\mathrm{I})$$

$$v_i = a_i.v_i + d_{i+1}.v_{i+1} + b_{i-1}.v_{i-1}, \qquad i = 1, 2, \ldots \ (\mathrm{II})$$

- Lembre que: $a_i = 1 - b_i - d_i$ (III). Substituindo então este valor em **(II)**:

$$v_i = (1 - b_i - d_i)\,.v_i + d_{i+1}.v_{i+1} + b_{i-1}.v_{i-1}, \qquad i = 1, 2, \ldots$$

$$b_i.v_i - d_{i+1}.v_{i+1} = b_{i-1}.v_{i-1} - d_i.v_i, \qquad i = 1, 2, \ldots$$

- Este último resultado mostra então que a diferença $b_i.v_i - d_{i+1}.v_{i+1}$ é independente de i. Mas veja que $a_o + b_0 = 1 \rightarrow a_o = 1 - b_0$.
- Daí, substituindo $a_o = 1 - b_0$ em **(I)**, temos:

$$v_o = (1 - b_0).v_0 + d_1.v_1$$

$$b_o.v_0 - d_1.v_1 = 0$$

- Dado então que $\boldsymbol{b_o.v_0 - d_1.v_1 = 0}$, podemos assim concluir que a diferença: $\boldsymbol{b_i.v_i - d_{i+1}.v_{i+1} = 0, \quad i = 1, 2, \ldots}$
- Daí:

$$\boldsymbol{v_i = \frac{b_{i-1}}{d_i}.v_{i-1}, \quad i = 1, 2, \ldots}$$

$$\boldsymbol{v_i = \frac{b_{i-1}}{d_i}.\frac{b_{i-2}}{d_{i-1}}.v_{i-2}, \quad i = 1, 2, \ldots}$$

$$\boxed{\boldsymbol{v_i = \prod_{j=1}^{i} \frac{b_{j-1}}{d_j}.v_0, \quad i = 1, 2, \ldots} \quad \textbf{(IV)}}$$

- **Lembrando** a condição: $\boldsymbol{\sum_{i=0}^{\infty} v_i = 1 \longrightarrow v_0 + \sum_{i=1}^{\infty} v_i = 1}$ **(V)**

- Substituindo **(IV)** em **(V)**, temos então:

$$\boxed{v_0 = \frac{1}{\sum_{i\geq 0} \prod_{j=1}^{i} \frac{b_{j-1}}{d_j}} \qquad \textbf{(VI)}}$$

- O resultado é válido desde que a série no denominador **acima convirja.** Se a série no denominador **diverge**, então podemos concluir que **todos os estados** da cadeia de Markov são **recorrentes nulos**.
- Desprezando os índices por simplificação, para **convergir** tem-se que: **b/d < 1**, caso contrário os nascimentos estariam sempre acima das mortes e, assim, **o crescimento seria contínuo** como se houvesse um estado absorvente no infinito.
- Assumiremos que a **série é convergente**, isto é, que todos os estados são **recorrentes não nulos (e Teorema 4 se aplica)**. Daí, **(IV) e (VI)** fornecem as **probabilidades de estado estacionário.**

- **Exemplo 9**: **Example 7.15 (TRIVEDI, p. 386, 2002)**
- Considere uma estrutura de dados (tal como uma lista linear) sendo manipulada por um programa. Modele como uma **cadeia de Markov**. Suponha que estamos interessados apenas na quantidade de memória consumida pela estrutura de dados. Se a quantidade de memória em uso é $\boldsymbol{i}$ nós, então dizemos que o estado da estrutura é $\boldsymbol{s_i}$. Sejam as probabilidades associadas com a próxima operação na estrutura de dados dadas por:
- $\boldsymbol{b_i} = \boldsymbol{P}$ ("**próxima operação** é **um** $\boldsymbol{insert}$"|**estado corrente é** $\boldsymbol{s_i}$)
- $\boldsymbol{d_i} = \boldsymbol{P}$ ("**próxima operação** é **um** $\boldsymbol{delete}$"|**estado corrente é** $\boldsymbol{s_i}$)
- $\boldsymbol{a_i} = \boldsymbol{P}$ ("**próxima operação** é **um** $\boldsymbol{access}$"|**estado corrente é** $\boldsymbol{s_i}$)
- Assuma que $\boldsymbol{b_i} = \boldsymbol{b}\ (\boldsymbol{i} \geq \boldsymbol{0})$ e $\boldsymbol{d_i} = \boldsymbol{d}\ (\boldsymbol{i} \geq \boldsymbol{1})$ para todo $\boldsymbol{i}$, e que $\boldsymbol{b} < \boldsymbol{d}$ para que os estados da cadeia sejam **recorrentes não nulos** e, ainda, que há um **número infinito** de nós disponíveis para alocação. Faça o que se pede.

1. Calcule as probabilidade de **estado estacionário.**
2. Identifique a distribuição de **probabilidade (pmf) de nós alocados.**
3. Calcule o **número médio** de nós alocados em **estado estacionário.**

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 9**: **Example 7.15 (TRIVEDI, p. 386, 2002)**

1. Calcule as **probabilidade de estado estacionário**.

A cadeia é **aperiódica, irredutível e tem todos os estados recorrentes não nulos**. O **Teorema 4** então se aplica. Empregam-se a seguir as formulações de um **processo de nascimento e morte. (Vide formulações anteriores IV e VI)**

$$v_0 = \frac{1}{\sum_{i\geq 0}\prod_{j=1}^{i}\frac{b_{j-1}}{d_j}} = \frac{1}{1+\sum_{i=1}^{\infty}(\frac{b}{d})^i} = \frac{1}{1+\frac{\frac{b}{d}}{1-\frac{b}{d}}} = 1-\frac{b}{d}$$

$$v_i = \prod_{j=1}^{i}\frac{b_{j-1}}{d_j}.v_0 = \left(\frac{b}{d}\right)^i.v_0 = \left(1-\frac{b}{d}\right).\left(\frac{b}{d}\right)^i, \qquad i = 0, 1, 2, \ldots$$

obs: as formulações IV e VI somente podem ser usadas porque b < d (há convergência na série)

- **Exemplo 9**: **Example 7.15 (TRIVEDI, p. 386, 2002)**

2. Identifique a **distribuição de probabilidade** de ***V*** (nós em uso)**.**

V tem distribuição (pmf) **geométrica modificada**, com parâmetro $\mathbf{1} - \frac{\boldsymbol{b}}{\boldsymbol{d}}$

3. Calcule o **número médio** de nós em uso em estado estacionário.

$$\boldsymbol{E[V]} = \frac{\frac{\boldsymbol{b}}{\boldsymbol{d}}}{\mathbf{1} - \frac{\boldsymbol{b}}{\boldsymbol{d}}}$$

Cadeia de Markov de Tempo Contínuo

3.1 Introdução

- A **análise** das **cadeias de Markov contínuas no tempo** (Continuous-Time Markov Chains - CTMCs) é **semelhante** àquela do **caso discreto**, exceto que as **transições** de um dado estado para outro pode ocorrer a **qualquer instante de tempo**.

- Como antes, nosso estudo foca em processos de **estados discretos**. Isso implica que, embora o parâmetro t tenha um intervalo **contínuo** de valores, o conjunto de valores de $X(t)$ é discreto.

- Assuma que $I = \{0,1, 2, ...\}$ denota o **espaço de estados** do processo, e $T=[0, \infty)$ seja o seu **espaço de parâmetro**.

3.2 Definição

- Um processo estocástico contínuo no tempo de estados discretos **{*X*(*t*) | *t* ≥ 0}** é denotado **cadeia de Markov** se, para $t_0 < t_1 < \cdots < t_n < t$, com t e t_r **≥ 0 (*r* = 0, 1, ..., *n*)**, sua **pmf condicional** satisfaz a relação:

$$P(X(t) = x \mid X(t_n) = x_n, X(t_{n-1}) = x_{n-1}, \cdots, X(t_0) = x_0)$$

$$= P(X(t) = x \mid X(t_n) = x_n).$$

3.2 Definição

- O **comportamento** do processo é caracterizado pelo **(1) vetor de probabilidade de estado inicial** e **(2) probabilidades de transição:**

$$\boldsymbol{p_{ij}(v,t) = P(X(t) = j \mid X(v) = i)}$$

- Para $\mathbf{0} \leq \boldsymbol{v} \leq \boldsymbol{t}$ e $\boldsymbol{i}, \boldsymbol{j} = \mathbf{0}, \mathbf{1}, \mathbf{2}, \cdots$, onde definimos:

$$\boldsymbol{p_{ij}(t,t)} = \begin{cases} \mathbf{1}, & \textbf{se } \boldsymbol{i} = \boldsymbol{j} \\ \mathbf{0}, & \textbf{caso contrário} \end{cases}$$

3.3 Homogênea no Tempo

- A **cadeia de Markov** $\{X(t) \mid t \geq 0\}$ é dita ser **homogênea no tempo** (ou ter **probabilidades de transição estacionárias**) se $\boldsymbol{p_{ij}(v, t)}$ depende apenas da diferença de tempo $(\boldsymbol{t - v})$.

- Temos que: $$\sum_{j \in I} p_{ij}(v,t) = 1 \text{ para todo } i; 0 \leq v \leq t$$

- Temos ainda:

$$p_{ij}(t) = P(X(t+v) = j \mid X(v) = i) \quad \text{para qualquer } v \geq 0$$

- Seja a pmf de ***X(t)*** ou as **probabilidades de estado** no tempo t denotadas por:

$$\pi_j(t) = P(X(t) = j), \qquad j = 0, 1, 2, \cdots; t \geq 0.$$

- Pode-se verificar que: $$\sum_{j \in I} \pi_j(t) = 1$$

Para qualquer $t \geq 0$, pois em **qualquer tempo considerado** o processo necessariamente está em algum estado.

- **Ademais**, usando o **teorema da probabilidade total**, para $t > v$, podemos expressar as probabilidades de estado $\pi_j(t)$ em termos das probabilidades de transição $p_{ij}(v,t)$:

$$\pi_j(t) = P(X(t) = j)$$
$$= \sum_{i \in I} P(X(t) = j | X(v) = i) P(X(v) = i) = \sum_{i \in I} p_{ij}(v,t)\, \pi_i\,(v)$$

- Se fazemos v **= 0,** então: $$\pi_j(t) = \sum_{i \in I} p_{ij}(0,t)\pi_i(0)$$

- Daí, o **comportamento probabilístico** de uma **cadeia de Markov contínua no tempo** é **completamente** determinado uma vez que as **probabilidades de transição** $p_{ij}(v,t)$ e o **vetor de probabilidade inicial** $\pi_0 = [\pi_0(0), \pi_1(0)$**,...]** sejam especificados.

- **Temos ainda que** as **probabilidades de transição** de uma **cadeia de Markov contínua no tempo** satisfazem a equação de **Chapman-Kolmogorov**, que estabelece o seguinte, para todos os $i, j \in I$:

$$\boldsymbol{p_{ij}(v,t) = \sum_{k \in I} p_{ik}(v,u) p_{kj}(u,t), \qquad 0 \leq v < u < t}$$

- **Por fim**, em muitas situações temos que as probabilidades $\boldsymbol{\pi_j(t)}$ se aproximam de um limite $\boldsymbol{\pi_j}$ quando $\boldsymbol{t} \to \infty$. Essas situações são exploradas mais adiante em que o **vetor de probabilidade limite** existe.

3.4 Classificação de Estados

- A **classificação** de estados de uma **Cadeia de Markov Contínua no Tempo** é semelhante ao da **cadeia discreta no tempo**, **exceto** que não há a noção de estado **periódico/aperiódico** no caso da **cadeia contínua no tempo.**

- Um estado i é **absorvente** quando a **taxa de transição** do estado i para o estado j é igual a **zero** (i.e., $q_{ij} = 0$) para todo $j \neq i$, de forma que, uma vez tenha-se entrado no estado i, o processo ali permanece.
- Um estado j é **alcançável** a partir do estado i **se,** para algum $t > 0$, $p_{ij}(t) > 0$.
- Uma **Cadeia de Markov Contínua no Tempo** é dita **irredutível** se cada estado é **alcançável** a partir de cada outro estado.

3.5 Teorema 5 (Theorem 8.1, TRIVEDI, p. 409, 2002)

- Para uma **Cadeia de Markov Contínua no Tempo irredutível**, os **limites**

$$\pi_j = \lim_{t\to\infty} p_{ij}(t) = \lim_{t\to\infty} \pi_j(t) \qquad i,j \in I$$

Sempre existem e são **independentes** do **estado inicial** i.

3.6 Considerações

- Se as **probabilidades limites** $\boldsymbol{\pi_j}$ existem, então:

$$\lim_{t\to\infty} \frac{d\pi_j(t)}{dt} = 0$$

E podemos obter o seguinte **sistema de equações lineares homogêneas** (uma equação para **cada estado** $\boldsymbol{j}$)

$$0 = \sum_{i\neq j} \pi_i q_{ij} - \pi_j q_j$$

Esse somatório traz a **intuição** do **balanceamento de fluxo**: **o que entra é igual ao que sai de** $\boldsymbol{j}$**.**

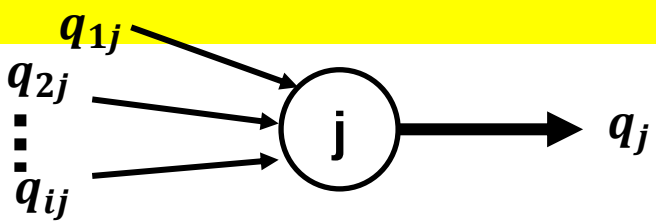

- Se definimos o **vetor de probabilidade estacionário** $\boldsymbol{\pi} = [\boldsymbol{\pi_0}, \boldsymbol{\pi_1}, \cdots]$**,** então o **somatório anterior** na forma de **matriz** se torna:

$$\boldsymbol{\pi}.\boldsymbol{Q} = \mathbf{0} \quad (\mathbf{I})$$

- $\boldsymbol{Q}$ é denominada **matriz geradora infinitesimal** da cadeia de **Markov contínua no tempo**. Ademais, note que $\boldsymbol{\pi}.\boldsymbol{Q} = \mathbf{0}$ é o correspondente **contínuo** de $\boldsymbol{v} = \boldsymbol{v}.\boldsymbol{P}$ da cadeia no **caso discreto**, visto anteriormente.

- Para o **sistema homogêneo** de equações, uma possível solução é ter $\boldsymbol{\pi_j} = \mathbf{0}$ para todo $\boldsymbol{j}$, isto é: $\boldsymbol{\pi} = [\boldsymbol{\pi_0}, \boldsymbol{\pi_1}, \cdots] = [\mathbf{0}, \mathbf{0}, \cdots]$. Para determinar uma solução única **não nula**, usamos a seguinte condição:

$$\sum_{\boldsymbol{j}} \boldsymbol{\pi_j} = \mathbf{1} \quad (\mathbf{II})$$

Esta Foto de Autor Desconhecido está licenciado em CC BY-NC-ND

- **Cadeias de Markov irredutíveis** que geram probabilidades limites positivas $\{\boldsymbol{\pi_j}\}$ são chamadas de **não-nulas recorrentes** ou **recorrentes positivas**, e as probabilidades $\{\boldsymbol{\pi_j}\}$ satisfazendo **(I)** e **(II)** são chamadas de **probabilidades de estado estacionário**.

- Sabemos que a **distribuição dos tempos** que uma cadeia homogênea de **Markov** permanece em um dado estado deve ser **sem memória**. Isso implica que os **tempos de permanência** em um estado de uma cadeia homogênea de Markov são **exponencialmente distribuídos.**

- **Em síntese:** para resolução em **estados estacionários** é preciso resolver o seguinte **sistema de equações lineares**.

$$0 = \sum_{i \neq j} \pi_i q_{ij} - \pi_j q_j \quad \Rightarrow \quad \boldsymbol{\pi}.\boldsymbol{Q} = 0 \quad (\mathrm{I})$$

$$\sum_j \pi_j = 1 \quad (\mathrm{II})$$

- Admita a notação $q_{ij} = \lambda_{ij}$; $q_j = \lambda_j$; e assuma $\lambda_j = \sum_{i=1}^{n} \lambda_{ji}$, **então**:

$$\boldsymbol{Q} = \begin{bmatrix} -\lambda_1 & \lambda_{12} & \lambda_{13} & \cdots & \lambda_{1n} \\ \lambda_{21} & -\lambda_2 & \lambda_{23} & \cdots & \lambda_{2n} \\ \lambda_{31} & \lambda_{32} & -\lambda_3 & \cdots & \lambda_{3n} \\ \vdots & \vdots & & \ddots & \vdots \\ \lambda_{n1} & \lambda_{n2} & \cdots & & -\lambda_n \end{bmatrix}$$

* O que entra = o que sai

- A seguir são apresentados exemplos envolvendo **Cadeias de Markov Contínuas no Tempo.**

- **Exemplo 9**: **Seção 8.2 (TRIVEDI, p. 412, 2002)**

- Uma cadeia homogênea de Markov contínua no tempo $\{X(t)|t \geq 0\}$ com espaço de estados $\{0, 1, 2, \cdots\}$ é conhecida como **processo de nascimento e morte** se existem constantes λ_i $(i = 0, 1, \cdots)$ e μ_i $(i = 1, 2, \cdots\}$ tal que as **taxas de transição** são dadas por:

$$q_{i,i+1} = \lambda_i$$

$$q_{i,i-1} = \mu_i$$

$$q_i = \lambda_i + \mu_i$$

$$q_{ij} = 0 \text{ para } |i - j| > 1$$

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 9**: **Seção 8.2 (TRIVEDI, p. 412, 2002)**

- A taxa de nascimento $\boldsymbol{\lambda_i}$ $(\geq \mathbf{0})$ é a taxa na qual nascimentos ocorrem no estado $\boldsymbol{i}$, e a taxa de mortes $\boldsymbol{\mu_i}(\geq \mathbf{0})$ é a taxa com que mortes ocorrem no estado $\boldsymbol{i}$.
- Estas taxas são assumidas depender apenas do estado $\boldsymbol{i}$ e são independentes do instante de tempo. Note que **apenas transições entre estados vizinhos (adjacentes, mais próximos) são permitidas**. Em um dado estado, nascimentos e mortes ocorrem **independentemente entre si.**
- Este processo é um modelo útil em muitas situações em **teoria de filas** e teoria da confiabilidade.

1. Apresente o **diagrama de estados do processo** e **diferencie-o** daquele do caso discreto,

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 9**: **Seção 8.2 (TRIVEDI, p. 412, 2002)**

1. Apresente o **diagrama de estados** do processo e **diferencie-o** daquele do caso discreto,

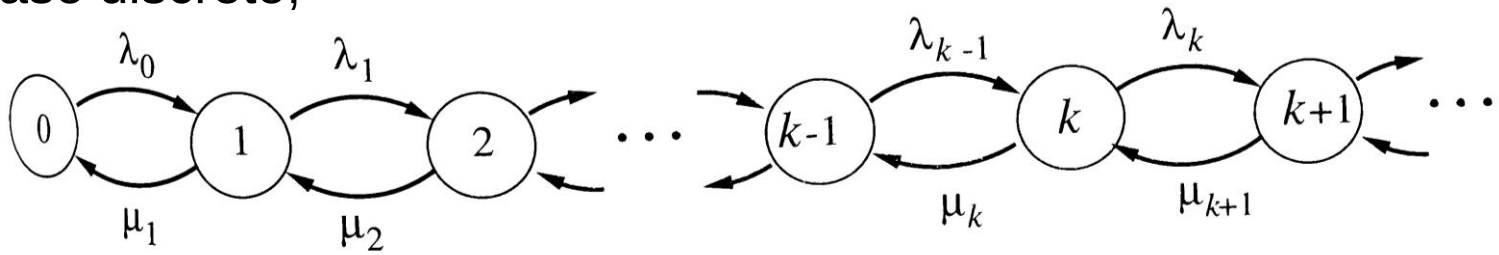

- Deve-se observar **a diferença** entre este diagrama de estados (**contínuo**) e aquele diagrama de estados relacionado à cadeia de Markov **discreta** no tempo, visto anteriormente.
- No **caso discreto**, os arcos entre os estados são rotulados com **probabilidades condicionais**. No **caso contínuo**, os arcos são rotulados com as **taxas de transição** entre estados, daí a denominação **diagrama de transição de estados.**

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

- Considere um **sistema de fila de um único servidor** como mostrado na figura abaixo.

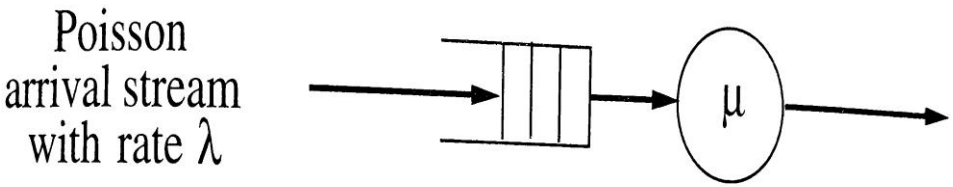

- As **chegadas dos clientes** constituem um processo de **Poisson** com **taxa** λ **.** Equivalentemente os tempos entre chegadas são exponencialmente distribuídos com **média** $\frac{1}{\lambda}$. Os tempo de serviço dos clientes são variáveis aleatórias independentes e identicamente distribuídas, sendo a distribuição comum **exponencial com média** $\frac{1}{\mu}$**.**

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**
- Os clientes são servidos na **ordem de chegada** (disciplina FIFO). Se o cliente é um **job (trabalho)** chegando ao sistema computacional, então o servidor representa o sistema computacional. Sob uma outra interpretação da **Fila M/M/1**, o cliente pode representar uma mensagem e o servidor um canal de comunicação. (obs: Fila de tamanho infinito.)
- Seja $\boldsymbol{N(t)}$ o número de clientes no sistema (clientes na fila mais o cliente em serviço) no tempo $\boldsymbol{t}$. $\{\boldsymbol{N(t)} \mid \boldsymbol{t} \geq \mathbf{0}\}$ é então um processo de **nascimento e morte** com: $\boldsymbol{\lambda_k} = \boldsymbol{\lambda}, \text{para } \boldsymbol{k} \geq \mathbf{0}$; $\boldsymbol{\mu_k} = \boldsymbol{\mu}, \text{ para } \boldsymbol{k} \geq \mathbf{1}$.
- O **raio (razão)** $\boldsymbol{\rho} = \frac{\boldsymbol{\lambda}}{\boldsymbol{\mu}}$ é chamado de **intensidade de tráfego.**

1. Calcule as probabilidades de estado estacionário $\boldsymbol{\pi_k}, \text{para } \boldsymbol{k} = \mathbf{0}, \mathbf{1}, \ldots$.
2. Discuta a estabilidade do sistema com base na intensidade de tráfego.
3. Calcule o número médio de clientes e discuta as fórmulas de Little.

TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

1. Calcule as probabilidades de **estado estacionário** $\boldsymbol{\pi_k}$, para $\boldsymbol{k = 0, 1, \ldots}$.

- A partir das **seguintes formulações**:

$$\begin{cases} \mathbf{0} = \sum_{i \neq j} \boldsymbol{\pi_i q_{ij} - \pi_j q_j} \Rightarrow \boldsymbol{\pi . Q = 0} \quad \textbf{(I)} \\ \sum_j \boldsymbol{\pi_j = 1} \quad \textbf{(II)} \end{cases}$$

* O que entra = o que sai

- E lembrando: $\boldsymbol{q_{ij} = \lambda_{ij}}$; $\boldsymbol{q_j = \lambda_j}$; $\boldsymbol{\lambda_j = \sum_{i=1}^{n} \lambda_{ji}}$, além das condições impostas nesta questão, temos então o seguinte **sistema de equações**:

$$\begin{cases} \text{• } \textit{Estado } 0: \quad \boldsymbol{\lambda . \pi_0 = \mu . \pi_1} \\ \text{• } \textit{Estado } 1: \quad \boldsymbol{\lambda . \pi_0 + \mu . \pi_2 = (\lambda + \mu) . \pi_1} \end{cases}$$

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

- **Continuação:**

- *Estado* 0: $\lambda.\pi_0 = \mu.\pi_1$ **(i)**
- *Estado* 1: $\lambda.\pi_0 + \mu.\pi_2 = (\lambda + \mu).\pi_1 \longrightarrow \pi_2 = \frac{\lambda^2}{\mu^2}.\pi_0$ **(ii)**
- *Estado k*: $\pi_k = \left(\frac{\lambda}{\mu}\right)^k.\pi_0,$ para k = 0, 1, ... **(iii)**

- São equações **linearmente dependentes**. Para resolver, **adicionamos** a condição:

$$\sum_{k=0}^{\infty} \pi_k = 1 \longrightarrow \pi_0 + \sum_{k=1}^{\infty} \pi_k = 1 \qquad \textbf{(iv)}$$

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**
- **Continuação:**
- Substituindo **(iii)** em **(iv),** temos:

$$\pi_0 + \sum_{k=1}^{\infty} \left(\frac{\lambda}{\mu}\right)^k . \pi_0 = 1 \quad \longrightarrow \quad \pi_0 . \left(1 + \sum_{k=1}^{\infty} \left(\frac{\lambda}{\mu}\right)^k\right) = 1$$

- **Se** $\rho = \frac{\lambda}{\mu} < 1,$ então o **somatório** converge e:

$$\pi_0 = \frac{1}{1 + \frac{\lambda/\mu}{1 - \lambda/\mu}} = 1 - \frac{\lambda}{\mu} \qquad \textbf{(v)}$$

- Substituindo **(v)** em **(iii),** temos: $\boxed{\pi_k = \left(1 - \lambda/\mu\right) . \left(\frac{\lambda}{\mu}\right)^k}$

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**
- **Continuação:**

$$\pi_k = \left(1 - \lambda/\mu\right).\left(\frac{\lambda}{\mu}\right)^k$$

- Note que **o vetor de probabilidade se refere à** uma variável **geométrica modificada** de parâmetro $1 - \lambda/\mu$. Daí, a distribuição da fila em **estado estacionário** é **geométrica modificada** de parâmetro $1 - \lambda/\mu$.

- Em síntese, para um sistema estável (i.e., $\rho = \frac{\lambda}{\mu} < 1$), as **probabilidades de estado estacionário** constituem uma pmf **geométrica modificada de parâmetro $1 - \rho$.**

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

2. Discuta a estabilidade do sistema com base na **intensidade de tráfego**.

- A intensidade de tráfego $\boldsymbol{\rho} = \frac{\boldsymbol{\lambda}}{\boldsymbol{\mu}} \geq \mathbf{1}$ implica que a taxa de chegada $\boldsymbol{\lambda}$ excede a taxa de serviço $\boldsymbol{\mu}$. Nesta situação, o somatório (até **infinito**) no denominador da expressão obtida **diverge.**
- No caso de $\boldsymbol{\rho} > 1$, todos os **estados** da cadeia de Markov Contínua no Tempo são **transientes**, e se $\boldsymbol{\rho} = 1$, todos os estados dessa cadeia são **recorrentes nulos**. Daí, em ambos casos, o número de clientes no sistema tende **a aumentar sem limites.** Tal sistema é denominado **instável.**
- Para um **sistema estável** $\boldsymbol{\rho} < 1$, vemos então, conforme formulações anteriores, que as **probabilidades de estado estacionário** deste sistema (cadeia **infinita**) constituem então uma pmf geométrica modificada com parâmetro $\mathbf{1} - \boldsymbol{\rho}$.

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

2. Discuta a estabilidade do sistema com base na **intensidade de tráfego**.

- Agora, relembrando o **Teorema 5** (e considerações postas), a resolução em estado estacionário, usando os resultados **(I)** e **(II),** admite que a cadeia **irredutível contínua** no tempo seja **recorrente não nula** ou **recorrente positiva**. Ante o **sistema fila aqui examinado**, temos:

- No caso da cadeia **infinita**, impusemos a condição $\rho < 1$ para ter a convergência do somatório.
- Mas, se a cadeia é **finita**, a condição $\rho < 1$ desaparece. Em verdade, uma cadeia de Markov **finita** irredutível contínua no tempo é sempre **recorrente positiva**.

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

2. Discuta a estabilidade do sistema com base na **intensidade de tráfego**.

- A **intensidade de tráfego** também representa **neste caso** a utilização do servidor: $U_0 = 1 - \pi_0 = \rho = \lambda/\mu$, sendo interpretada como a **proporção do tempo** em que o servidor está ocupado.

- Uma outra maneira de observar esse resultado, é considerar a seguinte formulação para a **utilização do servidor**: **probabilidade de haver alguém no sistema?** Assim:

$$\rho = \sum_{k=1}^{\infty} \pi_k = 1 - \pi_0 = 1 - \left(1 - \lambda/\mu\right) = \lambda/\mu$$

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

3. Calcule o número médio de clientes e discuta as fórmulas de Little.

- Neste caso, como visto, o número médio de clientes no sistema (clientes na fila aguardando serviço mais aquele que está sendo servido) corresponde à média de uma **variável aleatória geométrica modificada**, com parâmetro $\mathbf{1-\rho}$. Seja **N** esta variável, então:

$$\boldsymbol{E[N] = \frac{\lambda/\mu}{1-\lambda/\mu}}$$

- **Exemplo 10**: **Seção 8.2.1 (TRIVEDI, p. 415, 2002) - Fila M/M/1**

3. Calcule o número médio de clientes e discuta as fórmulas de Little.

- Seja ***T*** tempo médio de permanência no sistema. A **fórmula de Little** estabelece então que:

$$E[N] = \lambda . E[T]$$

- Daí:

$$E[T] = \frac{E[N]}{\lambda} = \frac{1/\mu}{1 - \lambda/\mu}$$

Obs: É o mesmo resultado do slide anterior

- **Extraclasse:** Derive o tempo médio de espera na fila, **W,** e o número médio de clientes na fila (aguardando serviço), **L**. Por fim, compare com os resultados **apresentados na literatura** (no módulo visto de filas).

Fundamentos da Simulação

- Definição
- Erros comuns
- Terminologia
- Escolha da linguagem
- Tipos de simulação
- Simulação de eventos discretos

4.1 Definição

- A **simulação** é uma técnica útil para **análise de desempenho** de sistemas computacionais (neste nosso caso, as **redes de computadores**).

- Se o sistema a ser caracterizado **não** está disponível, como é caso durante a fase de projeto ou aquisição, um **modelo de simulação** provê uma **maneira prática** de **prever o desempenho ou comparar alternativas.**

- **Além disso**, mesmo que o sistema esteja disponível para **medição**, um modelo de **simulação** pode ser escolhido em vez da **medição** por permitir que **as alternativas sejam comparadas sob diferentes cargas e ambientes.**

4.2 Erros comuns em simulação

1. **Nível inadequado de detalhamento**: Um modelo **analítico** é menos detalhado que um modelo de **simulação**. Mas é preciso ter equilíbrio: nem pouco nem muito, apenas o **suficiente**. É recomendável começar com o modelo **menos detalhado**, obter alguns resultados, estudar a sensibilidade e, então, introduzir progressivamente **mais detalhes**.

2. **Linguagem (ferramenta) de programação inapropriada.** O desenvolvedor deve escolher a **linguagem (ferramenta) correta.**

3. **Modelos que não são verificados ou inválidos.** Os modelos de simulação usualmente são **complexos**. É preciso ter a estratégia correta para garantir que o modelo **não tem erro** de programação (i.e., são **verificados**) e **representam** o sistema (i.e., são **válidos**).

4. **Não tratamento da fase transiente**: a **parte inicial da simulação** geralmente não é representativa do comportamento do sistema em **estado estacionário**. Essa parte inicial deve então **ser descartada** ou devidamente tratada.

5. **Simulações muito curtas:** Resultados de simulações **muito curtas** não representam **a realidade**. A definição do tempo de simulação depende da precisão desejada (**largura dos intervalos de confiança**) e da **variância** dos valores medidos.

6. **Inadequados geradores de números aleatórios**: modelos de simulação exigem **quantidades aleatórias** na entrada. É melhor usar um gerador já conhecido na literatura do que tentar criar um. Neste contexto, é preciso ter cuidado com a escolha da chamada **semente do gerador**.

4.3 Terminologia

Há **alguns termos** que são usualmente utilizados na atividade de **modelagem.**

1. **Variáveis de Estado:** as variáveis cujos valores definem o estado do sistema. Por exemplo, o número médio de jobs no servidor.

2. **Evento:** uma mudança no estado do sistema é chamada de um evento. Por exemplo, a chegada de um job no servidor.

3. **Modelos de tempo discreto e modelos de tempo contínuo**: um modelo no qual o estado do sistema é definido em todos os instantes de tempo é chamado de modelo de **tempo contínuo**. Um modelo no qual o estado do sistema é definido apenas em instantes específicos é chamado de modelo de **tempo discreto**.

4. **Modelos de estado discreto e modelos de estado contínuo:** um modelo de **estado contínuo** implica que a **variável aleatória** que define o estado é **contínua.** Um modelo de **estado discreto** implica que a **variável aleatória** que define o estado é **discreta.**

- **Obs**: Um modelo de **estado discreto** é também chamado de **modelo de evento discreto**. Um modelo de **estado contínuo** também é chamado de **modelo de evento contínuo.**

5. **Modelos probabilísticos e modelos determinísticos:** se a saída (resultados) puder ser determinada com **exatidão (nunca muda)**, então tem-se um **modelo determinístico.** Já um modelo **probabilístico** pode fornecer uma **saída (resultados) diferente** mesmo que a entrada não mude.

6. **Modelo estático e modelo dinâmico:** um modelo no qual o **tempo** não é considerado é chamado **estático**. Neste caso o estado do sistema **não muda com o tempo**. Por exemplo, um modelo de transformação de matéria em energia: $E = m.c^2$. Todavia, se o estado do sistema **muda com o tempo**, então o **modelo é dinâmico**. Por exemplo, o número de jobs no servidor.

7. **Modelos lineares e modelos não lineares:** se a saída é uma função linear da entrada, então o **modelo é linear**. Caso contrário, o **modelo é não linear.**

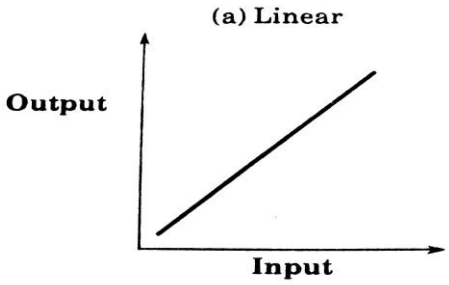

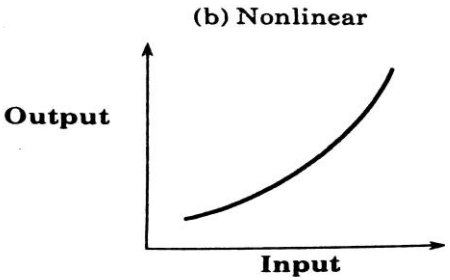

8. **Modelos abertos e modelos fechados:** se a entrada é externa ao modelo e é independente do mesmo, então o modelo é **aberto**. Em um modelo f**echado**, não há entrada externa.

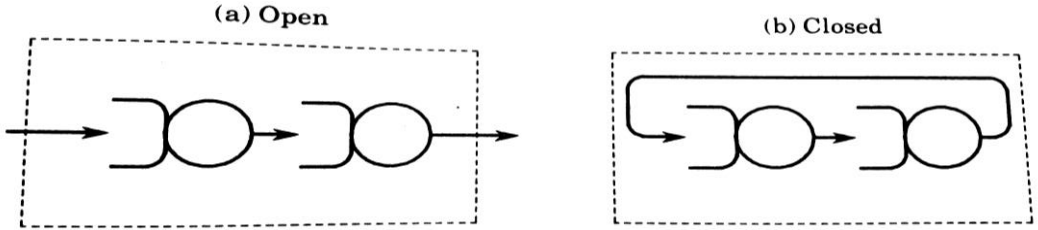

9. **Modelos estáveis e não estáveis:** se o comportamento dinâmico do modelo converge para um **estado estacionário**, i.e., independente do tempo, é chamado **estável**. Um modelo cujo comportamento está **continuamente mudando** é chamado **instável**.

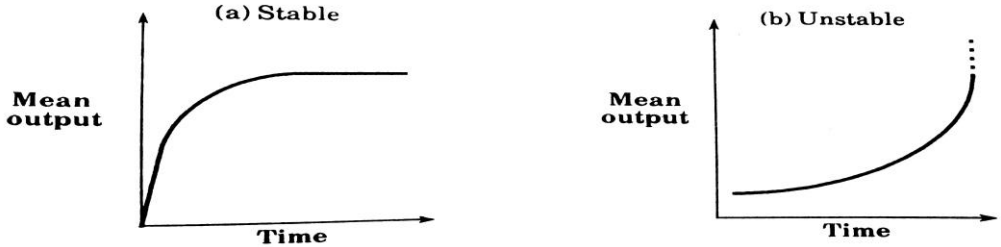

- **Modelos de sistemas computacionais são usualmente:**
  - **Tempo contínuo**
  - **Estado discreto**
  - **Probabilístico**
  - **Dinâmico**
  - **Não linear**

- **Alguns são abertos, outros são fechados.**

- **Alguns são estáveis, outros são instáveis.**

4.4 Escolha da Linguagem

- Escolher a **linguagem apropriada** é provavelmente o passo mais importante no processo de desenvolvimento de um **modelo de simulação**.

- Uma **decisão incorreta** nesse momento pode levar a **longos tempos** de desenvolvimento, **estudos incompletos**, e **fracassos.**

- Há **quatro opções**, cada uma tem suas vantagens e desvantagens:

1. Uma **linguagem de simulação** (especializada)
2. Uma **linguagem de propósito geral**
3. Uma **extensão** de uma linguagem de propósito geral
4. Um **pacote de simulação*** (um simulador, ferramenta, ambiente, resolvedor, network solvers, etc.)

4.4.1 Linguagem de simulação

- Linguagens **de simulação** como **Simula** e **SIMSCRIPT** **economizam considerável tempo de desenvolvimento do modelo.**
- As linguagens de simulações possuem **facilidades intrínsecas** (*built-in facilities*) para avanço do tempo, escalonamento de eventos, manipulação de entidades, geração de números aleatórios, dentre outras.
- Essas linguagens permitem **investir mais tempo em questões específicas do sistema** que está sendo modelado, e não se preocupar com questões que são comuns em todas as simulações.
- Também possibilitam a escrita de um **código modular** bem inteligível e fornecem **boa detecção** (depuração, *debugging*) **de erros**.

https://en.wikipedia.org/wiki/Simula

https://en.wikipedia.org/wiki/SIMSCRIPT

4.4.2 Linguagem de propósito geral

- Um **linguagem de propósito geral** como Pascal, C, Java ou FORTRAN é a primeira opção de escolha quando se possui **grande familiaridade** com ela.
- Muitos profissionais **não têm conhecimento** ou **familiaridade** com **linguagens de simulação**.
- Muitas das vezes também **não há tempo hábil**, em virtude de prazos a serem cumpridos, para estudar e aprender **linguagens de simulação.**
- Muitas das vezes **as linguagens de simulação** também podem **não estar facilmente disponíveis** para instalação nos equipamentos que estão sendo utilizados para o desenvolvimento dos modelos.

- **Idealmente**, para **DECIDIR** entre **linguagem de simulação** e **linguagem de propósito geral**, o recomendável seria:

- O profissional deveria **aprender** ao menos **uma linguagem de simulação** para que, além da **familiaridade com a linguagem de propósito geral**, **outros critérios** pudessem ser utilizados **na decisão.**

- **Ou sej**a, conheça os **dois tipos** para escolher o melhor para o seu projeto!

4.4.3 Extensão

- Uma **extensão** de uma linguagem de propósito geral como **GASP** (para FORTRAN) é uma outra alternativa.

- Estas extensões consistem de uma **coleção de rotinas** para **manipular tarefas** que são comumente requeridas em **simulações.**

- O objetivo dessas rotinas é prover um **compromisso** entre eficiência, flexibilidade e portabilidade (ofertadas pela **linguagem de propósito geral**) e, simultaneamente, evitar também a **perda de tempo** com desenvolvimento de rotinas comuns exigidas nas simulações (ofertada pelas **linguagens de simulação**). Busca-se assim capturar **o melhor dos dois mundos.**

https://en.wikipedia.org/wiki/GASP_(simulation_language)

4.4.4 Pacote de Simulação

- Um pacote de simulação (como pacotes: **QNET4** e **RESQ)** permite o **desenvolvimento de modelos de simulação** por meio de **interfaces textuais e/ou gráficas.**
- Estes pacotes possuem **inúmeras bibliotecas de estruturas de dados, rotinas e algoritmos.**
- A **grande vantagem é o tempo economizad**o. É possível desenvolver um modelo, resolvê-lo e obter os resultados em um dia de trabalho.
- Desenvolver um modelo de simulação **usando uma linguagem**, por outro lado, pode **levar alguns dias (ou meses)** de trabalho, dependendo da complexidade do sistema.
- A grande desvantagem é a **inflexibilidade.** Todo pacote **tem limitações** quanto aos tipos de modelos que podem ser desenvolvidos.

https://researcher.watson.ibm.com/researcher/view_group_subpage.php?id=4517
https://ieeexplore.ieee.org/document/1146049

4.5 Tipos de Simulação

- Dentre os vários **tipos de simulação** existentes, aquelas usualmente de maior interesse para a **área de sistemas computacionais** são:

1. **Emulação**
2. **Monte Carlo**
3. **Trace-Driven**
4. **Evento Discreto**

4.5.1 Emulação

- De maneira sintética, uma **simulação** baseada em **hardware** ou **firmware** é chamada de **emulação.**
- Um **emulador de terminal**, por exemplo, simula um **tipo de terminal em um outro terminal.**
- Um emulador de **processador** simula o **conjunto de instruções** de um processador em **outro processador.**
- As **questões de projeto** da emulação estão em sua maioria relacionadas a questões **de projeto de hardware.**

https://pt.wikipedia.org/wiki/Firmware

https://www.gta.ufrj.br/grad/09_1/versao-final/virtualizacao/cinco%20perguntas.html

4.5.2 Monte Carlo

- Uma **simulação estática** ou uma sem **um eixo de tempo** é chamada de simulação de **Monte Carlo.**

- Tais simulações são usadas para modelar **fenômenos probabilísticos que não mudam suas características com o tempo**.

- Como em uma simulação dinâmica, é necessária também a geração de números pseudoaleatórios (ou aleatórios).

- **Simulações de Monte Carlo** podem ser também usadas para avaliar expressões **não probabilísticas** usando **métodos probabilísticos**.

4.5.3 Trace-Driven

- Uma simulação usando um **trace** como **entrada** é uma **simulação trace-driven.**

- **Trace** é um **registro ordenado no tempo** de eventos no sistema real.

- Normalmente são simulações usadas para **sintonia (ajuste) ou análise de algoritmos de gerência de recursos.**

- Por exemplo, para a **análise algoritmos de compartilhamento de fluxos** em sistemas de VoD, considerando **uma largura de banda de rede limitada**. O **trace** poderia ser, por exemplo, o **padrão de acesso** (ações de interatividade durante a reprodução do filme) dos usuários que acessam o servidor de VoD.

https://en.wikipedia.org/wiki/Trace-based_simulation

4.5.4 Evento Discreto

- Uma simulação usando um **modelo de estado discreto** do sistema é chamada de **simulação de evento discreto**.

- Esta simulação de **evento discreto** é oposta à simulação de **evento contínuo;** nesta última o estado do sistema assume **valores contínuos.**

- Note que o termo **DISCRETO** não se aplica aos **valores de tempo** usados na simulação, mas sim aos **estados**. Assim, uma simulação de **evento DISCRETO** pode usar **valores de tempo contínuos ou discretos.**

Agora nosso foco neste módulo é

SIMULAÇÃO DE EVENTOS DISCRETOS

4.6 Simulação de Eventos Discretos

- É uma **técnica de modelagem** que visa à **representação do comportamento do sistema** para obtenção de **medidas de desempenho e/ou confiabilidade.**

- O **sistema** é representado por meio de **eventos** que ocorrem segundo uma **distribuição de probabilidade.**

- Daí a i**mportância** do conhecimento de **variáveis aleatórias.**

4.7 Ciclo de Modelagem

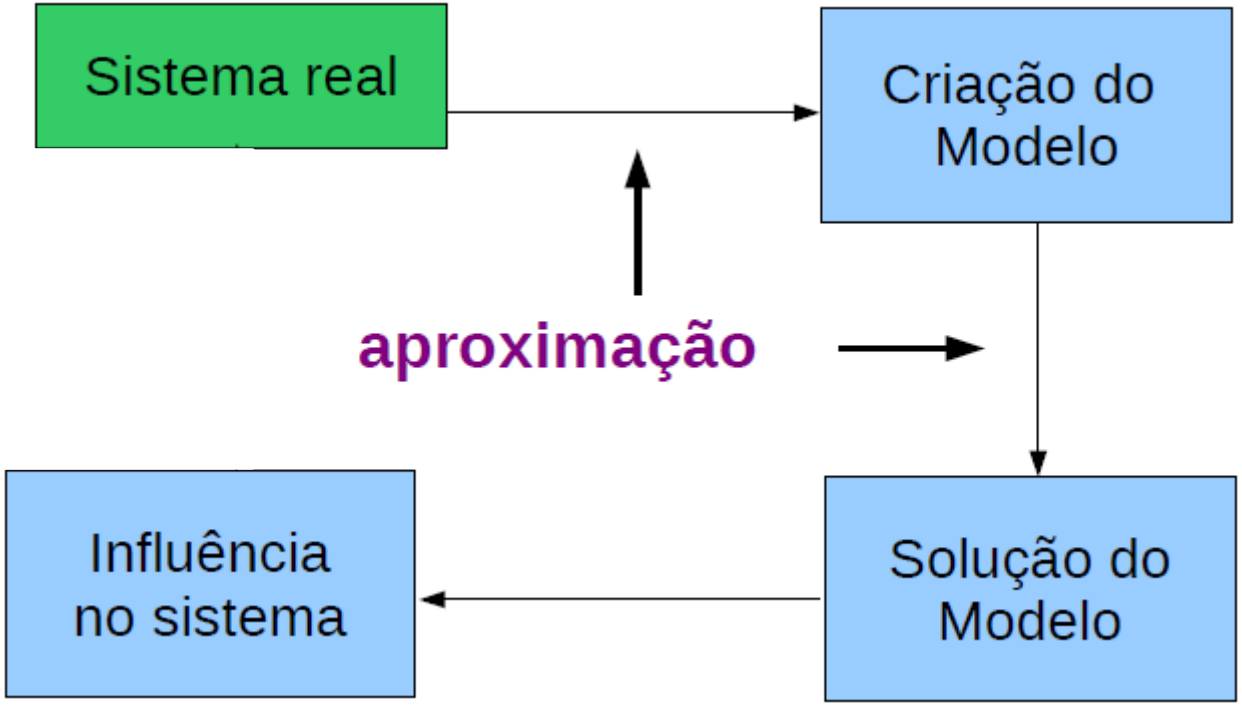

4.8 Modelando um Sistema: Exemplo

- Abstração do sistema
- Simplificação necessária
- Representação matemática do sistema
- Aleatoriedade

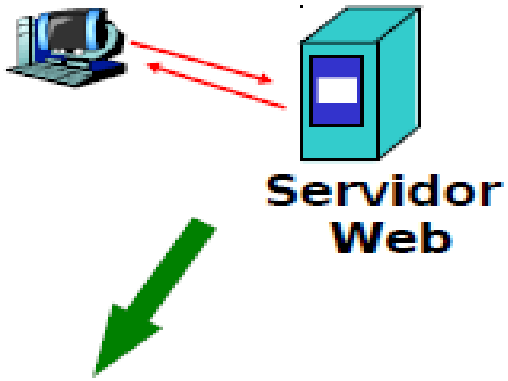

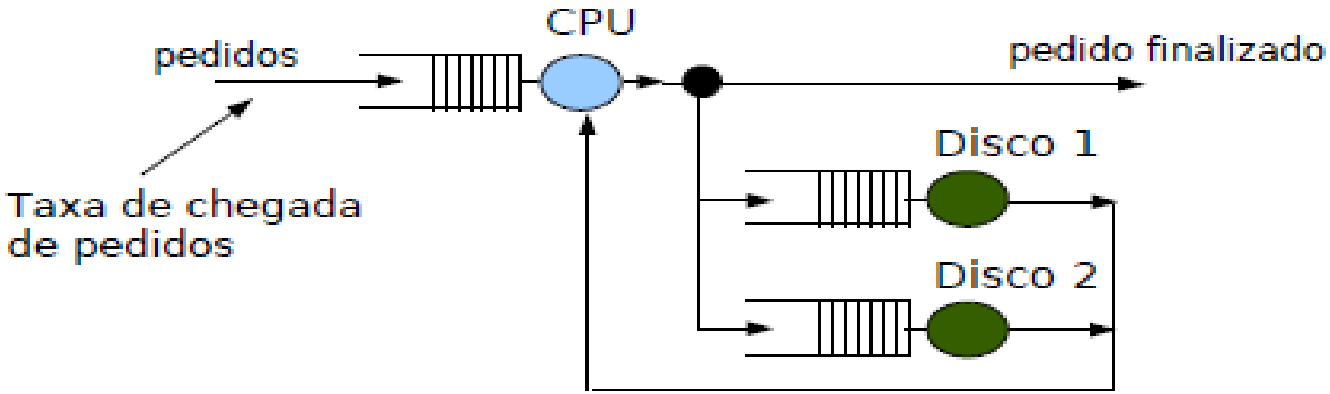

4.9 Medidas de Desempenho

- **Vazão de um recurso**: número de processos servidos por unidade de tempo.
- **Utilização de um recurso**: percentual do tempo que o recurso fica ocupado.
- **Número médio** de processos na fila do recurso.
- **Tempo médio** que cada processo fica na fila do recurso.
- **Outras.**

4.10 Conhecimentos Básicos para Simular

- **Geração de Variáveis Aleatórias**
- **Descrição do comportamento do sistema**
- **Análise estatística dos resultados**

4.10.1 Geração de Variáveis Aleatórias

- Como **gerar números aleatórios** (**pseudoaleatórios**: que parecem aleatórios)? É o **alicerce** para a geração da **variáveis aleatórias.**
- **Ideia básica**: Usa-se **um algoritmo** que gera uma **sequência de números** inteiros **U1, U2, ...,** que **parecem** ser: (i) **uniformemente distribuídos** no intervalo [0, M-1], para algum **M,** e (ii) **Estatisticamente independentes**.
- A **sequência de números** deve ter propriedades relevantes de sequência de **v.a. uniforme**. Métodos, e.g.: **Congruente** e **Congruente Linear**.
- **Na prática, as linguagens de programação** têm geradores implementados. **Ex: drand48(), erand48(),... em C/C++.**
- Para a **geração de v.a,** a partir dos nrs. aleatórios**,** tem-se então, e.g., os métodos: **Transformada Inversa (v.a contínua) e Rejeição (v.a. discreta e contínua).**

https://en.wikipedia.org/wiki/Random_number_generation

4.10.2 Descrição do comportamento

- **Procedimentos (algoritmos)** devem ser descritos para refletir o **comportamento** do **sistema**. Os procedimentos são executados conforme ocorram os **eventos**. Naturalmente a **descrição** depende do sistema em si a ser simulado.
- **Por exemplo**: Um sistema representado por **uma fila**. O que precisamos considerar para essa descrição?
- **Resposta**: Processo de chegada de jobs, tempo de serviço, capacidade da fila, política de atendimento, parâmetros das v.a., estado inicial do sistema, instantes de mudanças de estado (chegadas e saídas de jobs), medidas de interesse, etc.
- A **escolha da linguagem de simulação** deve ser criteriosamente realizada para tornar a descrição a **mais correta e prática possível**.

4.10.3 Análise Estatística dos Resultados

- Os **valores numéricos** obtidos para as medidas e interesse estão adequados? São **confiáveis**?
- Existem **duas formas** de organizar as simulações: **1)** método das **replicações independentes** e **2**) método de **uma única execução**.
- 1) Método das **replicações independentes:** executa-se a replicação (rodada) ***n* vezes**, e em cada uma das vezes coleto ***m* amostras**. Ao final, devo calcular a **média** (das médias) e a **variância** associada.
- 2) Método de uma **única execução:** devo ter um total de ***n*** grupos de ***m*** valores considerando **uma única sequência** (replicação) realizada.
- Os valores de ***n*** e ***m*** vão ser determinados em função da **variância** (calculada), **largura do intervalo de confiança** e da **probabilidade de estar no intervalo** (arbitrados), podendo ser **aumentados se desejado**.

https://en.wikipedia.org/wiki/Confidence_interval

Replicações Independentes

- Execução 1 → $X_1 = 1/m \sum_{j=1}^{m} X_{1j}$
- Execução 2 → $X_2 = 1/m \sum_{j=1}^{m} X_{2j}$
- Execução n → $X_n = 1/m \sum_{j=1}^{m} X_{nj}$

Única Execução

$$\underbrace{X_{11} \ldots X_{1m}}_{X_1} \quad \underbrace{X_{21} \ldots X_{2m}}_{X_2} \quad \ldots \quad \underbrace{X_{n1} \ldots X_{nm}}_{X_n}$$

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i \qquad s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X}_n)^2$$

5. Síntese Final

- Este módulo apresentou **brevemente** o tema **Cadeia de Markov e Simulação**

- O tema foi desenvolvido sob o enfoque geral de **Avaliação de Desempenho de Redes.**

- Os slides desta aula estão disponíveis em **www.carlokleber.shorturl.com**

- A **lista de exercícios**, disponível no site acima, propicia a oportunidade de praticar, complementar e fixar o conteúdo ministrado.

Prática e Estudo Individual

Acesse o MOODLE tempestivamente, acesse a aba atividades e realize a atividade prevista.

Referências

- HILLIER, F. S.; LIEBERMAN, G. Introdução à Pesquisa Operacional. 8ª ed. São Paulo: McGraw Hill, 2006. 852p.
- TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.
- ROSS, S. M. Stochastic processes. 2nd ed. New York: John Wiley & Sons, 1996. 510p.
- Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/
- Leão, R. M. M (2015). “Estatística e Modelos Probabilísticos”, Notas de aula. Online http://www.land.ufrj.br/~classes/est-prob-2015/
- H. Pishro-Nik, "Introduction to probability, statistics, and random processes", available at https://www.probabilitycourse.com, Kappa Research LLC, 2014.
- Joseane Farias et al. Simulador de Redes IP. https://www.researchgate.net/publication/255645154_QNet_-_Um_Simulador_Grafico_de_Trafego_IP_para_Redes_Convergentes

Fim

Prof. Carlo Kleber da Silva Rodrigues
carlo.kleber@ufabc.edu.br