Avaliação de Desempenho de Redes

MCZA004-13

Inferência Estatística e Resultados de Simulação

Prof. Carlo Kleber
carlo.kleber@ufabc.edu.br

Sumário

1. Introdução
2. Inferência Estatística
3. Resultados de Simulação
4. Síntese final

Parte Prática

Referências

Apêndices

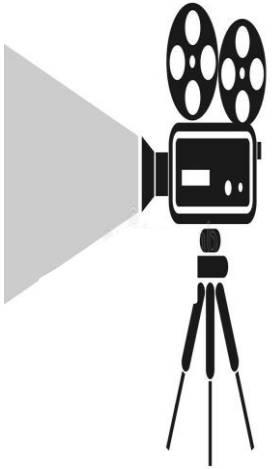

1. Introdução

- Neste módulo temos então os seguintes dois grandes objetivos:

- **Discutir** Inferência Estatística
- **Discutir** Resultados de Simulação

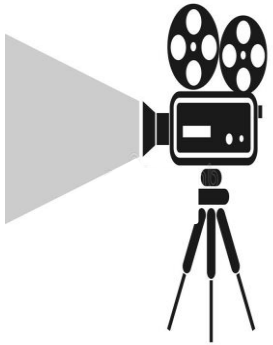

2. Inferência Estatística

Fontes principais:

- **Cap 10 Trivedi**
- **Cap 13 Jain**

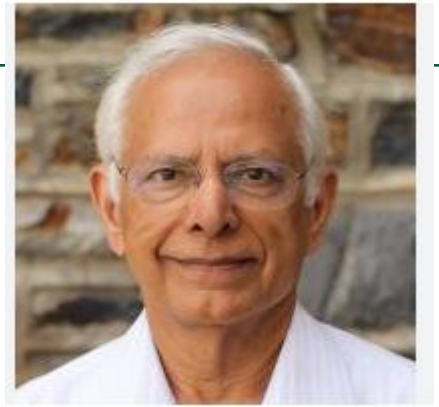

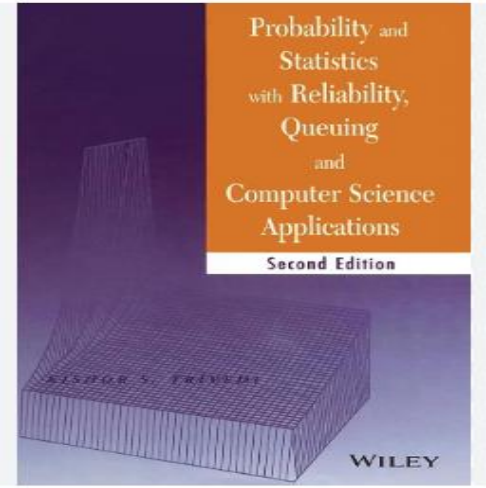
Probability and Statistics with Reliability, Queuing and Computer Science Applications
Second Edition
WILEY

WILEY
WILEY PROFESSIONAL COMPUTING
THE ART OF COMPUTER SYSTEMS PERFORMANCE ANALYSIS
Techniques for Experimental Design, Measurement, Simulation, and Modeling
Raj Jain

2.1 Introdução

- As **distribuições de probabilidade** discutidas em módulos anteriores calculam as **probabilidades dos eventos de interesse**, dado que a família (ou tipo) da distribuição e os valores de seus parâmetros são **conhecidos antecipadamente.**

- **Na prática**, a família da distribuição e seus parâmetros associados têm de ser estimados **a partir dos dados coletados** durante a **operação verdadeira do sistema sob investigação**.

- **Nesta seção** deseja-se investigar cenários em que, a partir do conhecimento de **algumas das características de um subconjunto** adequadamente escolhido de uma coleção de elementos, derivamos **inferências sobre as características de todo o conjunto inteiro**.

2.1 Introdução

- A **coleção de elementos sob investigação** é conhecida como a **população**, e seu subconjunto selecionado é chamado de **amostra**.

- **Métodos de inferência estatística** ajudam a estimar as **características da população inteira** baseando-se nos **dados coletados** a partir de (ou evidência produzida por) **uma amostra**.

- **Dois** aspectos do processo de **amostragem** aparentam ser bem intuitivos. **Primeiro**, conforme o **tamanho da amostra** aumenta, a estimativa geralmente **se aproxima** do **valor verdadeiro**, com completa correspondência sendo alcançada quando a amostra contempla **a população inteira. Segundo**, qualquer que seja o tamanho da amostra, a amostra deve ser **representativa da população**.

2.1 Introdução

- Os **dois** aspectos mencionados anteriormente (nem sempre satisfeitos) do processo de amostragem leva a definições de **consistência** e **não enviesamento** de uma **estimativa**.

- Quando dizemos que uma **população** tem uma **distribuição F(x),** implica dizer que estamos interessados em estudar uma **característica X** dos elementos desta população, e que **esta característica X** é uma **variável aleatória** cuja **função de distribuição** é **F(x).**

- Os **quatro pontos** elencados a seguir (próximo slide) constituem o tema **Inferência Estatística.**

1. Diferentes **amostras** da **mesma população** resultam, em geral, em **distintas estimativas**, e estas estimativas seguem alguma forma de distribuição estatística, chamada **distribuição amostral.**

2. Assumindo que a **forma de distribuição** (e.g., normal ou exponencial) da **população pai** é **conhecida**, parâmetros desconhecidos da população podem **ser estimados**. Neste caso é necessário definir-se a **confiança nas estimativas**. Isso conduz às **estimativas de intervalos** ou **intervalos de confiança.**

3. Nos casos em que a forma de distribuição da população pai **não é conhecida,** podemos realizar um teste de **goodness-of-fit** considerando alguma família específica de distribuições e, portanto, determinar **se a população pai** pode ser declarada como **pertencente a esta família**.

4. Em vez de **estimar propriedades da distribuição da população**, podemos estar interessados em **testar** uma **hipótese** sobre um relação envolvendo **propriedades da função de distribuição**. Nesse sentido, com base **nos dados coletados**, podemos realizar **testes estatísticos** e **rejeitar ou não rejeitar** a **hipótese**, e também **estudar os erros** envolvidos em tais julgamentos.

2.1 Introdução

- **Técnicas estatísticas** são extremamente úteis em áreas como avaliação de algoritmos, **avaliação de performance de sistemas**, e estimação de confiabilidade. Nesta seção estamos, sempre que possível, enfatizando a **avaliação de performance de sistemas**.

- **Por exemplo**, assuma que os tempos **entre chegadas** de jobs vindos para **um servidor** são **exponencialmente distribuídos com parâmetro λ**, mas o valor de **λ é desconhecido**. Depois de observar o processo de chegada por um tempo finito, podemos obter uma **estimativa** $\hat{\lambda}$ **de λ.**

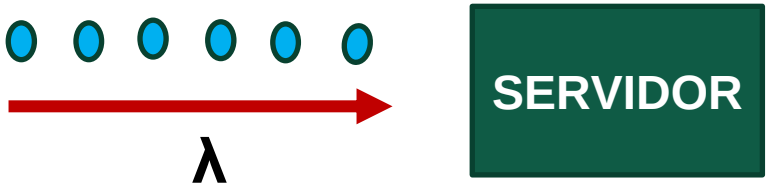

2.1 Introdução

- **Todavia**, algumas vezes podemos **não** estar interessados em estimar o valor de **λ**, mas sim testar a hipótese **λ < λo** (contra uma hipótese alternativa de **λ > λo**).

- Neste caso, se **λo** representa algum **limiar** de taxa de chegada de jobs **acima do qual** o servidor fica **sobrecarregado ou instável**, então a **aceitação da hipótese** implica que **não há necessidade** da aquisição de um novo servidor. Também poderíamos **testar a hipótese** dos tempos **entre chegadas de jobs** serem **exponencialmente distribuídos**, caso isso não fosse conhecido.

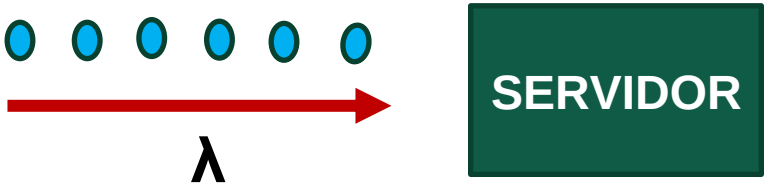

2.1 Introdução

- Nesta seção estamos **principalmente** interessados em discutir **problemas de estimativa de parâmetros da distribuição de uma única variável aleatória *X*** e a **determinação de intervalos de confiança.**

- Os **demais pontos** relacionados à **inferência estatística** estão **fora do escopo aqui tratado**, podendo ser consultados na referências indicadas ao final.

2.2 Estimativa de Parâmetros

- Suponha que a **população pai** é distribuída em uma forma que é **completamente determinada** (fixa, exata) exceto por um **parâmetro** θ**.**

- O **parâmetro** θ a estimar poderia ser a **média (verdadeira)** da população **μ = E[X]** ou a variância (verdadeira) da população $\sigma^2 = Var[X]$

- A **estimativa** é baseada em uma coleção de ***n*** resultados experimentais (observações) **x1, x2, x3, ..., xn**. Cada resultado experimental **xi** é um valor de uma variável aleatória **Xi.** O conjunto das variáveis aleatórias **X1, X2, ..., Xn** é chamada de uma amostra de tamanho **n** da população.

2.2.1 Definição: amostra aleatória

- O conjunto de variáveis aleatórias **X1, X2, ..., Xn** é dito constituir uma **amostra aleatória** de **tamanho n** da função de distribuição **F(x)**, desde que elas sejam **mutuamente independentes e identicamente distribuídas** com função de distribuição **F(Xi) = F(x)** para **todo i** e **todo x.**

- A menos que dito o contrário, vamos **sempre assumir** que a população é **muito grande** ou **conceitualmente de tamanho infinito.**

2.2.2 Definição: estatística

- Qualquer função **W(X1, X2, ..., Xn) das observações X1, X2, ..., Xn, é** chamada uma estatística.

- Portanto, uma **estatística** é uma função de ***n* variáveis aleatórias**, e assumindo que ela também é uma **variável aleatória**, sua função de distribuição, chamada de **distribuição de amostragem de *W***, pode ser derivada da **distribuição da população**.

- Os tipos de **funções W** em que estamos interessados incluem:

MÉDIA AMOSTRAL: $\bar{X} = \sum_{i=1}^{n} \frac{X_i}{n}$

VARIÂNCIA AMOSTRAL: S^2

2.2.3 Definição: estimador

- Qualquer **estatística** $\widehat{\Theta}=\widehat{\Theta}(X_1, X_2, \dots, X_n)$ usada para estimar o valor de um parâmetro θ da população é chamado um **estimador** de θ. Um valor da estatística $\hat{\theta}= \hat{\theta}(x_1, x_2 \dots, x_n)$ é conhecido como estimativa de θ.

- Uma **estatística** $\widehat{\Theta}$ não pode garantir uma **estimativa** próxima de θ para cada amostra. Precisamos então projetar/considerar estatísticas que resultam em bons resultados **na média** (ou *in the long run*).

2.2.4 Definição: estimador imparcial

- Uma **estatística** $\widehat{\Theta}=\widehat{\Theta}(X_1, X_2, \dots, X_n)$ é dita constituir um **estimador imparcial** (unbiased) do parâmetro θ desde que:

$$E[\widehat{\Theta}=\widehat{\Theta}(X_1, X_2, \dots, X_n)] = \theta$$

- Em outras palavras, **na média**, o **estimador** está no alvo.

Exercício 1: Example 10.1 p.641 Trivedi

- Sejam $X_1, X_2, \ldots, X_n$ v.a i.i.d. **Verificar** se a média amostral $\bar{X}$ é um estimador **imparcial** da média da população **E[X] = μ**, se ela existir.

$$E[\bar{X}] = E\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} E[X_i] = \frac{1}{n}\sum_{i=1}^{n} E[X] = \frac{1}{n} nE[X] = E[X] = \mu$$

- $\bar{X}$ **é então um estimador imparcial.**

Exercício 1: Example 10.1 p.641 Trivedi

- Sejam $X_1, X_2, \dots, X_n$ v.a i.i.d com **variância finita** σ^2. **Qual a variância do estimador $\bar{X}$?**
  - Como $X_1, X_2, \dots, X_n$ são mutuamente independentes e sejam as constantes $a_1, a_2, \dots, a_n$, então a **variância** do somatório é dada por (**Teorema 4.3 pag. 204, Trivedi**).

$$Var[\sum_{i=1}^{n} a_i X_i] = \sum_{i=1}^{n} a_i{}^2 Var[X_i]$$

- Como $X_1, X_2, \dots, X_n$ são mutuamente independentes com **Var[Xi] =**σ^2**,** então a **variância** do somatório é dada por (**Teorema 4.3,** pag. 204, Trivedi).

$$Var[\sum_{i=1}^{n} X_i] = n\, Var[X_i] = n\sigma^2$$

Exercício 1: Example 10.1 p.641 Trivedi

- E a **variância** da **média amostral** é:

$$Var[\bar{X}] = Var\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n^2} Var\left[\sum_{i=1}^{n} X_i\right] = \frac{\sigma^2}{n}$$

- Isso implica que a precisão da **média amostral,** como um **estimador da média** da população, **aumenta** com a o **tamanho da amostra *n*** quando a **variância** da população é **finita.**

Exercício 2: Example 10.2 p.642 Trivedi

- Sejam $X_1, X_2, \ldots, X_n$ v.a i.i.d. **Verificar** se a **variância amostral** S^2 definida a seguir é um estimador **imparcial** da variância da população **Var[X] =** σ^2 , **se ela existir**.

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(\ X_i - \bar{X}\ )^2$$

- É possível **mostrar** que:

$$E[S^2] = \frac{1}{n-1}n(\sigma^2 + \mu^2) - \frac{n}{n-1}\left(\frac{\sigma^2}{n} + \mu^2\right) = \sigma^2$$

- Portanto, a **variância amostral** S^2 é um **estimador imparcial** da variância da população σ^2

2.2 Intervalos de Confiança (10.2.3 – Trivedi)

- Naturalmente, o ponto estimado $\hat{\theta}$ raramente coincide com o valor real do parâmetro θ que está sendo estimado. É, portanto, desejável estabelecer uma **estimativa de intervalo.**

- Nesse sentido, construímos então um intervalo, chamado de **intervalo de confiança,** de tal sorte que ficamos razoavelmente confiantes de que ele **contém o valor verdadeiro do parâmetro de interesse**.

2.2 Intervalos de Confiança

- Se pudermos verificar que o **estimador** $\widehat{\Theta}$ satisfaz a condição:

$$P\left(\widehat{\Theta} - \epsilon_1 < \theta < \widehat{\Theta} + \epsilon_2\right) = \gamma$$

- Então dizemos que o intervalo aleatório a seguir é um intervalo de confiança de $100\gamma\%$ para o parâmetro θ . γ é chamado de coeficiente de confiança.

$$A(\theta) = (\widehat{\Theta} - \epsilon_1, \widehat{\Theta} + \epsilon_2)$$

- Frequentemente usamos um intervalo de confiança **simétrico** de tal sorte que: $\epsilon_1 = \epsilon_2 = \epsilon$

2.2 Intervalos de Confiança

- O significado da probabilidade associada ao intervalo de confiança pode ser mais esclarecido como segue.

- Para qualquer conjunto específico de observações **x1, x2, ..., xn**, a estimativa $\hat{\theta}$ é um valor fixo. O intervalo de confiança $A(\theta)$ poderá então conter (ou não conter) o valor verdadeiro de θ com probabilidade **um** ou **zero.**

- Entretanto, quando $\widehat{\Theta}$ é considerado como uma função de variáveis aleatórias X1, X2, ..., Xn, os extremos do intervalo $A(\theta)$ são então variáveis aleatórias, e é possível dizer que a probabilidade é γ de que o intervalo aleatório $A(\theta)$ irá conter o valor fixo verdadeiro de θ.

2.2 Intervalos de Confiança

- A interpretação de frequência relativa da probabilidade anteriormente discutida implica que se o processo de amostragem é repetido muitas vezes, a fração de tempo na qual o valor verdadeiro de θ está contido no intervalo de confiança $A(\theta)$ será γ .

- Uma forma simples de obter um intervalo de confiança, envolvendo um estimador imparcial, é aplicando a desigualdade de Chebyshev a seguir, desde que $Var[\widehat{\Theta}]$ é conhecida ou pode ser estimada.

$$P\left(\widehat{\Theta} - \epsilon < \theta < \widehat{\Theta} + \epsilon\right) \geq 1 - \frac{Var[\widehat{\Theta}]}{\epsilon^2}$$

Exercício 3: Example 10.13 p.657 Trivedi

- Seja $\theta = \mu \quad e \quad \widehat{\Theta} = \bar{X}$, a média amostral. Assuma que a variância da população σ^2 é conhecida. Então, tem-se:

$$Var[\bar{X}] = \frac{\sigma^2}{n}$$

- E a **desigualdade de Chebyshev** leva a:

$$P(\bar{X} - \epsilon < \mu < \bar{X} + \epsilon) \geq 1 - \frac{\sigma^2}{n\epsilon^2}$$

- Portanto, para um dado $\epsilon > 0$, podemos fazer o coeficiente de confiança γ arbitrariamente próximo de 1 ao escolher um valor de ***n*** suficientemente grande.

2.2 Intervalos de Confiança

- **Todavia, intervalos de confiança** obtidos pela desigualdade de Chebyshev podem usualmente ser melhorados se a **distribuição de X** (i.e., da população) é conhecida.

- Neste contexto, em **geral**, os **passos envolvidos** em obter um intervalo de confiança para o **parâmetro** θ a partir de uma amostra aleatória, **X1, X2, ..., Xn**, são apresentados **a partir do próximo slide**, assumindo **duas distribuições conhecidas da literatura**.

2.2.1 Intervalos de Confiança

- Seja $\boldsymbol{\theta} = \boldsymbol{\mu}$ (média da população), e seja $\bar{\boldsymbol{X}}$ a **média amostral**. Assuma que a variância da população $\boldsymbol{\sigma}^2$ é conhecida.

- Uma forma de estimar o quanto $\bar{\boldsymbol{X}}$ é próximo de $\boldsymbol{\theta}$ é calcular um intervalo ao qual atribuímos um grau de confiança para que $\boldsymbol{\theta}$ esteja dentro dele:

$$P(\bar{X} - \epsilon < \boldsymbol{\theta} < \bar{X} + \epsilon) = p$$

$$P(|\bar{X} - \boldsymbol{\theta}| \leq \epsilon) = p$$

- Para calcular esta probabilidade, vamos então **assumir** que $\bar{\boldsymbol{X}}$ tem **distribuição Normal** com base no **Teorema do Limite Central**, conforme detalhado a seguir.

2.2.1 Intervalos de Confiança

- Pelo **Teorema do Limite Central**, temos que:

- Seja **X1, X2, ..., Xn** variáveis aleatórias independentes e identicamente distribuídas (i.i.d.), com média $\boldsymbol{\theta} = \boldsymbol{\mu}$, e variância $\boldsymbol{\sigma^2}$. Tem-se então que:

$$\boldsymbol{Z} = \frac{X_1 + X_2 + \cdots + X_n - n\theta}{\sigma\sqrt{n}} = \frac{n\overline{\boldsymbol{X}} - n\theta}{\sigma\sqrt{n}} \sim \boldsymbol{N}(\mathbf{0}, \mathbf{1}) \text{ quando } \boldsymbol{n} \to \infty$$

- Disso decorre que: $\overline{\boldsymbol{X}} \sim \boldsymbol{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2/\boldsymbol{n})$

2.2.1 Intervalos de Confiança

- Reescrevendo **Z**, tem-se:

$$\boldsymbol{Z} = \frac{n\bar{\boldsymbol{X}} - n\theta}{\sigma\sqrt{n}} = \frac{(\bar{\boldsymbol{X}} - \boldsymbol{\theta})\sqrt{n}}{\sigma} \sim \boldsymbol{N}(\mathbf{0}, \mathbf{1})$$

Função de densidade da Normal (pdf): $\boldsymbol{f_Z(z)}$

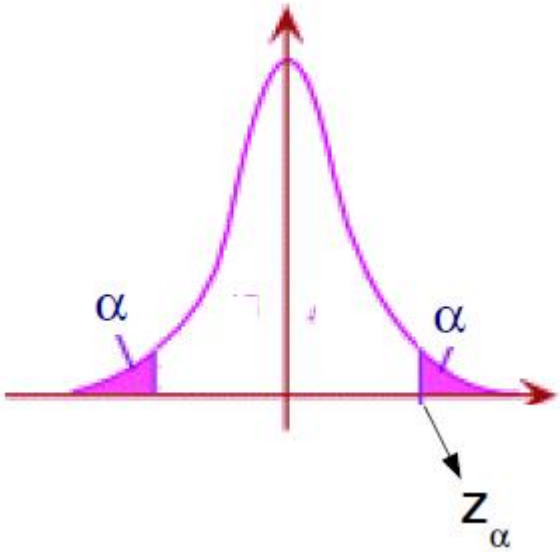

- Área **sob a curva** ($\boldsymbol{\alpha}$) é a **probabilidade**:

$$P[Z > z_\alpha] = \alpha$$

$$P[Z < -z_\alpha] = \alpha$$

$$P[-z_\alpha < Z < z_\alpha] = 1 - 2\alpha$$

$$\boldsymbol{P\left[-z_{\alpha/2} < Z < z_{\alpha/2}\right] = 1 - \alpha}$$

2.2.1 Intervalos de Confiança

- Substituindo-se **Z** e manipulando-se a equação, obtemos:

$$P\left[-z_{\alpha/2} < \frac{(\bar{X}-\theta)\sqrt{n}}{\sigma} < z_{\alpha/2}\right] = 1-\alpha$$

$$P\left[-z_{\alpha/2}\frac{\sigma}{\sqrt{n}} < \bar{X}-\theta < z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right] = 1-\alpha$$

$$\boldsymbol{P\left[\bar{X}-z_{\alpha/2}\frac{\sigma}{\sqrt{n}} < \theta < \bar{X}+z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right] = 1-\alpha} \qquad \textbf{(I)}$$

Obs:

Valores de $\boldsymbol{z_{\alpha/2}}$ podem ser lidos a partir de tabela.

2.2.1 Intervalos de Confiança

- Veja que**, embora** a **distribuição real** da população (**ou seja, a distribuição de *X***) possa **até não** ser **Normal**, assumir a **distribuição Normal para** $\bar{X}$ **não** é **um problema** quando o tamanho da amostra é **grande**, graças ao resultado do **Teorema do Limite Central.**

(Trivedi, p. 660)

- A fórmula para **intervalo de confiança** apresentada em **(I)** **requer** o conhecimento da **variância** da **população real**, $\boldsymbol{\sigma^2}$. Quando este valor não é conhecido, podemos usar em seu lugar a sua **estimativa** $\boldsymbol{s^2}$ para obter um **intervalo de confiança** aproximado para $\boldsymbol{\theta = \mu}$, ficando:

$$\boldsymbol{P\left[\bar{X} - z_{\alpha/2}\frac{s}{\sqrt{n}} < \theta < \bar{X} + z_{\alpha/2}\frac{s}{\sqrt{n}}\right] = 1 - \alpha} \qquad \textbf{(II)}$$

2.2.1 Intervalos de Confiança

- Observe então que **expressão** de intervalo de confiança em **(II)** deve ser usada quando **não** conhecemos a **variância** da população. Caso contrário, usamos a **expressão** em **(I).**

- Todavia, a expressão de **intervalo de confiança** em **(II)** é uma **boa aproximação apenas** para grandes valores de ***n*** (i.e., $n > 30$).

- Quando o **tamanho da amostra** é pequeno (i.e., $n \leq 30$), essa **aproximação não** é mais adequada. Neste caso podemos utilizar a **distribuição t-Student,** como explicado no próximo slide.

Trivedi p. 660

2.2.2 Intervalos de Confiança

- Se $\bar{X}$ é a média amostral de uma **amostra aleatória** de tamanho ***n*** de uma população de distribuição **Normal** com média $\boldsymbol{\theta = \mu}$ e com variância $\boldsymbol{\sigma^2}$, então podemos assumir que a variável aleatória ***T*,** descrita a seguir, tem **distribuição t-Student** com ***n*-1** graus de liberdade.

$$\boldsymbol{T = \frac{(\bar{X} - \theta)}{S/\sqrt{n}}}$$

- **Todavia,** este resultado **somente é válido** quando a **distribuição real** da população é **Normal** e ***n* ≤ 30**. **(Raj Jain, p. 206; Trivedi p. 660)**

2.2.2 Intervalos de Confiança

pdf da Normal padrão

pdf da t-Student com **n-1= 3** graus de liberdade

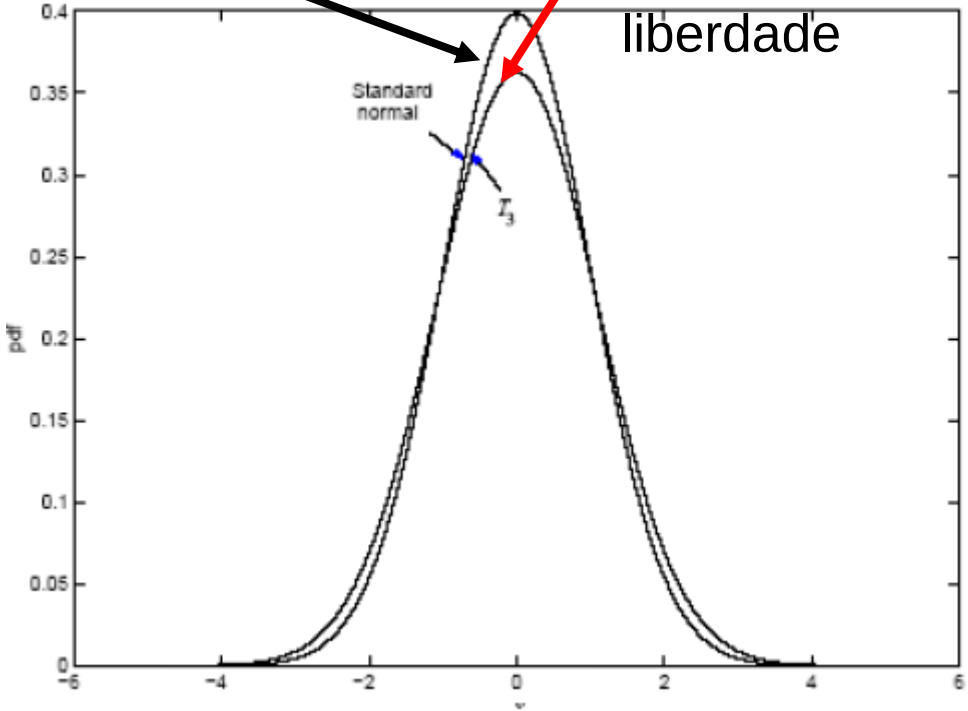

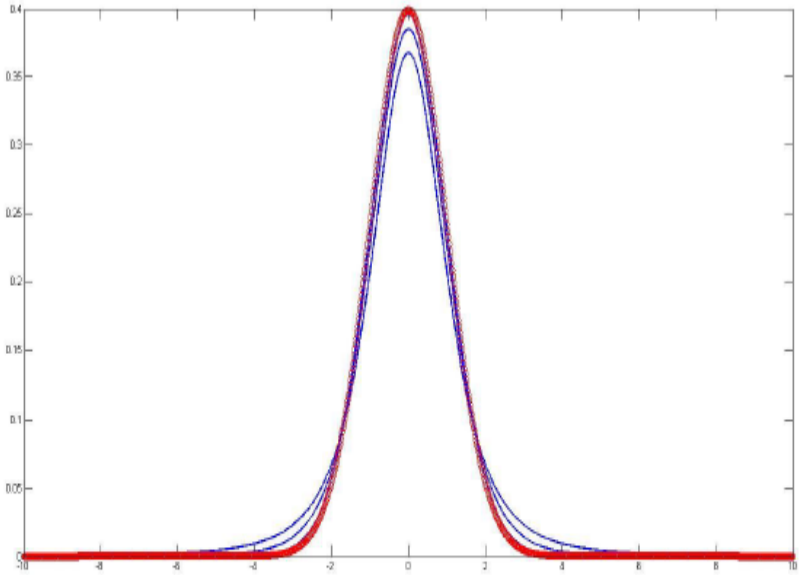

The red curve is the pdf of standard normal distribution, the lowest blue curve is T_3, the middle one is T_7, and the highest is T_{30}. We can see T_{30} and standard normal almost overlap with each other.

2.2.2 Intervalos de Confiança

- A partir do anterior, é possível então mostrar que a fórmula para **intervalo de confiança,** quando ***n* ≤ 30** e **distribuição real** da população é **Normal,** é dada por:

$$P\left[\bar{X} - t_{\alpha/2}\frac{s}{\sqrt{n}} < \theta < \bar{X} + t_{\alpha/2}\frac{s}{\sqrt{n}}\right] = 1 - \alpha \qquad \textbf{(III)}$$

Obs:
Valores de $t_{\alpha/2}$ podem ser obtidos a partir de tabelas.

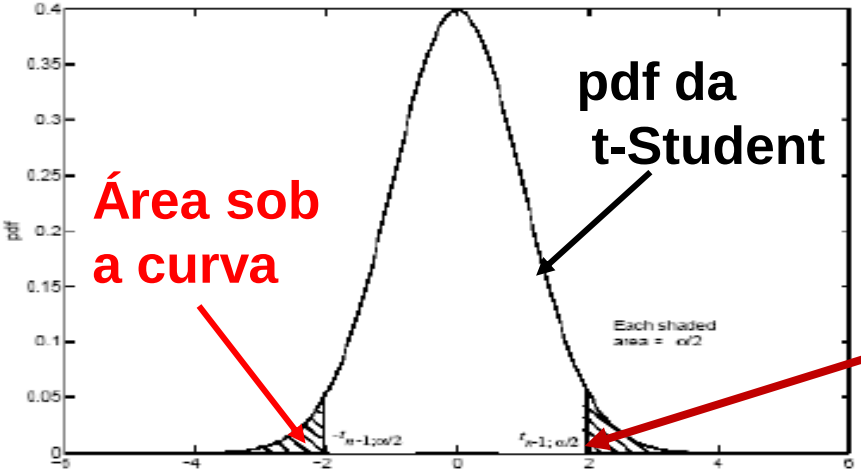

Exercício 4: Example 10.16 Trivedi p. 660

- O **nível de confiança** das conclusões obtidas a partir de um conjunto de dados então calculados/medidos depende naturalmente do **tamanho desse conjunto de dados**. Quanto **maior for a amostra**, **maior é a confiança** associada.

- **Entretanto**, **amostras grandes** também requerem **mais esforço e recursos**. Daí, o objetivo do analista deve ser **encontrar o menor tamanho de amostra que possa prover a confiança desejada.**

- O exercício a seguir **trata** sobre esta questão.

- **Raj Jain p. 216, Sec. 13.9**

Exercício 4: Example 10.16 Trivedi p. 660

- Suponha que desejamos estimar o **tempo de serviço médio** de CPU para um certo trabalho (*job*), e queremos garantir com **99% de confiança** que o valor estimado está **afastado** em (**dentro do limite** de) menos **de 0,5 s** do valor real.

- Suponha ainda que sabe-se que o **tempo de serviço** de CPU tem **distribuição Normal** com **variância** igual a **2,25 segundos ao quadrad**o.

- Qual o **tamanho mínimo da amostra, *n*,** para garantir a **confiança desejada** a para o valor a ser estimado?

Exercício 4: Example 10.16 Trivedi p. 660

Sabemos que:

$$P\left[\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} < \theta < \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right] = 1 - \alpha$$

Seja ***E*** o **afastamento limite**. Temos então que:

$$E = z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \longrightarrow \sqrt{n} = z_{\alpha/2}\frac{\sigma}{E} \longrightarrow n = \left[\left(z_{\alpha/2}\frac{\sigma}{E}\right)^2\right] \quad \textbf{(IV)}$$

Desejamos uma confiança de **99%.** Tem-se então:

$$1 - \alpha = 0{,}99 \longrightarrow \alpha = 0{,}01 \longrightarrow \frac{\alpha}{2} = 0{,}005$$

Exercício 4: Example 10.16 Trivedi p. 660

Daí, temos:

$$P\left[Z > z_{\alpha/2}\right] = \frac{\alpha}{2} = 0{,}005$$

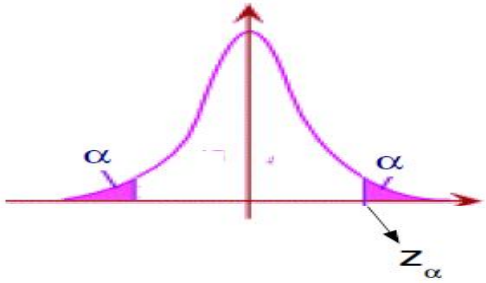

$$P\left[Z \leq z_{\alpha/2}\right] = 1 - \frac{\alpha}{2} = 0{,}995$$

Tab. distribuição **Normal padrão**

$$\boldsymbol{z_{\alpha/2} = 2,57}$$

Tabela da Distribuição Normal Padrão
P(Z<z)

z	0,0	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964

$$\boldsymbol{n} = \left\lceil \left(z_{\alpha/2}\frac{\sigma}{E}\right)^2 \right\rceil = \left\lceil \left(2{,}57\frac{1{,}5}{0{,}5}\right)^2 \right\rceil = \lceil 59{,}72 \rceil = \mathbf{60}$$

Exercício 4: Example 10.16 Trivedi p. 660

$$P\left[Z \leq z_{\alpha/2}\right] = 1 - \frac{\alpha}{2} = 0{,}995$$

$$\boldsymbol{z_{\alpha/2} = 2{,}57}$$

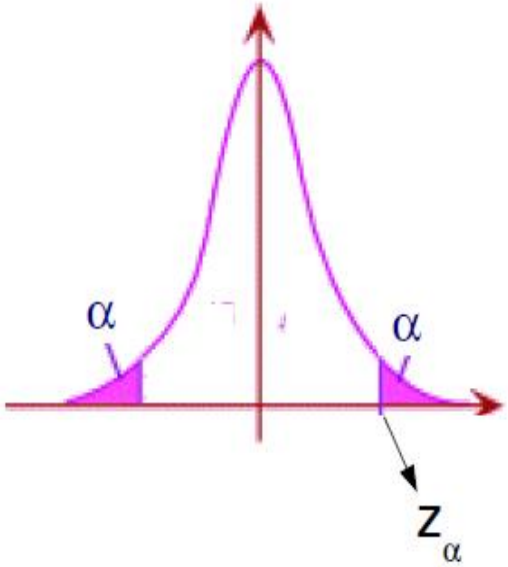

Tab. distribuição **Normal padrão**

Tabela da Distribuição Normal Padrão
P(Z<z)

z	0,0	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964

Exercício 5: Example 10.15 Trivedi p. 660

- O **tamanho médio** de um programa (em nr de páginas) que é executado em um dado sistema tem **distribuição Normal** com **média μ** desconhecida e **variância igual a 81.**

- O programa foi então executado **36** vezes e o tamanho do programa em cada execução (rodada) foi anotado. **A média amostral** foi calculada como **100 páginas**.

- Assumindo que as execuções são independentes, apresente o **intervalo de confiança de 95%** para o **tamanho médio** do programa.

Exercício 5: Example 10.15 Trivedi p. 660

Sabemos que:

$$\boldsymbol{P\left[\bar{X} - z_{\alpha/2}\frac{s}{\sqrt{n}} < \theta < \bar{X} + z_{\alpha/2}\frac{s}{\sqrt{n}}\right] = 1 - \alpha}$$

O valor de $\boldsymbol{z_{\alpha/2}}$ pode ser determinado como segue.

$$1 - \alpha = 0{,}95 \longrightarrow \alpha = 0{,}05 \longrightarrow \boldsymbol{\frac{\alpha}{2} = 0{,}025}$$

$$P\left[Z > z_{\alpha/2}\right] = \frac{\alpha}{2} = 0{,}025 \longrightarrow P\left[Z \leq z_{\alpha/2}\right] = 1 - \frac{\alpha}{2} = 0{,}975$$

Tab. distribuição **Normal padrão**

$$\boldsymbol{z_{\alpha/2} = 1{,}96}$$

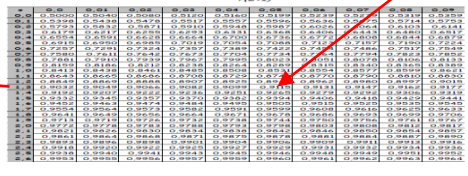

Exercício 5: Example 10.15 Trivedi p. 660

Substituindo os valores, temos então:

$$P\left[100 - 1{,}96\frac{9}{\sqrt{36}} < \mu < 100 + 1{,}96\frac{9}{\sqrt{36}}\right] = 0{,}95$$

$$P\left[100 - 1{,}96\frac{9}{\sqrt{36}} < \mu < 100 + 1{,}96\frac{9}{\sqrt{36}}\right] = 0{,}95$$

Finalmente, temos então o **seguinte intervalo**:

$$[\mathbf{97,06; 102,94}]$$

Exercício 6: Example 10.17 Trivedi p. 661

- Desejamos estimar o **tempo médio de execução** de um programa.
- O programa foi executado **6 vezes** com um conjunto de dados escolhido randomicamente a cada vez, e a **média amostral** do tempo de execução foi computada em **230 ms** e o **desvio padrão da amostra** em **14 ms**.
- Apresente um **intervalo de confiança de 98%** da **média verdadeira μ** do tempo de execução.

Exercício 6: Example 10.17 Trivedi p. 661

Como ***n* = 6,** vamos **considerar** que a distribuição do tempo de execução é **Normal** para então podermos utilizar a distribuição **t-Student** com **n-1 graus de liberdade** e derivar o intervalo de confiança desejado.

Sabemos que:

$$\boldsymbol{P\left[\bar{X} - t_{\alpha/2}\frac{s}{\sqrt{n}} < \theta < \bar{X} + t_{\alpha/2}\frac{s}{\sqrt{n}}\right] = 1 - \alpha}$$

Temos que:

$$1 - \alpha = 0{,}98 \longrightarrow \alpha = 0{,}02 \longrightarrow \boldsymbol{\frac{\alpha}{2} = 0{,}01}$$

Exercício 6: Example 10.17 Trivedi p. 661

$$P\left[T > t_{\alpha/2}\right] = \frac{\alpha}{2} = 0{,}01 \longrightarrow P\left[T \leq t_{\alpha/2}\right] = 1 - \frac{\alpha}{2} = 0{,}99$$

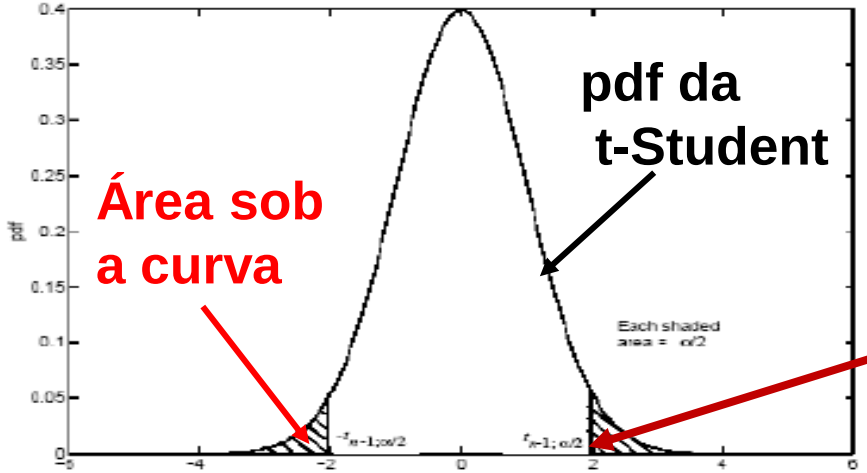

Valor (no eixo horizontal) de $t_{\alpha/2}$

Com **5 graus** de liberdade e consultando **tabela**, tem-se: $t_{\alpha/2} = 3{,}365$

n -1 = **5**

$$\frac{\alpha}{2} = 0,01$$

Com **5 graus** de liberdade

TABLE C.4. Critical values of the Student's t-distribution

df[a] \ α	0.1	0.05	0.025	0.01	0.005	0.001
1	3.078	6.314	12.706	31.821	63.657	318.309
2	1.886	2.920	4.303	6.965	9.925	22.327
3	1.638	2.353	3.182	4.541	5.841	10.215
4	1.533	2.132	2.776	3.747	4.604	7.173
5	1.476	2.015	2.571	3.365	4.032	5.893
6	1.440	1.943	2.447	3.143	3.707	5.208
7	1.415	1.895	2.365	2.998	3.499	4.785
8	1.397	1.860	2.306	2.896	3.355	4.501
9	1.383	1.833	2.262	2.821	3.250	4.297
10	1.372	1.812	2.228	2.764	3.169	4.144
11	1.363	1.796	2.201	2.718	3.106	4.025
12	1.356	1.782	2.179	2.681	3.055	3.930
13	1.350	1.771	2.160	2.650	3.012	3.852
14	1.345	1.761	2.145	2.624	2.977	3.787
15	1.341	1.753	2.131	2.602	2.947	3.733
16	1.337	1.746	2.120	2.583	2.921	3.686
17	1.333	1.740	2.110	2.567	2.898	3.646
18	1.330	1.734	2.101	2.552	2.878	3.610
19	1.328	1.729	2.093	2.539	2.861	3.579
20	1.325	1.725	2.086	2.528	2.845	3.552
21	1.323	1.721	2.080	2.518	2.831	3.527
22	1.321	1.717	2.074	2.508	2.819	3.505
23	1.319	1.714	2.069	2.500	2.807	3.485
24	1.318	1.711	2.064	2.492	2.797	3.467
25	1.316	1.708	2.060	2.485	2.787	3.450
26	1.315	1.706	2.056	2.479	2.779	3.435
27	1.314	1.703	2.052	2.473	2.771	3.421
28	1.313	1.701	2.048	2.467	2.763	3.408
29	1.311	1.699	2.045	2.462	2.756	3.396
30	1.310	1.697	2.042	2.457	2.750	3.385
40	1.303	1.684	2.021	2.423	2.704	3.307
60	1.296	1.671	2.000	2.390	2.660	3.232
120	1.289	1.658	1.980	2.358	2.617	3.160
∞	1.282	1.645	1.960	2.326	2.576	3.090

[a]Degree of freedom.

$$t_{\alpha/2} = 3,365$$

Trivedi, p. 790

Exercício 6: Example 10.17 Trivedi p. 661

Substituindo-se os valores, tem-se então:

$$P\left[230 - 3{,}365\frac{14}{\sqrt{6}} < \mu < 230 + 3{,}365\frac{14}{\sqrt{6}}\right] = 0{,}98$$

Temos então que o **intervalo** é:

$$\left[230 - 3{,}365\frac{14}{\sqrt{6}}; 230 + 3{,}365\frac{14}{\sqrt{6}}\right]$$

$$[\mathbf{210{,}7675; 249{,}2325}]$$

2.2.3 Intervalos de Confiança

- Veja que **se** a **população** é **Normal** com **média e variância conhecidas**, então a **formulação** de **intervalo de confiança (I)** é suficiente. As formulações **(II)** e **(III)** são específicas. **Este entendimento é importante**.

- **Até este ponto**, consideramos **intervalos de confiança** para **a média. Intervalos de confiança** para a **variância** são deixados como **estudo extraclasse.**

- Quando a população não é **Normal** e/ou **fora** os casos anteriormente discutidos (i.e., usando o **Teorema do Limite Central** e **t-Student**, e as **formulações I, II, e III**), podemos identificar outras distribuições para população **X** em análise, e.g., Exponencial, Weibull, Bernoulli, etc. Essa discussão também é deixada como **estudo extraclasse**.

2.3 Que nível de confiança usar?

- Comumente falamos em **níveis de confiança** de **90%** ou **95%**

- Isso pode levar a pensar que os **níveis de confiança** devem ser **sempre altos (grandes).**

- **Na verdade,** a **escolha** do nível de confiança deve ser baseada na **perda** que se pode admitir se o parâmetro estiver **fora do intervalo** e no **ganho** que se tem se o parâmetro estiver **dentro do intervalo**.

- Se a **perda é alta** comparada **ao ganho**, os intervalos de confiança devem ser **altos**. Se a **perda é negligível** comparada **ao ganho**, os intervalos de confiança **não tão alto** são satisfatórios.

- **Raj Jain p. 212, Sec. 13.5**

2.3 Que nível de Confiança usar?

Exemplo: **Ganhar na loteria!!!**

2.3 Que nível de Confiança usar?

- **Exemplo:**
- Considere, e.g., uma loteria na qual o bilhete custa **1 dólar** e o **prêmio é de 5 milhões de dólares.**
- Suponha que para ganhar com uma confiança de **90%** seja necessário comprar **nove milhões de bilhetes**!
- É razoável imaginar que **ninguém** vai gastar tanto (i.e., **9 milhões**) para (tentar) ganhar apenas **5 milhões!**
- A **maioria das pessoas** deve ficar satisfeita com uma **confiança bem menor** de ganhar **(talvez 0,01%)!**
- Neste exemplo, a **perda é negligível** (custo de apenas alguns bilhetes) comparada ao ganho (5 milhões de dólares), os intervalos de confiança **não tão alto são satisfatórios!**

2.3 Que nível de confiança usar?

- **Conclusão:**

- O **ponto** é que se você se depara com um **parâmetro** para o qual o **nível de confiança** relacionado é de **50%, não assuma** automaticamente que a **confiança é baixa** e que **não vale a pena tomar uma decisão** baseada nesse parâmetro.

- **Semelhantemente**, se o **parâmetro** tem associado **um nível de confiança de 99%,** os decisores podem ainda considerar que o **nível de confiança não é suficientemente alto** se a perda devido à uma decisão errada **for enorme!**

3. Resultados de Simulação

Fontes principais:

- **Cap 25 Jain**

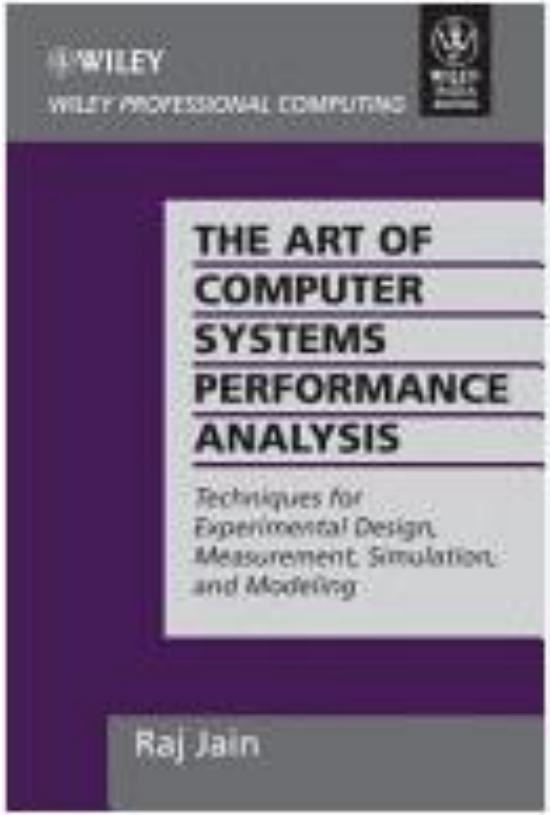
WILEY
WILEY PROFESSIONAL COMPUTING
THE ART OF COMPUTER SYSTEMS PERFORMANCE ANALYSIS
Techniques for Experimental Design, Measurement, Simulation, and Modeling
Raj Jain

3. Resultados de Simulação

- Durante o desenvolvimento de um **modelo de simulação**, é preciso certificar-se de que: **(1)** o modelo **foi corretamente implementado** e que **(2)** ele é **representa o sistema real**. Essas **duas** etapas são chamadas de **(1) verificação de modelo** e **(2) validação de modelo**, respectivamente.

- Depois que o **desenvolvimento** do modelo **está concluído**, as duas próxima etapas são decidir: **(3)** quantas das **observações iniciais** devem ser **descartadas** para garantir que o modelo atingiu o estado estacionário (i.e., realizar a **remoção do transiente**), e **(4) quanto tempo** deve durar uma simulação.

- Essas **QUATRO** etapas são discutidas nesta seção.

3.1 TÉCNICAS DE VERIFICAÇÃO DE MODELOS

3.2 TÉCNICAS DE VALIDAÇÃO DE MODELOS

3.3 REMOÇÃO DE TRANSIENTE

3.4 TÉRMINO DE SIMULAÇÕES

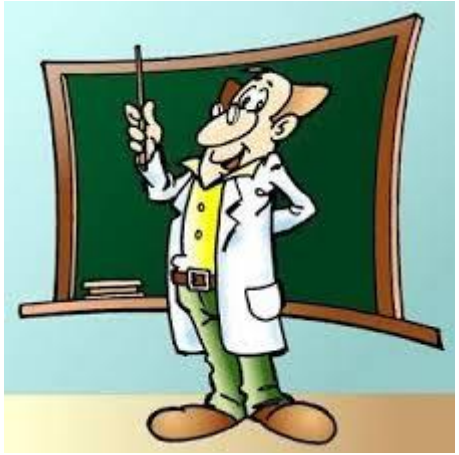

(1) O modelo **foi corretamente implementado?**

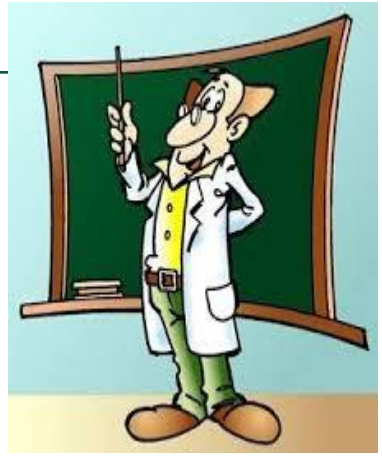

3.1 TÉCNICAS DE VERIFICAÇÃO DE MODELOS

3.1 TÉCNICAS DE VERIFICAÇÃO DE MODELOS

- A **adequação** de um **modelo de simulação** é medida pela **proximidade** dos resultados de saída (output) do modelo em relação aos resultados produzidos pelo sistema real.
- Como **suposições** (premissas, simplificações, abstrações, etc.) foram **admitidas** no desenvolvimento do modelo, podemos então ter também o seguinte entendimento para as etapas de **validação e verificação de modelos**, respectivamente.
- **Validação do modelo**: garantir que as **suposições admitidas** são **razoáveis e condizentes** com o sistema real. Isso significa que os **resultados obtidos** a partir **do modelo** são **próximos** daqueles produzidos pelo **sistema real.**
- **Verificação do modelo**: garantir que **as suposições admitidas** estão **corretamente implementadas** no modelo.

3.1 TÉCNICAS DE VERIFICAÇÃO DE MODELOS

- Se a **modelagem** e a **programação** de um **modelo de simulação** são realizadas por duas pessoas distintas (ou equipes distintas), então a pessoal responsável **pela modelagem** seria a responsável pela **validação**, enquanto a pessoa responsável pela **programação** seria a responsável pela **verificação.**
- Na **literatura** de **linguagens de programação**, existem **várias técnicas** que podem ser utilizadas na etapa de **verificação de modelos** de simulação.
- **Exemplos de técnicas**: **Top-Down Modular Design** (um módulo é dividido em submódulos hierarquizados, e a análise fica assim facilitada); **Structured Walk-Through** (explicar para outros o que cada linha de código faz); **Run Simplified Cases** (analisar (sem simular) casos simples e, depois, comparar com os resultados de simulação); **etc.**

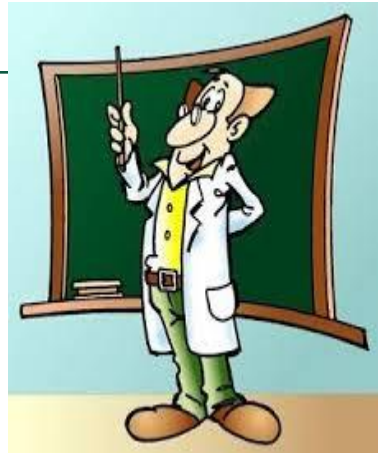

(2) O modelo representa o sistema real?

3.2 TÉCNICAS DE VALIDAÇÃO DE MODELOS

3.2 TÉCNICAS DE VALIDAÇÃO DE MODELOS

- **Como já mencionado**, **validação** se refere a garantir que as **suposições** (simplificações, abstrações, etc.) admitidas são razoáveis e condizentes com o **sistema real.** Isso implica que, se **essas suposições** admitidas são **corretamente implementadas** (codificadas em linguagem de programação), o **modelo** produz **resultados próximos** daqueles observados no **sistema real**.
- As **técnicas de validação** dependem das **suposições** e, portanto, do **sistema que está sendo modelado.**
- **Diferentemente** das **técnicas de verificação** que são aplicáveis de **forma geral,** as técnicas de **validação** não o são, i.e., as técnicas de **validação** usadas em **uma simulação** podem **não ser aplicáveis** a **outra simulação.**

3.2 TÉCNICAS DE VALIDAÇÃO DE MODELOS

- A etapa de **validação** do modelo consiste **mais especificamente** em validar **três aspectos chave** do modelo:

1. Suposições
2. Valores de parâmetros de entrada e distribuições
3. Valores de saída e conclusões

- Cada um desses **três aspectos** pode então estar sujeito a um **teste de validação** feito a partir da **comparação** com o que é obtido a partir das seguintes **três fontes**:

1. Intuição do especialista
2. Medições do sistema real
3. Resultados teóricos

- Isso nos leva a **NOVE** possíveis **testes de validação**.

3.2 TÉCNICAS DE VALIDAÇÃO DE MODELOS

- Claro que pode **não ser possível** executar **todos** os **NOVE** testes de **validação**. Por exemplo, **medições** de um **sistema real** ou **resultados teóricos** podem não estar disponíveis por alguma razão.

- **Pode** ser até que ocorra que **nenhuma das NOVE possibilidades de testes** esteja disponível por alguma razão. Nesses casos, o analista deve **ao menos** conseguir **validar o modelo** considerando configurações bem **simplificadas**.

3.2 TÉCNICAS DE VALIDAÇÃO DE MODELOS

- Na prática, é melhor validar os **três aspectos** chave do modelo separadamente, conforme o modelo é desenvolvido, em vez de esperar até que ele esteja **finalizado**.
- As **suposições** devem ser discutidas tão logo uma **versão preliminar** do **projeto** do modelo esteja pronta.
- Os **valores de entrada e distribuições** devem ser discutidos durante o **desenvolvimento** do modelo.
- Os **valores de saída** (e conclusões) devem ser discutidos tão logo um **modelo executável** exista e tenha sido **verificado.**
- A seguir vamos discutir as **TRÊS fontes de obtenção de informação que podem ser utilizadas** para efeito de comparação com **aquilo que é** obtido a **partir do modelo.**

3.2.1 Intuição do especialista

3.2.2 Medições do sistema real

3.2.3 Resultados Teóricos

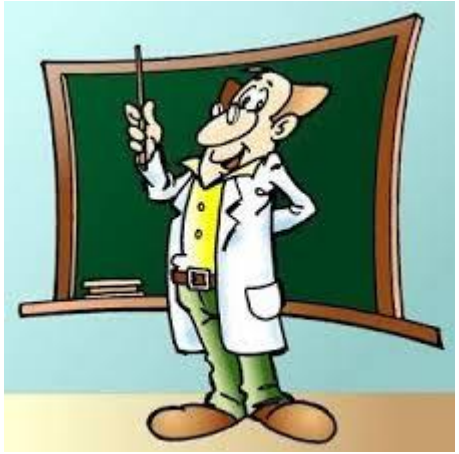

3.2.1 Intuição do especialista

- Usar a **intuição do especialista** é a forma **mais prática e comum** de **validação** de um modelo.
- Na prática, é adequado **validar** os três aspectos – suposições, entrada, e saída – **separadamente** conforme o modelo evolui em vez de esperar até que o fim seja alcançado.
- As **suposições** devem ser discutidas tão logo o projeto preliminar do modelo de simulação esteja preparado.
- Os **valores de entrada** e a distribuição devem ser discutidas e **validadas** a seguir durante o desenvolvimento do modelo.
- A **saída** deve ser **validada** tão logo um modelo executável exista e tenha sido **verificado**.

3.2.1 Intuição do especialista

- Uma técnica **para julgar** a **validade** **das saídas** é apresentar os **resultados do modelo** e também os **resultados das medições** de **sistemas reais** aos **especialistas** e ver se eles **conseguem diferenciá-las.**

Esta Foto de Autor Desconhecido está licenciado em CC BY

3.2.2 Medições do sistema real

- A **comparação** com o **sistema real** é a forma **mais confiável** e preferida para **validar** um **modelo de simulação**. Na prática, entretanto, isso pode ser inexequível ou porque os sistemas reais **não existem** ou porque as medições reais podem ser muito **custosas**.
- Quando possível, **suposições, entradas, saídas cargas configurações, e comportamento do sistema** devem ser **comparados** com o **observado no mundo real**. Por exemplo:
- **a)** Testes **estatísticos** podem ser usados para **comparar** o modelo de simulação com as **medições obtidas**.
- **b)** **Distribuições de entrada** podem ser v**erificadas** por **técnicas de ajuste de distribuição estatística** ou por **testes estatístico**s, comparando-se com o **real**.
- **c)** Em simulações do **tipo trace-driven**, **múltiplos traces** obtidos em diferentes ambientes podem ser usados **para validar o modelo.**

3.2.3 Resultados teóricos

- Em **alguns casos**, é possível **modelar analiticamente** o sistema sob suposições **simplificadoras** (e.g., quando o sistema é muito difícil de ser modelado analiticamente). Nesse caso, também pode ser possivel **determinar analiticamente** quais deveriam ser as distribuições de entrada.

- Em **tais casos**, a **similaridade dos resultados teóricos** e dos **resultados da simulação** é usada para **validar** o **modelo de simulação.**

- A **validação** por **meio da comparação** de resultados de **simulações e teóricos** devem ser utilizada **com cuidado**, pois ambos pode ser **inválidos** no sentido de que ambos podem **não representar** o comportamento de **um sistema real.**

3.2.3 Resultados teóricos

- Também, **alternativamente** assim. A **modelagem analítica** permite a validação de **casos complexos**. Por exemplo, um **modelo de simulação** de **um multiprocessador** pode **validado** usando um sistema com **um ou dois** processadores, e antão **a teoria (modelagem analítica)** pode ser utilizada para **inferir sobre um maior número de processadores.**

- Todavia, devemos destacar que um modelo completamente validado é um mito. Na verdade, é possível apenas mostrar que o modelo não é **inválido** para algumas **situações investigadas.** Para provar que **um modelo** produz os mesmos resultados de um sistema original usualmente seriam necessárias **quantidades sem precedentes** de recursos. O **exercício de validação** é portanto **limitado a alguns cenários**, e uma **tentativa** é feita para **cobrir os casos mais importantes.**

(3) Quantas das **observações iniciais** devem ser **descartadas** para garantir que o modelo atingiu o estado estacionário (i.e., realizar a **remoção do transiente**)?

3.3 REMOÇÃO DE TRANSIENTE

3.3 REMOÇÃO DE TRANSIENTE

- Na **maioria** das simulações, apenas o **desempenho em estado estacionário,** que é o desempenho depois que o sistema atingiu o estado **estável (estabilidade),** é realmente **de interesse.**

- Em tais caso, a **parte inicial da simulação não deve ser incluída** nos resultados finais da simulação. A **parte inicial** é também chamada de **estado transiente**. O problema de identificar fim do **estado transiente** é chamado de **remoção do transiente.**

- A **principal dificuldade** coma **remoção do transiente** é que não é possível definir exatamente o que constitui o **estado transiente** e quando o **estado transiente termina**. Todos os métodos de remoção de transiente são **portanto heurísticas.**

3.3 REMOÇÃO DE TRANSIENTE

- Há **06 (seis) métodos** básicos de **remoção de transiente.**

1. **Long Runs** (execuções longas)
2. **Proper initialization** (inicialização apropriada)
3. **Truncation** (truncamento)
4. **Initial data deletion** (remoção de dados iniciais)
5. **Moving average of independente replications** (média móvel de replicações independentes)
6. **Batch means**

3.3 REMOÇÃO DE TRANSIENTE

1. Long Runs (execuções/rodadas longas)

O **primeiro método** consiste em simplesmente usar **execuções/rodadas muito longas**. Ou seja, execuções que sejam **longas o suficiente** para garantir que a presença das **condições iniciais não** afetarão **o resultado final.**

Há **duas desvantagens** para este método. **Primeiro**, há o **desperdício de recursos**. Se os recursos são dispendiosos, a simulação não deve rodar mais que o absolutamente necessário. **Segundo**, mesmo que não haja o consumo excessivo de recursos, é **difícil assegurar** que a duração da execução é **suficientemente** longa. Por estas duas razões, há assim **restrições** óbvias para o uso deste método.

3.3 REMOÇÃO DE TRANSIENTE

2. Proper initialization (inicialização apropriada)

- Este método requer **começar a simulação** em um **estado** que esteja **próximo do estado estacionário.**

- Por exemplo, para simular o escalonamento de jobs em uma CPU se pode **iniciar a simulação** já considerando **uma certa quantidade de jobs na fila** (em vez de uma fila vazia). O **número de jobs inicial** pode ser determinado por **simulações anteriores** ou por **simples análise.**

- Este método resulta em uma **redução** dos **períodos transientes**, diminuindo **as influências no resultado final**.

3.3 REMOÇÃO DE TRANSIENTE

3. Truncation (truncamento)

- **Este e os métodos subsequentes** são baseados **na suposição** de que a **variabilidade** durante o **estado estacionário** é **menor** do que durante o **estado transiente**, o que é geralmente verdade.

- Neste método, a **variabilidade** é medida em termos de **intervalo: o valor mínimo** e o **valor máximo** obtidos nas observações**.**

- Se uma trajetória que mostra **sucessivas observações** é apresentada em um gráfico, **intervalos de valores obtidos nas observações** vão progressivamente estabilizando conforme a simulação entra na fase de **estado estacionário**, conforme detalhado a seguir.

3.3 REMOÇÃO DE TRANSIENTE

3. Truncation (truncamento)

- Dada uma amostra de **n** observações **{x1, x2, ..., xn}**, este método consiste em ignorar as primeiras **L** observações e então calcular o mínimo e o máximo das restantes **n – L** observações.

- Este passo é repetido para **L = 1, 2, 3, ..., (n – 1)** até que a **(L+1)-ésima** observação não seja nem a mínima nem a máxima das observações remanescentes. O valor de **L** dá o comprimento do estado transiente.

3.3 REMOÇÃO DE TRANSIENTE

3. Truncation (truncamento)

- **Exemplo**: Considere a seguinte sequência de observações: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 10, 9, 10, 11, 10, 11, 10, 9, ...
- **Ignorando** a primeira observação (**L = 1**), o intervalo da sequência remanescente é (2, 11). Como a **segunda** observação (= 2) é igual ao mínimo, a fase transiente é mais longa que 1.
- **Ignorando** as duas primeiras observações (**L = 2**), o intervalo da sequência remanescente é (3, 11). Novamente, a **próxima observação** (terceira, = 3) é igual ao mínimo, a fase transiente é mais longa que 2.
- **Repetindo-se o anterior**, chega-se então a **L = 9**. O intervalo da sequência remanescente é **(9, 11),** e a **próxima observação** (décima, = 10) não é **nem mínima nem máxima**. O comprimento da fase transiente é portanto **9,** e as **primeiras nove observações** são **descartadas.**

3.3 REMOÇÃO DE TRANSIENTE

3. Truncation (truncamento)

- O intervalo da sequência remanescente é **(9, 11),** e a **próxima observação** (décima, = 10) não é **nem mínima nem máxima**. O comprimento da fase transiente é portanto **9,** e as **primeiras nove observações** são **descartadas.**

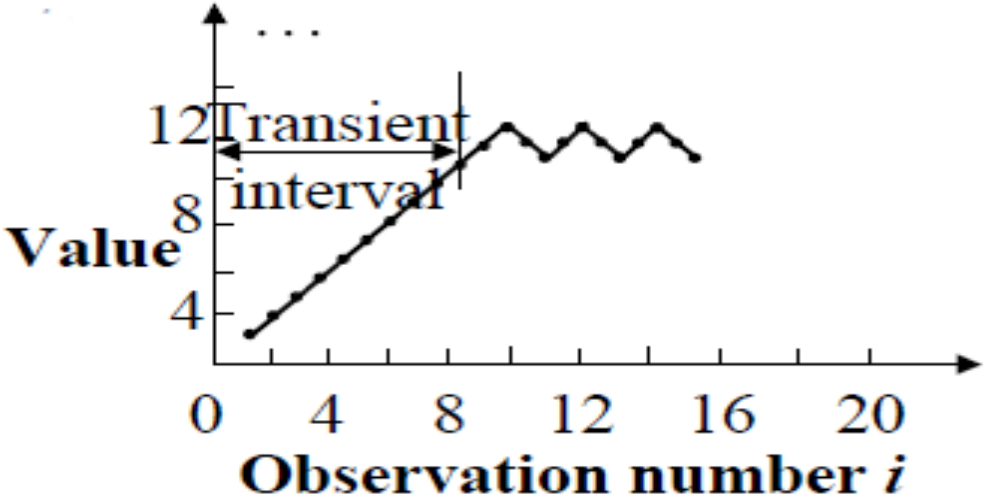

3.3 REMOÇÃO DE TRANSIENTE

4. Initial Data Deletion (Remoção de dados iniciais)

- Este método consiste em considerar **a média cruzada** entre distintas **replicações**, como detalhado a seguir.

- **Cada replicação** consiste de uma rodada completa da simulação. As **replicações diferem** apenas nos **valores das sementes** usadas nos geradores de números aleatórios. Ou seja, os **valores dos parâmetros** de entrada são **os mesmos** em todas as replicações.

- Suponha que há **m** replicações de tamanho **n** cada. Seja x_{ij} a **j-ésima observação** na **i-ésima replicação**. Note que **j** varia de **1** a **n** ao longo do **eixo de tempo**, enquanto **i** varia de **1** a **m** com respeito a **replicações**.

3.3 REMOÇÃO DE TRANSIENTE

4. Initial Data Deletion (Remoção de dados iniciais)

- O **método** consiste dos seguintes passos:

1. Obtenha uma **trajetória de média** calculando a **média cruzada** das replicações.

$$\bar{x}_j = \frac{1}{m}\sum_{i=1}^{m} x_{ij} \quad , j = 1, 2, 3, \dots, n$$

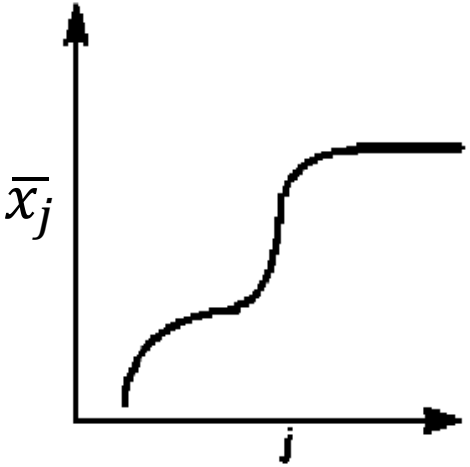

Veja que $\bar{x}_j$ é a média do valor da **j-ésima** observação, considerando todas as **m** replicações,.

3.3 REMOÇÃO DE TRANSIENTE

2. Obtenha a **média total**.

$$\bar{\bar{x}} = \frac{1}{n}\sum_{j=1}^{n} \bar{x}_j$$

Veja que $\bar{\bar{\boldsymbol{x}}}$ é a média das médias.

3. Seja **L = 1**. Assuma que o estado transiente tem comprimento ***L*** (em nr. de observações). Daí, remova as *L* primeira observações da trajetória da média e calcule a **média geral** para os ***n – L*** valores remanescentes.

$$\overline{\overline{x_L}} = \frac{1}{n-L}\sum_{j=L+1}^{n} \bar{x}_j$$

4. Calcule a **diferença relativa** (*relative change*) da **média geral**:

$$Relative\ change = \frac{\overline{x_L} - \bar{x}}{\bar{\bar{x}}}$$

5. Repita os **Passos 3 e 4** variando **L** de 1 a **n-1**. Gráficos da **média geral** e da diferença relativa como funções de **L** são mostrados abaixo. Depois de um certo valor de **L**, a diferenças relativa estabiliza. Este ponto é conhecido como o **joelho (knee),** e o valor correspondente **de L no joelho** é o comprimento do **intervalo transiente**.

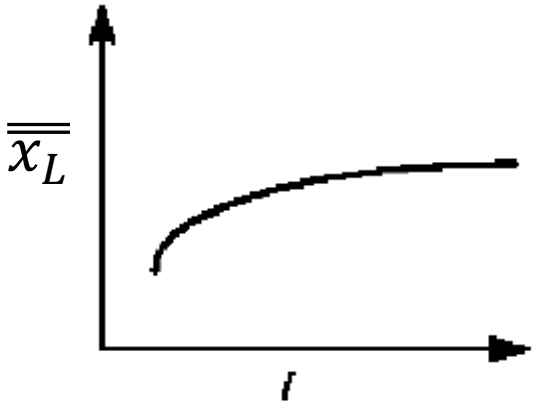

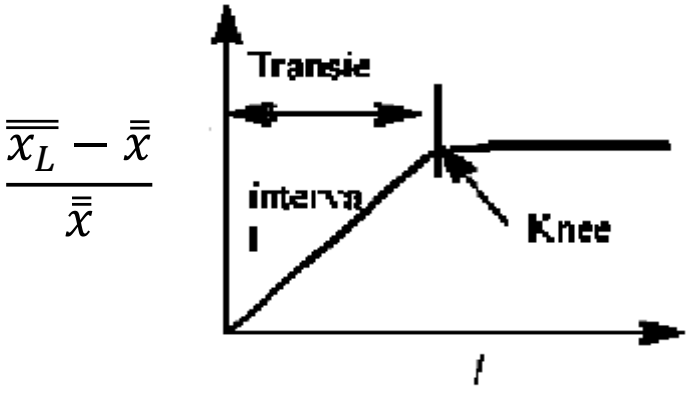

3.3 REMOÇÃO DE TRANSIENTE

5. Moving average of independent replications (média móvel de replicações independentes)

- Este método é similar ao método de **remoção de dados iniciais**. A **diferença** chave é que este método requer o cálculo da **média** considerando uma **janela de intervalo de tempo deslizante** em vez da média total.

- Dadas **m** replicações de tamanho **n** cada, novamente seja x_{ij} a **j-ésima** observação na **i-ésima** replicação. Os **passos** a serem considerados são apresentados a partir do próximo slide.

1. Obtenha uma **trajetória de média** calculando a **média cruzada** das replicações.

$$\overline{x_j} = \frac{1}{m}\sum_{i=1}^{m} x_{ij} \quad , j = 1, 2, 3, \dots, n$$

2. Seja **k = 1**. Obtenha uma **trajetória de média móvel** (gráficos) de sucessivos intervalos de **2k+1** valores:

$$\overline{\overline{x_j}} = \frac{1}{2k+1}\sum_{l=-k}^{k} \overline{x_{j+l}} \qquad , j = k+1, k+2, \dots, n-k$$

3. Repita o **Passo 2**, com **k = 2, 3, ...** Até que a trajetória (gráfico) seja suficientemente suave. Ache então o **joelho (knee)** do gráfico. O valor de **j** no joelho dá o **comprimento da fase transiente**.

Exemplo

$$\bar{\bar{x}}_j = \frac{1}{2k+1}\sum_{l=-k}^{k}\overline{x_{j+l}}$$

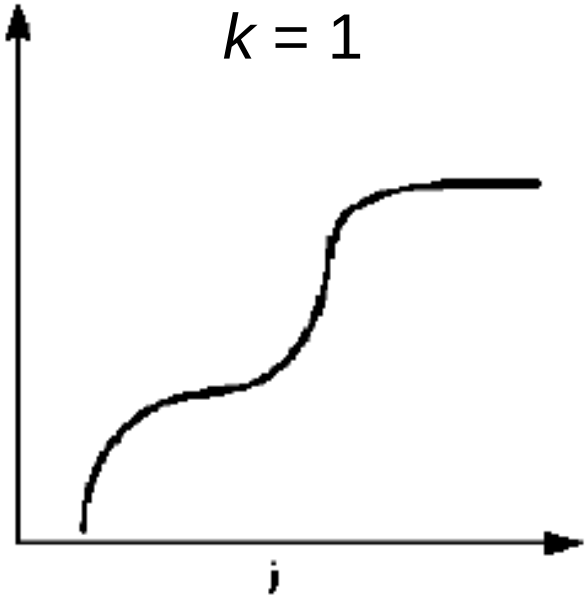

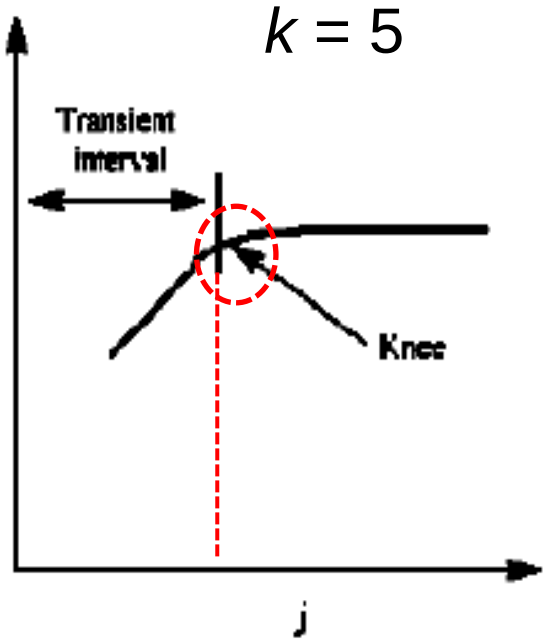

3.3 REMOÇÃO DE TRANSIENTE

6. Batch Means (médias em batch)

- Este método requer executar **uma simulação muita longa de N observações,** e em seguida dividi-la em partes de igual duração. Cada parte é chamada de um **batch** ou **subamostra**.

- A **média** das observações em **cada batch** é chamada de **média batch**. O método requer o estudo da variância destas **médias batch** como uma função do tamanho do **batch**.

- Como mostrado na figura a seguir (próximo slide), uma rodada de **N** observações pode ser dividida em **m batches** de tamanho **n** cada, onde $m = \lfloor N/n \rfloor$. Seja (comece) **n = 2**, e seja x_{ij} a **j-ésima** observação no **i-ésimo batch**. Considere os passos a seguir (próximo slide).

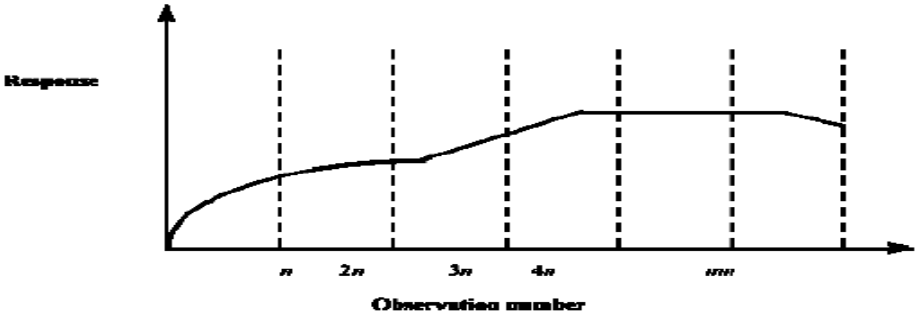

1. Para cada **batch**, compute a **média batch:**

$$\bar{x}_i = \frac{1}{n}\sum_{j=1}^{n} x_{ij} \ , \qquad i = 1, 2, 3, \dots, m$$

2. Calcule a **média geral**: $\bar{\bar{x}} = \frac{1}{m}\sum_{i=1}^{m} \bar{x}_i$

3. Calcule a **variância das médias batch:** $Var(\bar{x}) = \frac{1}{m-1}\sum_{i=1}^{m} (\bar{x}_i - \bar{\bar{x}})^2$

4. Repita os **Passos 1 e 3** para **n = 3, 4, 5, 6,....** Em seguida, plote (gráfico) a **variância** como função do **tamanho do batch** (**n**). O **comprimento do fase transiente** é o valor de **n** para o qual a variância começa a **efetivamente diminuir.**

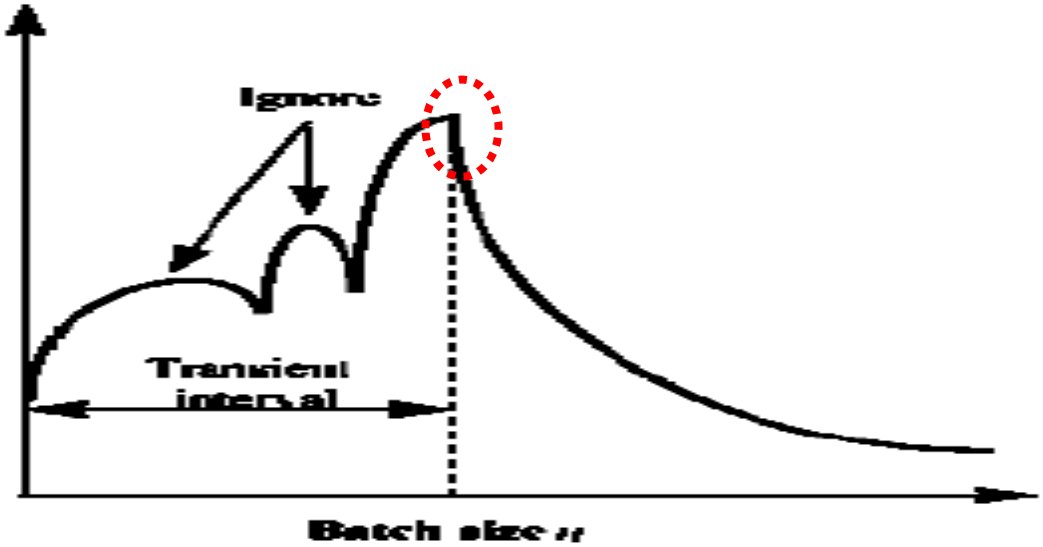

n

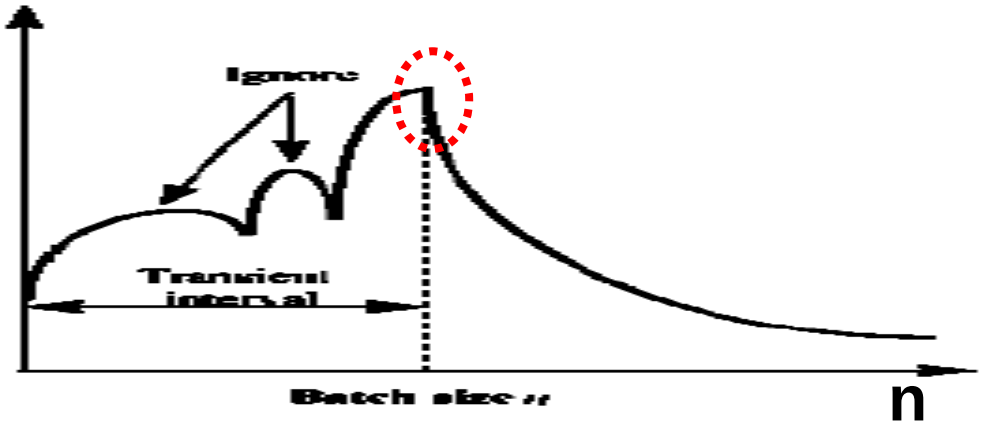

- Se o valor de **n** é muito menor que o **comprimento da fase transiente, L,** os **batches** construídos fazem com que a média total seja próxima das médias dos **batches iniciais**, e a **variância** é “até” ser **pequena** para certos valores de **n.**
- Quando o **tamanho do batch, n,** cresce, a **variância aumenta**. Porém, para **n maio**r que **L**, apenas a **primeira média de batch** é diferente; as outras **médias de batches** são aproximadamente iguais. Isso resulta na **diminuição** definitiva **da variância.**

(4) quanto tempo deve durar uma simulação?

3.4 TÉRMINO DA SIMULAÇÃO

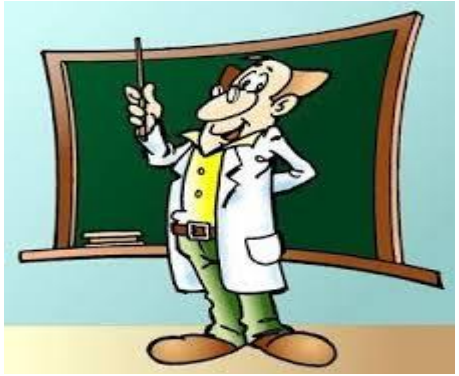

3.4 TÉRMINO DA SIMULAÇÃO

- Embora na **maioria das simulações** o desempenho de **estado estacionário** seja o de **interesse**, há sistemas que **nunca** chegam ao estado estacionário. Esses sistemas operam em **estado transiente.**

- **Exemplos** desses sistemas são aqueles que **são desligados às 5 PM todos os dias**, ou sistemas que cujos **parâmetros** de configuração (luz, temperatura, umidade, etc.) **mudam** ao longo do tempo. As simulações nestes caso **não precisam de remoção da fase transiente**.

- **Outra** questão relacionada se refere às **condições finais**, i.e., as condições **no final da simulação**. O estado do sistema no final da simulação pode **não ser típico do estado estacionário**. Nestes casos, é necessário **remover da resposta a parte final**. Os métodos para isso são análogos àqueles usados para os **períodos transientes iniciais**.

3.4 TÉRMINO DA SIMULAÇÃO

- Finalmente, o **analista** (projetista) deve ter cuidado ao **manipular as entidades** (jobs, etc.) que **não foram concluídas** (terminadas, tratadas, etc.) **ao final da simulação**.

- Considere o exemplo da simulação de escalonamento da CPU. No cálculo do **tempo de serviço médio** (ou média do tempo de serviço), apenas os jobs que completaram (terminaram) o serviço devem ser incluídos, ou seja:

- **Tempo médio de serviço** =
  Tempo total de serviço / No. de Jobs que completaram o serviço

3.4 TÉRMINO DA SIMULAÇÃO

- Para computar o **tempo médio de espera,** apenas os jobs que **terminaram a espera e começaram a execução do serviço** devem ser considerados, ou seja:

- **Tempo médio de espera** =
  Soma do tempo de espera / No. de Jobs que receberam serviço

3.4 TÉRMINO DA SIMULAÇÃO

- Se q_j é comprimento da fila no **j-ésimo** evento que resultou em uma mudança do comprimento da fila, a **média** de $q_j{}'$s não fornece o comprimento médio da fila, isto é:

$$comprimento\ médio\ da\ fila = \frac{\sum_{j=1}^{n}(comprimento\ da\ fila\ no\ evento\ j}{n{:}\ número\ de\ eventos}$$

- Na verdade, deve-se usar a **média no tempo** de um **processo de comprimento da fila**, isto é:

$$Comprimento\ médio\ da\ fila = \frac{1}{T}\int_0^T comprimento(t)dt$$

3.4 TÉRMINO DA SIMULAÇÃO

EXEMPLO: pag. 430. Raj Jain.

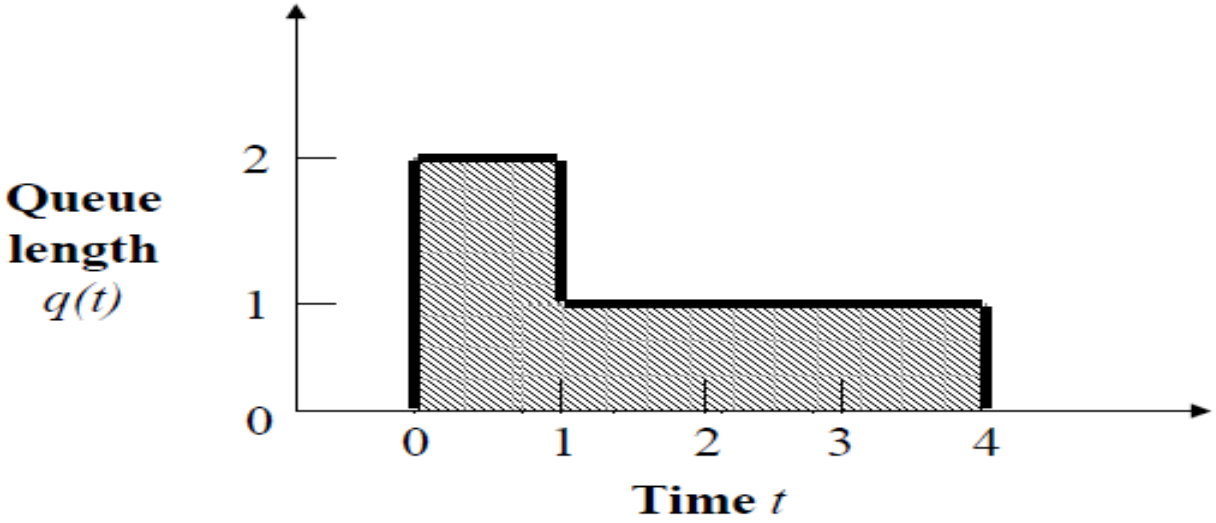

- Three events: Arrival at t=0, departures at t=1 and t=4
- Q = 2, 1, 0 at these events. Avg Q ≠ (2+1+0)/3 = 1
- Avg Q = Area/4 = 5/4

3.4.1 CRITÉRIO DE PARADA

- É importante que a duração (comprimento) da simulação seja **adequadamente escolhida**. Se a simulação é **muito curta**, os resultados podem ter muita **variabilidade**. Por outro lado, se a simulação é **muito longa**, recursos (computacionais/humanos) são **desnecessariamente utilizados**.

- Da discussão da **primeira parte** deste módulo sobre a determinação do tamanho da amostra, segue que a simulação deve rodar até que **o intervalo de confiança** para a média da resposta tenha **a largura desejada.**

- Se a média amostral é $\bar{x}$ e a sua variância é Var($\bar{x}$), um intervalo de confiança de **100(1-α)%** para a média é dada por: $\bar{x} \pm z_{1-\frac{\alpha}{2}} Var(\bar{x})$

4. Síntese Final

- Este módulo apresentou **brevemente** o tema **Intervalo de Confiança e Análise de Resultados de Simulação**

- O tema foi desenvolvido sob o enfoque geral de **Avaliação de Desempenho de Redes.**

- Os slides desta aula estão disponíveis em **https://sites.google.com/site/carlokleber/disciplinas-ministradas/avalia-de-desempenho-de-redes**

- A **lista de exercícios**, disponível no site acima, propicia a oportunidade de praticar, complementar e fixar o conteúdo ministrado.

Prática e Estudo Individual

Acesse o MOODLE tempestivamente, acesse a aba atividades e realize a atividade prevista.

Referências

- JAIN, R. The art of computer systems performance analysis: techniques for experimental design, measurement, simulation, and Modeling. John Wiley &Sons, Inc., 1991. 685p.
- TRIVEDI, K. S. Probability and statistics with reliability, queuing and computer science applications. 2nd ed. New York: John Wiley & Sons, 2002. 830p.
- Taboga, Marco (2017). "Binomial distribution", Lectures on probability theory and mathematical statistics, Third edition. Kindle Direct Publishing. Online appendix. https://www.statlect.com/probability-distributions/
- Leão, R. M. M (2015). “Estatística e Modelos Probabilísticos”, Notas de aula. Online http://www.land.ufrj.br/~classes/est-prob-2015/
- H. Pishro-Nik, "Introduction to probability, statistics, and random processes", available at https://www.probabilitycourse.com, Kappa Research LLC, 2014.
- Joseane Farias et al. Simulador de Redes IP. https://www.researchgate.net/publication/255645154_QNet_-_Um_Simulador_Grafico_de_Trafego_IP_para_Redes_Convergentes

Fim

Prof. Carlo Kleber da Silva Rodrigues
carlo.kleber@ufabc.edu.br

APÊNDICES

APÊNDICE A

ESTUDO EXTRACLASSE

Como calcular PERCENTIL?

PERCENTIL?

- Dada uma amostra (ou coleção de dados), os **percentis** são medidas que **dividem a amostra ordenada (por ordem crescente dos dados) em 100 partes**, cada uma com uma percentagem de dados aproximadamente igual.
- **Exemplo**: Uma menina de 4 anos, 105 cm de altura, está no **80º percentil** (ou percentil 80) para meninas dessa idade. Isso **significa** que **80%** das meninas dessa idade estão abaixo dessa altura. Da mesma forma, podemos afirmar que a altura dessa menina é superada por **20%** das meninas da sua idade.
- O **1º percentil** determina o **1% menor dos dados**; e **98º percentil** determina os **98% menores** dos dados. O **25º percentil** determina o primeiro **quartil**. O **50º percentil** determina a **mediana**. De igual forma, o **10º percentil** determina o **primeiro decil,** e o **80º percentil** determina o **oitavo decil.**

https://pt.wikipedia.org/wiki/Percentil https://amenteemaravilhosa.com.br/percentis/

COMO CALCULAR O PERCENTIL?

- Para calcular um percentil, devemos levar em consideração os seguintes passos:

➢ Classifique os dados do menor para o maior.

➢ Calcule a **posição** do **percentil** aplicando a seguinte fórmula:

➢ **i = k (n + 1) / 100**

- **Onde:**

❑ **i** = Posição dentro da amostra solicitada que representa o percentil.

❑ **k** = número do percentil a ser encontrado.

❑ **n** = tamanho da amostra.

❑ Se **i** é um número inteiro, então **Pk = Yi** (valor de onde i está localizado).

❑ Se **i** não é um número inteiro, então Pk = (1-d) Yi + (d) Yi+1

❑ **Yi+1** representa o valor que está **na posição ao lado de Yi.**

❑ **d** = valores decimais.

COMO CALCULAR O PERCENTIL?

- Qual o **percentil 25 (P25) das idades** para um grupo de homens e mulheres que fazem parte de uma indústria farmacêutica **(k =25)?**

FUNCIONÁRIO	IDADE	TAMANHO DA AMOSTRA (n)
HOMENS	18, 19, 20, 22, 24, 26, 29, 31, 35, 45, 61	11
MULHERES	19, 20, 21, 22, 23, 24, 25, 27, 28, 29, 30, 31, 32, 35	14

HOMENS: **i** = k (n + 1) / 100; i = 25 (11 + 1) / 100 = **3**. Por se tratar de um número inteiro **i**, o valor da idade encontrado na posição 3 é tomado como o valor do **percentil 25.** Neste caso a idade do grupo de homens que ocupa a **posição 3** é de **20 anos**. Isso significa que **25%** da amostra masculina tem menos de 20 anos.

COMO CALCULAR O PERCENTIL?

FUNCIONÁRIO	IDADE	TAMANHO DA AMOSTRA (n)
HOMENS	18, 19, 20, 22, 24, 26, 29, 31, 35, 45, 61	11
MULHERES	19, 20, 21, 22, 23, 24, 25, 27, 28, 29, 30, 31, 32, 35	14

MULHERES: **i** = k (n + 1) / 100; i = 25 (14 + 1) / 100 = **3,75**. Como i não é inteiro, então devemos interpolar os resultados, tomando **i = 3** e **d = 0,75**. A substituição dos dados na fórmula ficaria assim:

Pk = (1-d) Yi + (d) Yi+1; P25 = (1-0,75) 21 + (0,75) 22 = **21,75**

Portanto, o **25º** percentil para o grupo de mulheres é de **21,75 anos**. Isso significa que **25% da amostra** de mulheres tem idade **inferior a 21,75 anos**.

Ainda pode-se afirmar que **75%** das mulheres estão acima de **21,75 anos.**

APÊNDICE B

ESTUDO EXTRACLASSE

Estimativa com amostras reais dependentes & Replicações independentes?
TRIVEDI P. 689 SEC 10.2.5

Contradição de n (10 ou 30) para Normal?
P. 241 Ex. 4.20 Trivedi

APÊNDICE C

ESTUDO EXTRACLASSE

CAPÍTULO 13 RAJ JAIN

COMPARING SYSTEMS USING SAMPLE DATA

FIM